

ScrapIQ CI

Intelligent Web Scraping SaaS

Cahier des Charges

Fonctionnel & Technique

SaaS Web Scraping Intelligent
pour le marché ivoirien

Version 1.0

17 July 2026

Document confidentiel — © ScrapIQ CI

Table des matières

Chapitre 1 — Contexte du projet	15
1.1 Présentation du marché ivoirien	15
1.2 Problématique identifiée	16
1.3 Opportunité de marché	17
1.4 Étude de marché approfondie	18
1.5 Analyse concurrentielle	20
1.6 Segmentation et ciblage	22
Chapitre 2 — Objectifs du projet	25
2.1 Objectifs fonctionnels	25
2.2 Objectifs techniques	26
2.3 Objectifs business	27
2.4 Indicateurs de performance (KPIs)	28
2.5 Critères de succès	30
Chapitre 3 — Fonctionnalités détaillées	35
3.1 Scraping multi-sources	35
3.2 IA cleaner (nettoyage, dédoublonnage, enrichissement)	38
3.3 Moteur de recherche Elasticsearch	41
3.4 Cartographie OpenStreetMap	43
3.5 Exports multi-formats	45
3.6 Notifications multi-canal	47
3.7 API REST publique	49
3.8 Authentification et sécurité	51
3.9 RBAC et gestion des rôles	53
3.10 PWA et expérience mobile	55
3.11 Business Intelligence (BI)	57
3.12 Plateforme SaaS Enterprise	59
3.13 Agents IA multi-agents	62
3.14 Sécurité globale	65
Chapitre 4 — Architecture technique	70
4.1 Vue d'ensemble	70
4.2 Architecture logique	72
4.3 Architecture physique	74
4.4 Microservices et distribution	76
4.5 Flux de données	78
4.6 Diagrammes d'architecture	80
Chapitre 5 — Cas d'utilisation	90
5.1 Acteurs du système	90

5.2 Cas d'utilisation Owner	92
5.3 Cas d'utilisation Admin	94
5.4 Cas d'utilisation Manager	96
5.5 Cas d'utilisation Agent	98
5.6 Cas d'utilisation Viewer	100
Chapitre 6 — Wireframes	105
6.1 Tableau de bord	105
6.2 Recherche	107
6.3 Carte interactive	109
6.4 Entreprises	111
6.5 Jobs de scraping	113
6.6 Scraper multi-sources	115
6.7 Exports	117
6.8 API REST Explorer	119
6.9 Notifications	121
6.10 Équipe et permissions	123
6.11 Back office	125
6.12 Sécurité	127
6.13 PWA mobile	129
6.14 Business Intelligence	131
6.15 SaaS Enterprise	133
6.16 Agents IA	135
Chapitre 7 — Diagrammes UML	140
7.1 Diagramme de cas d'utilisation	140
7.2 Diagramme de classes	143
7.3 Diagrammes de séquence	146
7.4 Diagramme d'activité	149
7.5 Diagramme d'état	151
7.6 Diagramme de composants	153
Chapitre 8 — Diagrammes Mermaid	158
8.1 Flowcharts	158
8.2 Diagrammes de séquence	161
8.3 Diagramme entité-association	164
8.4 Diagramme de Gantt	166
Chapitre 9 — API REST	170
9.1 Conventions et versioning	170
9.2 Authentification	172
9.3 Endpoints Entreprises	173
9.4 Endpoints Scraping	176
9.5 Endpoints Exports	178
9.6 Endpoints Agents IA	180
9.7 Endpoints Notifications	182
9.8 Endpoints SaaS & facturation	184
9.9 Endpoints Sécurité	186
9.10 Webhooks & Swagger	188

Chapitre 10 — Base de données	192
10.1 Vue d'ensemble du schéma	192
10.2 Modèles multi-tenant	194
10.3 Modèles métier (entreprises)	197
10.4 Modèles scraping et jobs	200
10.5 Index et optimisations	203
10.6 Partitionnement et archivage	205
Chapitre 11 — Sécurité	210
11.1 Authentification JWT & OAuth	210
11.2 Double authentification (2FA)	212
11.3 Contrôle d'accès RBAC	214
11.4 WAF et protection DDoS	216
11.5 Chiffrement des données	218
11.6 Conformité RGPD / APIPD	220
11.7 Audit et traçabilité	222
11.8 Rate limiting et anti-abus	224
Chapitre 12 — Déploiement	229
12.1 Conteneurisation Docker	229
12.2 Orchestration Kubernetes	231
12.3 Pipeline CI/CD	233
12.4 Infrastructure cloud	235
12.5 Monitoring et observabilité	237
12.6 Stratégie de scalabilité	239
Chapitre 13 — Tests	244
13.1 Tests unitaires	244
13.2 Tests d'intégration	246
13.3 Tests end-to-end	248
13.4 Tests de performance	250
13.5 Tests de sécurité	252
13.6 Tests de charge	254
Chapitre 14 — Planning	259
14.1 Phases du projet	259
14.2 Diagramme de Gantt	261
14.3 Jalons et livrables	263
Chapitre 15 — Budget	268
15.1 Coûts de développement	268
15.2 Coûts d'infrastructure	270
15.3 Licences et services tiers	272
15.4 Maintenance et exploitation	274
15.5 Retour sur investissement (ROI)	276
Chapitre 16 — Roadmap	281
16.1 MVP	281
16.2 Version 1 (V1)	283
16.3 Version 2 (V2)	285

16.4 Version 3 (V3)	287
Chapitre 17 — Maintenance	291
17.1 Maintenance corrective	291
17.2 Maintenance évolutive	293
17.3 Maintenance préventive	295
17.4 SLA et support	297
Chapitre 18 — Évolutions	301
18.1 Évolutions envisagées	301
18.2 Recherche et développement	303
18.3 Innovations futures	305
Chapitre 19 — Annexes	309
19.1 Glossaire	309
19.2 Références et normes	311
19.3 Contacts	313

CHAPITRE 1

Contexte du projet

Ce premier chapitre pose le cadre général du projet ScrapIQ CI. Il décrit le contexte économique et numérique de la Côte d'Ivoire, identifie la problématique à laquelle la plateforme répond, quantifie l'opportunité de marché, présente une étude de marché approfondie, analyse l'environnement concurrentiel et précise la segmentation et le ciblage des clients. L'objectif est de justifier, par des données concrètes, la pertinence et la viabilité d'une solution SaaS de web scraping intelligent dédiée au marché ivoirien.

1.1. Présentation du marché ivoirien

La Côte d'Ivoire est l'une des économies les plus dynamiques d'Afrique de l'Ouest. Avec une population estimée à plus de 29 millions d'habitants et une croissance du PIB régulièrement supérieure à 6 % sur la dernière décennie, le pays constitue un hub économique régional majeur au sein de l'UEMOA et de la CEDEAO. Le tissu économique ivoirien est dominé par les secteurs de l'agriculture (cacao, café, hévéa, palmier à huile), des services, du commerce, du BTP, des télécommunications et d'une industrie manufacturière en pleine expansion autour d'Abidjan, de San Pedro et de Bouaké.

Le commerce formel et informel y est extrêmement dense. Abidjan, la capitale économique, concentre des dizaines de milliers d'entreprises enregistrées au RCCM (Registre du Commerce et du Crédit Mobilier) ainsi qu'un secteur informel estimé à plus de 80 % de l'activité économique. Les annuaires officiels, les pages professionnelles, les réseaux sociaux (notamment Facebook, très utilisé par les commerçants ivoiriens), Google Maps et les sites web d'entreprises constituent une mine d'informations dispersées et hétérogènes sur ces acteurs économiques.

Cependant, ces données sont éclatées, non structurées, souvent incomplètes, redondantes et de qualité variable. Il n'existe pas, à ce jour, de plateforme centralisée, intelligente et accessible permettant à un acteur économique (commercial, marketeur, investisseur, institution) d'obtenir rapidement une vue fiable, enrichie et géolocalisée des entreprises d'un secteur donné, dans une ville ou une commune donnée. Ce déficit informationnel pénalise la prospection commerciale, l'analyse de marché, le ciblage publicitaire et la prise de décision.

1.1.1 Indicateurs macro-économiques clés

Indicateur	Valeur (estimation)	Source / Remarque
Population totale	≈ 29,5 millions	INS, projection 2024
Croissance du PIB	6,5 % – 7,2 %	Banque Mondiale, 2023-2024
PIB nominal	≈ 90 milliards USD	FMI, 2024
Taux de pénétration Internet	≈ 71 %	ARTCI, 2024
Utilisateurs de smartphones	≈ 18 millions	GSMA, 2024
Utilisateurs Facebook	≈ 8 millions	Meta, 2024
Entreprises enregistrées (RCCM)	> 250 000	Greffe du tribunal de commerce
Secteur informel (% emploi)	≈ 82 %	BIT / INS
Nombre de communes	197	Décret 2011-263

Indicateur	Valeur (estimation)	Source / Remarque
Villes principales	Abidjan, Bouaké, Yamoussoukro, San-Pédro, Korhogo	—

La forte pénétration d'Internet et des smartphones, combinée à l'usage massif des réseaux sociaux par les commerçants locaux, crée un terrain particulièrement favorable au web scraping. Une quantité considérable de données business est publiquement accessible en ligne, mais reste inexploitée faute d'outils adaptés au contexte local (formats d'adresses ivoiriennes, numéros de téléphone à 10 chiffres depuis 2021, noms d'entreprises incluant des formes juridiques variées comme SARL, SA, EURL, SNC, GIE, entreprises individuelles).

1.1.2 Écosystème numérique et data

L'écosystème numérique ivoirien s'est structuré autour de plusieurs dynamiques : le Plan National de Développement (PND 2021-2025) qui fait du numérique un axe stratégique, la stratégie « Côte d'Ivoire Numérique 2030 », l'essor de hubs technologiques à Abidjan (Village des NTIC, Incubateurs), et l'adoption croissante du cloud et du SaaS par les entreprises locales. Le marché du data-driven business en est néanmoins à ses balbutiements : la plupart des PME n'ont pas encore accès à des outils de business intelligence abordables et localisés.

Parallèlement, le cadre réglementaire évolue. La loi n° 2013-450 relative à la protection des données personnelles, renforcée par l'autorité de régulation l'APIPD (Autorité de Protection des Données Personnelles), impose des obligations de loyauté, de finalité et de sécurité dans la collecte et le traitement des données. ScrapIQ CI intègre dès sa conception ces exigences de conformité, ce qui constitue un différenciateur majeur face à des solutions génériques importées.

1.2. Problématique identifiée

La problématique centrale à laquelle ScrapIQ CI répond peut s'énoncer ainsi : **comment permettre aux acteurs économiques ivoiriens d'obtenir, de manière rapide, fiable et conforme, des données business qualifiées et géolocalisées à partir de sources publiques disparates, sans avoir à maîtriser les techniques complexes du web scraping ?**

1.2.1 Les cinq problèmes fondamentaux

#	Problème	Conséquence sur les utilisateurs
1	Données dispersées sur de multiples sources hétérogènes (Google Maps, Facebook, LinkedIn, sites web, RCCM)	Prospection longue, fastidieuse, coûteuse en ressources humaines
2	Données brutes de qualité médiocre (doublons, formats incohérents, informations manquantes)	Fichiers inexploitables, erreurs de ciblage, perte de crédibilité
3	Absence de géolocalisation fiable des entreprises locales	Impossibilité d'analyser la densité commerciale par zone, de planifier des tournées
4	Outils de scraping existants non adaptés au contexte ivoirien (formats, langues, sources locales)	Résultats imprécis, beaucoup de bruit, faible taux de correspondance
5	Risque juridique et technique (blocages IP, CAPTCHA, non-conformité RGPD/APIPD)	Fragilité opérationnelle, exposition à des poursuites, interruptions de service

1.2.2 Illustration concrète de la problématique

Considérons un commercial d'une entreprise de distribution de matériel électrique basée à Abidjan, souhaitant prospecter les quincailleries de la commune de Yopougon. Sans outil adapté, il devra : ouvrir Google Maps et saisir « quincaillerie Yopougon », parcourir les résultats page par page, copier manuellement nom, adresse et téléphone dans un tableur, rechercher chaque enseigne sur Facebook pour vérifier l'activité, dédoubler les entrées redondantes, corriger les numéros de téléphone mal formatés, et tenter de géocoder les adresses à la main. Pour 200 quincailleries, cette tâche représente facilement 3 à 5 jours de travail, avec un résultat final de qualité incertaine et déjà partiellement obsolète.

Avec ScrapIQ CI, cette même opération se résume à une requête : « quincaillerie » dans la commune de « Yopougon ». La plateforme lance en quelques minutes un scraping multi-sources, nettoie et dédoublonne les données via des agents IA, enrichit chaque fiche (site web, horaires, secteur, score de qualité), géocode les adresses sur OpenStreetMap, et restitue un fichier exportable prêt à l'emploi. Le gain de temps est d'un facteur 50 à 100, et la qualité des données est significativement supérieure grâce au traitement IA.

Pain point critique

Le coût d'opportunité de la collecte manuelle de données business en Côte d'Ivoire est estimé à plusieurs dizaines de milliards de FCFA par an cumulés par l'ensemble des acteurs économiques. ScrapIQ CI transforme ce coût caché en valeur immédiatement actionnable.

1.3. Opportunité de marché

L'opportunité de marché pour ScrapIQ CI se situe à la confluence de plusieurs tendances structurelles : la digitalisation accélérée de l'économie ivoirienne, l'explosion du volume de données business en ligne, l'absence de solution locale spécialisée, et la maturité technologique atteinte par les techniques de scraping et d'IA qui permettent de traiter ces données à grande échelle et à un coût marginal faible.

1.3.1 Taille du marché adressable (TAM / SAM / SOM)

Segment	Définition	Estimation (entreprises cibles)	Potentiel CA annuel
TAM	Toutes les entreprises et indépendants ivoiriens susceptibles d'utiliser de la data business	≈ 1,2 million	≈ 60 Mds FCFA / an
SAM	PME, commerciaux, agences marketing, institutions, investisseurs en zones urbaines	≈ 180 000	≈ 18 Mds FCFA / an
SOM	Cible atteignable à 3 ans (Abidjan + grandes villes, segments prioritaires)	≈ 12 000 comptes	≈ 1,8 Mds FCFA / an

1.3.2 Facteurs favorables

- Volume de données en ligne en croissance exponentielle
 - Google Maps : des centaines de milliers de fiches d'établissements ivoiriens
 - Facebook : pages business actives pour la majorité des commerces urbains
 - LinkedIn : présence croissante des PME et cadres ivoiriens
- Absence de solution locale spécialisée et conforme
 - Les outils étrangers (Apollo, Lusha, ZoomInfo) ignorent le contexte ivoirien
 - Pas de normalisation des numéros (+225) ni des adresses communales
 - Aucune conformité native à l'APIPD
- Maturité technologique des techniques de scraping et d'IA

- Playwright / Puppeteer permettent le scraping robuste de sites dynamiques
- Les LLM permettent l'enrichissement, la classification et le scoring à coût raisonnable
- Elasticsearch offre une recherche full-text performante à grande échelle
- Réceptivité du marché au modèle SaaS
- Adoption croissante des abonnements logiciels par les PME ivoiriennes
- Tarification en FCFA et moyens de paiement locaux (Mobile Money) attendus

1.3.3 Verticales et cas d'usage à fort potentiel

Verticale	Cas d'usage type	Volume potentiel	Priorité
Commerce & distribution	Prospection de détaillants par zone et secteur	Élevé	P1
Agences marketing	Construction de bases de prospects pour campagnes	Élevé	P1
Institutions	Cartographie économique d'un territoire / secteur	Moyen	P2
Investisseurs	Analyse de la densité d'un secteur avant implantation	Moyen	P2
Livraison & logistique	Géolocalisation de points de collecte / livraison	Élevé	P1
Études & conseil	Production d'études de marché sectorielles	Moyen	P2
Assurances & banques	Enrichissement de fichiers clients, scoring KYC	Moyen	P3
EdTech / formation	Identification d'organismes de formation par zone	Faible	P3

Cette matrice verticales / cas d'usage confirme que ScrapIQ CI ne se limite pas à un outil de scraping, mais constitue une **infrastructure de données business** servant de socle à de multiples métiers. Cette polyvalence élargit considérablement le marché adressable et sécurise la récurrence des revenus via le modèle SaaS.

1.4. Étude de marché approfondie

L'étude de marché repose sur une analyse combinant données secondaires (rapports Banque Mondiale, INS, ARTCI, GSMA, études sectorielles), données primaires (interviews d'une quarantaine d'acteurs économiques ivoiriens : commerciaux, marketeurs, dirigeants de PME, responsables d'institutions) et une analyse technologique des sources de données disponibles en ligne.

1.4.1 Méthodologie de l'étude

Période	T2–T3 2024
Périmètre géographique	Abidjan (10 communes), Bouaké, Yamoussoukro, San-Pédro
Échantillon qualitatif	42 entretiens semi-directifs (30–60 min)
Échantillon quantitatif	216 répondants à un questionnaire en ligne
Sources de données analysées	Google Maps, Facebook, LinkedIn, RCCM, 12 sites web sectoriels
Critères de qualité	Taux de remplissage, fraîcheur, géocodabilité, conformité

1.4.2 Résultats clés de l'étude quantitative

Question	Oui	Non	Partiellement
Collectez-vous régulièrement des données business en ligne ?	78 %	9 %	13 %
Ces données sont-elles fiables et prêtes à l'emploi ?	11 %	44 %	45 %
Avez-vous déjà utilisé un outil de scraping ?	14 %	86 %	—
Le coût de collecte manuelle vous semble-t-il élevé ?	83 %	7 %	10 %
Seriez-vous prêt à payer un abonnement SaaS pour cela ?	67 %	12 %	21 %
La géolocalisation des entreprises est-elle importante pour vous ?	91 %	3 %	6 %
La conformité à l'APIPD est-elle un critère de choix ?	58 %	14 %	28 %

Les résultats convergent vers un besoin clairement exprimé : une large majorité des acteurs économiques collectent des données business en ligne, mais ces données sont rarement fiables et leur collecte est coûteuse. La disposition à payer existe pour deux tiers des répondants, et la géolocalisation ressort comme une fonctionnalité quasi indispensable. La conformité réglementaire est un critère de choix pour plus de la moitié, ce qui valide l'orientation « conforme par conception » de ScrapIQ CI.

1.4.3 Besoins fonctionnels prioritaires exprimés

- Recherche rapide d'entreprises par secteur, ville, commune, mot-clé
- Géolocalisation et visualisation cartographique des résultats
- Nettoyage automatique et dédoublonnage des données
- Enrichissement (site web, horaires, réseaux sociaux, secteur)
- Export multi-format (Excel, CSV, PDF, JSON) prêt à l'emploi
- Fraîcheur et fraîcheur de la donnée (date de dernière mise à jour)
- API pour intégration dans des outils tiers (CRM, ERP)
- Notifications en cas de changements détectés (nouvelle entreprise, fermeture)
- Tableau de bord d'analyse et de pilotage de l'activité de scraping
- Gestion multi-utilisateurs avec contrôle d'accès par rôle

1.4.4 Synthèse SWOT du projet

Forces (Strengths)	Faiblesses (Weaknesses)
Solution locale spécialisée et conforme APIPD ; IA de nettoyage/enrichissement ; géolocalisation native ; modèle SaaS abordable ; équipe technique expérimentée	Coût d'infrastructure initial ; dépendance à la disponibilité des sources ; besoin d'éducation du marché au scraping ; notoriété à construire
Opportunités (Opportunities)	Menaces (Threats)
Digitalisation accélérée ; absence de concurrent local ; partenariats institutions ; expansion régionale UEMOA ; essor du Mobile Money	Évolution des politiques anti-scraping des plateformes ; durcissement réglementaire ; entrée éventuelle d'un acteur étranger ; instabilité des sources

1.5. Analyse concurrentielle

Le paysage concurrentiel se compose de trois catégories d'acteurs : les outils internationaux de scraping et de data business (non spécifiques à la Côte d'Ivoire), les prestataires de services de collecte manuelle ou

semi-automatisée locaux, et les annuaires en ligne ivoiriens (statiques, non interrogeables en masse).

1.5.1 Matrice concurrentielle

Acteur / Solution	Type	Adaptation CI	IA	Géoloc.	Conformité	Prix
Apollo.io	SaaS data B2B	Faible	Partielle	Non	RGPD	\$\$\$
Lusha	SaaS data B2B	Faible	Non	Non	RGPD	\$\$\$
ZoomInfo	Enterprise data	Très faible	Partielle	Non	RGPD	\$\$\$\$
PhantomBuster	Scraping cloud	Moyenne	Non	Non	Limitée	\$\$
Octoparse	Scraping no-code	Moyenne	Non	Non	Limitée	\$\$
Annuaire CI (web)	Annuaire statiques	Élevée	Non	Non	Variable	Gratuit
Prestataires manuels	Service sur-mesure	Élevée	Non	Partielle	Variable	Variable
ScrapIQ CI (projet)	SaaS data B2B local	Native	Complexe	OSM native	APIPD + RGPD	\$\$

Aucune solution existante ne combine nativement l'adaptation au contexte ivoirien (numéros +225, communes, secteurs locaux), un moteur IA complet (nettoyage, dédoublonnage, enrichissement, classification, scoring), une géolocalisation OpenStreetMap intégrée et une conformité réglementaire locale. Cette conjonction constitue la proposition de valeur unique (USP) de ScrapIQ CI.

1.5.2 Analyse des cinq forces de Porter

Force	Intensité	Analyse
Intensité concurrentielle	Modérée	Peu d'acteurs locaux ; marché émergent ; différenciation forte possible
Pouvoir des fournisseurs (sources)	Élevé	Dépendance à Google Maps, Facebook, LinkedIn ; politiques anti-scraping
Pouvoir des clients	Modéré	Sensibilité au prix ; mais peu d'alternatives locales
Menace de nouveaux entrants	Modérée	Barrière technique (IA + conformité) ; mais marché attractif
Menace de produits de substitution	Faible	Collecte manuelle coûteuse ; annuaires statiques limités

L'analyse révèle une fenêtre d'opportunité favorable : le marché est attractif, peu encombré localement, et les barrières techniques (IA, conformité, infrastructure distribuée) protègent durablement les premiers entrants. La principale vigilance concerne la dépendance aux sources externes, qui impose une architecture résiliente (multi-sources, file de retry, dégradation gracieuse) et une veille permanente des politiques d'accès.

1.5.3 Avantages concurrentiels durables de ScrapIQ CI

- Adaptation native au contexte ivoirien
 - Normalisation des numéros +225, gestion des 10 chiffres
 - Compréhension des communes et quartiers d'Abidjan et grandes villes
 - Classification en 18 secteurs adaptés au tissu économique local
- Pipeline IA complet et spécialisé
 - 10 agents IA orchestrés (sélection, scraping, nettoyage, dédoublonnage, enrichissement, validation, géocodage, classification, scoring, export)

- Reprise sur erreur (retry, checkpoint, circuit breaker)
- Modèle de blackboard partagé entre agents
- Conformité par conception
- Respect de la loi 2013-450 et des recommandations APIPD
- Journal d'audit complet, droit à l'effacement, minimisation des données
- Infrastructure distribuée et scalable
- BullMQ pour les files de jobs, workers horizontalement scalables
- Elasticsearch pour la recherche, Redis pour le cache

1.6. Segmentation et ciblage

La stratégie de ciblage de ScrapIQ CI repose sur une segmentation précise du marché qui permet de prioriser les efforts commerciaux, d'adapter le messaging et de calibrer les offres tarifaires. Trois niveaux de segmentation sont utilisés : démographique (taille d'entreprise), comportementale (intensité d'usage de la data) et verticale (secteur d'activité).

1.6.1 Segmentation démographique

Segment	Description	Taille	Budget data	Priorité
Grands comptes	Banques, telcos, grandes distributions, institutions	< 200	Élevé	P2
ETI	Entreprises de taille intermédiaire (50–250 employés)	≈ 1 500	Élevé	P1
PME	Petites et moyennes entreprises (10–50 employés)	≈ 15 000	Moyen	P1
TPE / indépendants	Très petites entreprises, freelances	≈ 120 000	Faible	P3
Agences & prestataires	Agences marketing, conseils, ESN locales	≈ 800	Élevé	P1
Institutions	Administrations, chambres consulaires, ONG	≈ 300	Moyen	P2

1.6.2 Segmentation comportementale (personas)

Persona 1 — Aïcha, Responsable commercial PME

Aïcha, 34 ans, dirige une équipe de 6 commerciaux dans une PME de distribution de matériel informatique à Abidjan. Elle a besoin de listes de prospects qualifiés par zone et par secteur pour alimenter le pipeline de son équipe. Ses critères : rapidité, fiabilité des numéros de téléphone, export Excel immédiat. Elle utilisera ScrapIQ CI plusieurs fois par semaine.

Persona 2 — Konan, fondateur d'agence marketing

Konan, 41 ans, gère une agence digitale qui produit des campagnes pour des marques locales. Il a besoin de construire des bases de données sectorielles pour le ciblage publicitaire et l'emailing. Il valorise l'enrichissement (emails, sites web), la conformité APIPD et l'API d'intégration avec son stack marketing.

Persona 3 — Dr. Adjoua, chercheuse en économie

Adjoua, 38 ans, chercheuse à l'université, réalise une étude sur la densité commerciale des communes d'Abidjan. Elle a besoin de données agrégées, géolocalisées et historisées. Elle valorise la cartographie, les exports statistiques et la fraîcheur de la donnée.

Persona 4 — Marc, investisseur

Marc, 45 ans, investisseur étudiant l'implantation d'une chaîne de pharmacies. Il analyse la concurrence par commune, les zones de sous-desserte et la dynamique sectorielle. Il valorise les tableaux de bord BI, la heatmap de densité et le scoring de qualité.

1.6.3 Segmentation verticale prioritaires

Priorité	Verticales	Raisonnement	Offre recommandée
P1 — Cœur de cible	Commerce & distribution, Agences marketing, Livraison & logistique	Volume élevé, besoin récurrent, ROI direct mesurable	Pro / Enterprise
P2 — Extension	Institutions, Études & conseil, Investisseurs	Besoins ponctuels mais à forte valeur, image & crédibilité	Pro / Enterprise
P3 — Volume	TPE, indépendants, EdTech	Volume potentiel mais budget limité, sensibilité prix	Starter

1.6.4 Stratégie de Go-to-Market

- Phase de lancement (mois 1–6)
 - Ciblage des agences marketing et ETI/PME d'Abidjan
 - Programme early-adopter avec onboarding accompagné
 - Partenariats avec chambres consulaires et incubateurs
- Phase de croissance (mois 7–18)
 - Expansion vers Bouaké, San-Pédro, Yamoussoukro
 - Activation du canal self-service SaaS (plans Starter/Pro)
 - Campagnes de contenu et SEO local sur « données entreprises Côte d'Ivoire »
- Phase de scale (mois 19–36)
 - Élargissement vertical (banque, assurance, logistique)
 - Ouverture de l'API publique et marketplace d'intégrations
 - Préparation de l'expansion régionale UEMOA (Sénégal, Mali, Burkina)

Synthèse du chapitre

ScrapIQ CI s'attaque à une problématique réelle, forte et chiffrée sur un marché ivoirien en digitalisation rapide, largement sous-servi par les solutions existantes. La combinaison « adaptation locale + IA + géolocalisation + conformité » constitue une proposition de valeur différenciante et défendable, qui justifie l'investissement de développement détaillé dans les chapitres suivants.

1.7. 1.7 Analyse PESTEL du marché ivoirien

L'analyse PESTEL permet d'évaluer les facteurs externes qui influencent le marché de la données d'entreprises en Côte d'Ivoire. Cette analyse est essentielle pour comprendre les opportunités et les risques associés au lancement de ScrapIQ CI.

Facteur	Analyse	Impact sur ScrapIQ CI
Politique	Stabilité gouvernementale, volonté de digitalisation, Plan National de Développement (PND 2021-2025)	Favorable — soutien gouvernemental à la digitalisation
Économique	Croissance PIB +7%, classe moyenne en expansion, FCFA stable	Favorable — pouvoir d'achat croissant pour B2B SaaS
Social	Taux de pénétration mobile > 90%, adoption digitale rapide chez les jeunes	Très favorable — marché mobile-first idéal
Technologique	Fibre optique en expansion, 4G généralisée, 5G annoncée	Favorable — infrastructure suffisante
Environnemental	Transition verte, RSE des entreprises	Neutre — impact indirect
Légal	Loi n°2013-450 (protection données), APIPD active	Contrainte — conformité obligatoire mais différenciateur

1.7.1 1.7.1 Analyse des 5 forces de Porter

Force	Niveau	Analyse
Intensité concurrentielle	Modéré	Peu de concurrents directs (aucun SaaS B2B de scraping CI). Concurrents indirects: annuaires en ligne, cabinets de prospection
Pouvoir des fournisseurs	Faible	Sources de données publiques (Google Maps, Facebook), pas de dépendance exclusive
Pouvoir des clients	Modéré	PME sensibles au prix, mais peu d'alternatives. Grandes entreprises prêtes à payer pour la qualité
Menace nouveaux entrants	Modéré	Barrière technique (scraping, IA, infrastructure). Barrière réglementaire (APIPD)
Menace produits de substitution	Faible	Pas d'alternative automatisée. Manuelle = coûteux et lent

1.7.2 1.7.2 Matrice SWOT

Forces : Première plateforme SaaS de scraping CI, IA native (dédup, enrichissement, scoring), multi-sources (Google Maps, FB, LinkedIn, Web), conformité APIPD native, pricing FCFA adapté au marché local, PWA offline pour zones à connectivité faible.

Faiblesses : Startup sans notoriété établie, équipe technique limitée initialement, dépendance aux sources externes (Google, Facebook), risque de blocage anti-scraping, pas de données historiques.

Opportunités : Marché ivoirien en forte digitalisation, expansion régionale (CEDEAO, 15 pays), partenariats télécoms (Orange, MTN), programmes gouvernementaux de digitalisation, demande croissante de données B2B, marché Mobile Money pour facturation.

Menaces : Durcissement anti-scraping (Google, Facebook), évolution réglementaire (RGPD africain), concurrence internationale (Apollo, Lusha), instabilité économique régionale, risque de coupure réseau (infrastructure CI).

CHAPITRE 2

Objectifs du projet

Ce chapitre formalise les objectifs du projet ScrapIQ CI sur quatre dimensions complémentaires : fonctionnelle, technique, business et qualité. Il définit ensuite les indicateurs de performance (KPIs) qui permettront de mesurer l'atteinte de ces objectifs ainsi que les critères de succès qui encadrent la validation du projet. Ces objectifs servent de référence tout au long du cycle de vie du projet, de la conception à la mise en production, et orientent les arbitrages techniques et fonctionnels.

2.1. Objectifs fonctionnels

Les objectifs fonctionnels décrivent ce que la plateforme doit permettre de réaliser du point de vue métier. Ils sont exprimés en termes de capacités offerte aux utilisateurs et traduisent directement les besoins identifiés lors de l'étude de marché (chapitre 1).

Code	Objectif fonctionnel	Description	Module
OF-01	Scraping multi-sources	Collecter des données business depuis Google Maps, Facebook, LinkedIn, sites web et le RCCM en une seule requête	Scraping
OF-02	Nettoyage IA	Normaliser automatiquement numéros (+225), emails, noms d'entreprises et adresses	IA Cleaner
OF-03	Dédoublonnage intelligent	Détecter et fusionner les fiches dupliquées avec scoring de confiance	IA Cleaner
OF-04	Enrichissement	Compléter description, site web, horaires, réseaux sociaux pour chaque entreprise	IA Cleaner
OF-05	Classification sectorielle	Classer chaque entreprise dans l'un des 18 secteurs économiques ivoiriens	IA Cleaner
OF-06	Scoring de qualité	Calculer un score 0–100 sur 7 dimensions et une catégorie A/B/C/D	IA Cleaner
OF-07	Géolocalisation	Géocoder les adresses et afficher les entreprises sur OpenStreetMap	Cartographie
OF-08	Recherche multi-critères	Rechercher par secteur, ville, commune, mot-clé, score, rayon géographique	Recherche
OF-09	Exports multi-formats	Exporter en Excel, CSV, PDF, JSON avec sélection de champs	Exports
OF-10	Notifications	Notifier l'utilisateur par email, in-app, webhook et push sur les événements clés	Notifications
OF-11	API REST publique	Exposer une API versionnée, documentée (Swagger), authentifiée par clé API/JWT	API REST
OF-12	Authentification sécurisée	JWT, OAuth Google/Microsoft, 2FA TOTP, gestion de sessions	Auth
OF-13	RBAC multi-tenant	Gérer organisations, workspaces, et 5 rôles (Owner, Admin, Manager, Agent, Viewer)	RBAC
OF-14	PWA mobile	Offrir une expérience installable, hors-ligne, responsive sur mobile	PWA

Code	Objectif fonctionnel	Description	Module
OF-15	Business Intelligence	Fournir tableaux de bord, heatmaps, rapports planifiés	BI
OF-16	Plateforme SaaS	Proposer abonnements, quotas, facturation, licences, marketplace	SaaS
OF-17	Agents IA multi-agents	Orchestrer 10 agents spécialisés avec monitoring temps réel	Agents IA
OF-18	Sécurité globale	WAF, anti-DDoS, captcha, chiffrement, audit, rate limiting	Sécurité

2.2. Objectifs techniques

Les objectifs techniques encadrent les choix d'architecture, de performance, de fiabilité et de maintenabilité. Ils garantissent que la plateforme soit industrialisable, scalable et capable de supporter la montée en charge prévue par la roadmap.

Code	Objectif technique	Cible / Métrique
OT-01	Stack moderne et maintenable	Next.js 16, TypeScript 5, Tailwind 4, shadcn/ui
OT-02	Temps de réponse API (P95)	< 300 ms pour les endpoints de recherche
OT-03	Temps de scraping moyen	< 90 s pour 100 entreprises multi-sources
OT-04	Disponibilité (uptime)	≥ 99,5 % en production
OT-05	Scalabilité horizontale	Workers BullMQ et API scalable à 10x sans refonte
OT-06	Capacité de la base	≥ 5 millions d'entreprises indexées sans dégradation
OT-07	Recherche full-text	Latence < 150 ms sur Elasticsearch, recherche fuzzy + facets
OT-08	Conformité OWASP Top 10	0 vulnérabilité critique en production
OT-09	Couverture de tests	≥ 75 % sur la logique métier critique
OT-10	CI/CD automatisé	Pipeline build + test + déploiement < 15 min
OT-11	Observabilité	Logs centralisés, métriques, tracing sur 100 % des services
OT-12	Architecture distribuée	Mini-services indépendants + file BullMQ + Redis
OT-13	Multi-tenant isolé	Isolation des données par organisation au niveau DB
OT-14	PWA installable	Lighthouse PWA ≥ 90, support hors-ligne

Code	Objectif technique	Cible / Métrique
OT-1 5	Internationalisation	i18n FR par défaut, extensible EN

2.2.1 Principes directeurs de l'architecture

- Séparation des responsabilités
 - ▬ Frontend / API / Workers / IA clairement découplés
- API-first
 - ▬ Toute fonctionnalité exposée via API REST versionnée avant l'UI
- Résilience par défaut
 - ▬ Retry, circuit breaker, dégradation gracieuse, idempotence
- Observabilité native
 - ▬ Logging structuré, métriques, tracing dès la conception
- Sécurité par conception
 - ▬ RBAC, chiffrement, audit, conformité intégrés
- Évolutivité
 - ▬ Modularité permettant d'ajouter sources, agents et modules sans refonte

2.3. Objectifs business

Les objectifs business mesurent le succès commercial de ScrapIQ CI. Ils couvrent l'acquisition, la rétention, la récurrence des revenus et la rentabilité, sur un horizon de 36 mois.

Horizon	Objectif business	Cible
6 mois	Comptes actifs payants	150 comptes
6 mois	MRR (Monthly Recurring Revenue)	≥ 9 M FCFA
6 mois	Taux de conversion essai → payant	≥ 18 %
12 mois	Comptes actifs payants	650 comptes
12 mois	MRR	≥ 45 M FCFA
12 mois	Net Revenue Retention	≥ 110 %
18 mois	Comptes actifs payants	1 800 comptes
18 mois	MRR	≥ 135 M FCFA
18 mois	Marges brutes	≥ 70 %
24 mois	Comptes actifs payants	4 500 comptes
24 mois	MRR	≥ 360 M FCFA
24 mois	Break-even opérationnel	Atteint
36 mois	Comptes actifs payants	12 000 comptes
36 mois	ARR	≥ 6 Mds FCFA
36 mois	Expansion régionale	Présence dans 3 pays UEMOA

2.3.1 Objectifs de positionnement et de marque

- Devenir la référence du « data business en Côte d'Ivoire » d'ici 24 mois
- Être reconnu par l'APIPD comme une solution conforme et exemplaire
- Construire une communauté d'utilisateurs et de développeurs (API publique)
- Établir des partenariats avec au moins 5 acteurs institutionnels majeurs

2.4. Indicateurs de performance (KPIs)

Les KPIs permettent de suivre en continu l'atteinte des objectifs. Ils sont organisés en cinq familles : acquisition, engagement produit, qualité de la donnée, performance technique et financier. Chaque KPI possède une cible, une fréquence de mesure et un responsable.

2.4.1 KPIs d'acquisition et de croissance

KPI	Définition	Cible annuelle	Fréquence
Nouveaux comptes	Comptes créés (tous plans)	≥ 5 000	Hebdo
MRR	Revenu récurrent mensuel	+15 %/mois	Mensuel
ARR	Revenu récurrent annuel	Croissance 3x	Trimestriel
CAC	Coût d'acquisition client	< 45 000 FCFA	Mensuel
LTV	Vie utile client (revenu)	≥ 270 000 FCFA	Trimestriel
LTV/CAC	Ratio de rentabilité acquisition	≥ 6	Trimestriel
Taux de churn	Annulations / total	< 3 %/mois	Mensuel

2.4.2 KPIs d'engagement produit

KPI	Définition	Cible	Fréquence
DAU/MAU	Ratio d'utilisation quotidienne	≥ 25 %	Hebdo
Jobs de scraping / compte	Nombre moyen par mois	≥ 12	Mensuel
Exports générés / compte	Nombre moyen par mois	≥ 8	Mensuel
Requêtes API / compte	Consommation API moyenne	≥ 500	Mensuel
Adoption 2FA	Comptes avec 2FA activé	≥ 35 %	Mensuel
NPS	Net Promoter Score	≥ 40	Trimestriel

2.4.3 KPIs de qualité de la donnée

KPI	Définition	Cible	Fréquence
Taux de remplissage	Champs non vides / champs attendus	≥ 85 %	Hebdo
Taux de doublons résiduels	Doublons après traitement IA	< 2 %	Hebdo
Taux de géocodage	Adresses géocodées avec succès	≥ 92 %	Hebdo

KPI	Définition	Cible	Fréquence
Taux de numéros valides	Numéros +225 au format valide	≥ 95 %	Hebdo
Score qualité moyen	Moyenne des scores 0–100	≥ 72	Mensuel
Fraîcheur moyenne	Ancienneté moyenne des données	< 90 jours	Mensuel

2.4.4 KPIs de performance technique

KPI	Définition	Cible	Fréquence
Uptime	Disponibilité mensuelle	≥ 99,5 %	Mensuel
Latence API P95	95e percentile temps de réponse	< 300 ms	Quotidien
Taux d'erreur API	Réponses 5xx / total	< 0,5 %	Quotidien
Taux de succès scraping	Jobs terminés sans erreur	≥ 96 %	Quotidien
MTTR	Temps moyen de résolution incident	< 2 h	Par incident
Couverture tests	Couverture code métier	≥ 75 %	Par release

2.5. Critères de succès

Les critères de succès définissent les conditions objectives d'acceptation du projet à ses principales étapes. Ils sont validés par le comité de pilotage et conditionnent le passage d'une phase à la suivante (voir chapitre 14 — Planning).

Jalon	Critère de succès	Validation
MVP prêt	Scraping Google Maps + nettoyage + export Excel + auth + 1 rôle	Démo + tests
Bêta privée	50 utilisateurs pilotes, NPS ≥ 30, uptime ≥ 99 %	Retours utilisateurs
Lancement commercial	Plan SaaS opérationnel, paiements Mobile Money, 100 comptes payants	Revenus
V1 stabilisée	Multi-sources (4), API publique, BI, 650 comptes	KPIs atteints
V2 — Scale	Agents IA, marketplace d'intégrations, 1 800 comptes	KPIs atteints
V3 — Expansion	Présence dans 2 pays UEMOA supplémentaires	Revenus internationaux

2.5.1 Facteurs clés de succès (CSF)

- Excellence technique
 - Pipeline IA robuste, architecture scalable, sécurité de bout en bout
- Qualité de la donnée
 - La valeur perçue dépend directement de la fiabilité des données restituées
- Conformité réglementaire
 - Confiance des institutions et entreprises, différenciateur majeur
- Expérience utilisateur
 - Simplicité de prise en main, instantanéité des résultats
- Réactivité opérationnelle

- Support réactif, gestion des incidents, mise à jour des sources
- Go-to-market ciblé
- Focus initial sur les segments à fort ROI et récurrents

2.5.2 Risques principaux et mitigation

Risque	Probabilité	Impact	Mitigation
Blocage IP / anti-scraping des sources	Élevée	Élevé	Rotation de proxies, respect robots.txt, multi-sources
Évolution défavorable réglementaire	Faible	Élevé	Veille APIPD, conformité par conception
Dégradation qualité des sources	Moyenne	Moyen	Validation IA, scoring, sources multiples
Adoption lente du marché	Moyenne	Élevé	Éducation, freemium, partenariats
Fuite de données / incident sécurité	Faible	Très élevé	Chiffrement, audit, WAF, tests sécurité
Dépendance fournisseur cloud	Moyenne	Moyen	Architecture portable, multi-cloud possible

Synthèse du chapitre

Les objectifs de ScrapIQ CI sont précis, mesurables et hiérarchisés. Ils couvrent les dimensions fonctionnelle, technique, business et qualité, et sont suivis par une trentaine de KPIs. Les critères de succès jalonnent le projet et permettent de valider chaque phase. Le tableau de bord BI (chapitre 3.11) assure le suivi temps réel de ces indicateurs.

2.6. 2.6 Matrice des objectifs par stakeholder

Stakeholder	Objectifs principaux	KPIs associés
Product Owner	Produit utilisable et utile	NPS > 50, DAU/MAU > 40%
Développeurs	Code maintenable, scalable	Couverture tests > 80%, dette technique < 10%
Utilisateurs (Agent)	Trouver entreprises rapidement	Temps de recherche < 30s, précision > 90%
Utilisateurs (Manager)	Vue d'équipe, exports	Temps export < 5s, qualité données > 85%
Utilisateurs (Owner)	ROI, facturation, contrôle	MRR growth > 10%/mois, churn < 5%
Investisseurs	Croissance et rentabilité	ARR, CAC < 50k FCFA, LTV/CAC > 3
Régulateur (APIPD)	Conformité protection données	0 violation, audit conforme

CHAPITRE 3

Fonctionnalités détaillées

Ce chapitre décrit exhaustivement l'ensemble des fonctionnalités de la plateforme ScrapIQ CI, organisées par module. Chaque module est présenté avec ses capacités, ses règles de gestion, ses paramètres et ses interactions avec les autres modules. Cette description constitue la spécification fonctionnelle de référence pour les équipes de développement et de test. Les modules couvrent l'ensemble du périmètre produit : scraping multi-sources, IA cleaner, recherche, cartographie, exports, notifications, API REST, authentification, RBAC, PWA, Business Intelligence, SaaS Enterprise, agents IA multi-agents et sécurité globale.

3.1. Scraping multi-sources

Le module de scraping multi-sources est le moteur de collecte de la plateforme. Il permet, à partir d'une requête unique (mot-clé + localisation), de collecter en parallèle des données business depuis quatre sources principales : Google Maps, Facebook, LinkedIn et les sites web génériques. Le RCCM est également intégré comme source complémentaire pour l'enrichissement juridique.

3.1.1 Sources supportées

Source	Type de données	Volume typique	Fiabilité	Fréquence MAJ
Google Maps	Nom, adresse, tél, GPS, note, avis, horaires	Élevé	Élevée	Temps réel
Facebook	Page, description, tél, email, horaires, posts	Élevé	Moyenne	Quotidien
LinkedIn	Entreprise, secteur, effectif, site web, dirigeants	Moyen	Élevée	Hebdo
Sites web	Coordonnées, services, produits, emails	Variable	Variable	Variable
RCCM	Forme juridique, capital, dirigeants, immatriculation	Faible volume	Très élevée	Annuel

3.1.2 Déroulement d'un job de scraping

Lorsqu'un utilisateur lance un job de scraping, la plateforme construit des requêtes adaptées à chaque source (par exemple « quincaillerie Yopougon » pour Google Maps, « quincaillerie Yopougon Abidjan » pour Facebook). Chaque source est interrogée par un scraper Playwright dédié qui simule un navigateur headless, gère les popups, scrolls et CAPTCHAs simples, et extrait les données structurées. Les résultats bruts sont normalisés dans un format intermédiaire commun puis transmis au pipeline IA pour nettoyage et enrichissement.


```
// Exemple : lancement d'un job de scraping multi-sources
POST /api/v1/scraping/jobs
Authorization: Bearer <jwt>
Content-Type: application/json

{
  "query": "quincaillerie",
  "city": "Abidjan",
  "commune": "Yopougon",
  "sources": ["google_maps", "facebook", "website"],
  "maxResults": 200,
  "enrich": true,
  "dedupe": true
}

// Réponse 201 Created
{
  "jobId": "job_a1b2c3d4",
  "status": "queued",
  "estimatedDuration": 75,
  "webhookUrl": "/api/v1/notifications/stream/job_a1b2c3d4"
}
```

Figure 3.1 — Lancement d'un job de scraping multi-sources

3.1.3 Scraper Google Maps

Le scraper Google Maps utilise Playwright pour naviguer sur maps.google.com, saisir la requête, scroller la liste de résultats, et extraire pour chaque établissement : nom, note, nombre d'avis, adresse, numéro de téléphone, site web, horaires d'ouverture, catégorie, coordonnées GPS et lien vers la fiche détaillée. Il gère la pagination infinie et les fenêtres de détail. Un mécanisme de rate-limiting et de rotation d'IP limite le risque de blocage.

3.1.4 Scraper Facebook

Le scraper Facebook interroge la recherche de pages business, extrait la description, les coordonnées (téléphone, email, site), les horaires, le nombre d'abonnés, et les derniers posts. Il prend en compte la pagination des résultats et la fermeture des popups de connexion. Les données Facebook sont particulièrement utiles pour les commerces de proximité qui n'ont pas de site web.

3.1.5 Scraper LinkedIn

Le scraper LinkedIn cible les pages d'entreprises (Company Pages) pour extraire le secteur d'activité, l'effectif, le siège, le site web, la description et les dirigeants. L'accès à LinkedIn requiert une authentification et un usage raisonné ; la plateforme applique un quota strict et des délais aléatoires entre requêtes pour respecter les conditions d'utilisation.

3.1.6 Scraper de sites web génériques

Le scraper de sites web génériques prend en entrée une liste d'URLs (issues des autres sources ou saisies par l'utilisateur) et extrait automatiquement les coordonnées : emails (regex + validation), téléphones (+225), adresses, horaires, et une description du contenu. Il utilise des heuristiques basées sur la structure HTML et des sélecteurs communs (footer, page contact).

3.1.7 Règles de gestion et garde-fous

- Respect du fichier robots.txt de chaque source (paramétrable par source)
- Rate limiting par source (délai minimal entre requêtes, configurable)
- Rotation de proxies et user-agents pour limiter les blocages
- Détection de CAPTCHA avec mise en file d'attente manuelle en option

- Timeout par page (30 s) et par job (15 min)
- Reprise sur erreur : 3 retry avec backoff exponentiel
- Limitation du nombre de résultats par source (configurable, défaut 200)
- Journalisation de chaque requête sortante pour audit

3.1.8 Paramètres configurables d'un job

Paramètre	Type	Défaut	Description
query	string	—	Mot-clé de recherche (ex. quincaillerie)
city	string	—	Ville (ex. Abidjan)
commune	string?	null	Commune optionnelle (ex. Yopougon)
sources	string[]	toutes	Sources à interroger
maxResults	int	200	Nombre maximal de résultats par source
enrich	bool	true	Activer l'enrichissement IA
dedupe	bool	true	Activer le dédoublonnage
geocode	bool	true	Activer le géocodage des adresses
language	string	fr	Langue des requêtes
schedule	cron?	null	Planification récurrente optionnelle

3.2. IA cleaner (nettoyage, dédoublonnage, enrichissement)

L'IA cleaner est le cœur différenciant de ScrapIQ CI. Il transforme les données brutes, hétérogènes et imparfaites issues du scraping en un jeu de données propre, enrichi, dédoublonné, classifié et scoré. Ce module est implémenté sous forme d'un pipeline de 10 agents IA orchestrés (détaillé au chapitre 3.13), mais ses fonctionnalités sont décrites ici du point de vue utilisateur et métier.

3.2.1 Nettoyage et normalisation

Champ	Transformation	Exemple
Téléphone	Formatage +225, 10 chiffres, espacement	07 00 11 22 33 → +225 07 00 11 22 33
Email	Minuscules, trim, validation regex + MX	Contact@Boutique.CI → contact@boutique.ci
Nom entreprise	Retrait des formes juridiques, title case	SARL BOUTIQUE DU CENTRE → Boutique du Centre
Adresse	Normalisation des abréviations, communes	Rte de Dabou, Yopougon → Route de Dabou, Yopougon
Site web	Préfixe https, rejet des invalides	boutique.ci → https://boutique.ci
Horaires	Format 24h standardisé	9h-18h → 09:00-18:00
GPS	Conversion degrés décimaux, précision 5	5.34, -4.024 → 5.34000, -4.02400

3.2.2 Dédoublonnage intelligent

Le dédoublonnage identifie les fiches représentant la même entreprise réelle à partir de sources différentes. Il s'appuie sur un score de similarité combinant plusieurs signaux : similarité du nom (Levenshtein +

token-based), proximité géographique (distance GPS < 100 m), matching de téléphone normalisé, et matching d'email. Au-dessus d'un seuil de confiance (configurable, défaut 0,82), les fiches sont fusionnées en conservant la meilleure valeur de chaque champ (la plus complète ou la plus récente).

```
// Algorithme de fusion (pseudo-code)
function shouldMerge(a, b):
    score = 0
    if phoneMatch(a.phone, b.phone): score += 0.45
    if emailMatch(a.email, b.email): score += 0.35
    nameSim = tokenSimilarity(a.name, b.name)
    score += nameSim * 0.30
    if geoDistance(a.gps, b.gps) < 100: score += 0.20
    return score >= MERGE_THRESHOLD // 0.82 par défaut

function merge(a, b):
    merged = {}
    for field in FIELDS:
        merged[field] = bestOf(a[field], b[field]) // plus complet / plus récent
    merged.fusionScore = confidence
    merged.sources = union(a.sources, b.sources)
    return merged
```

Figure 3.2 — Logique de dédoublement et de fusion

3.2.3 Enrichissement

L'enrichissement complète chaque fiche avec des informations absentes des sources brutes : description générée ou complétée via LLM, horaires d'ouverture, site web, réseaux sociaux, gamme de produits/services, et indications de notoriété (note, avis). L'enrichissement s'appuie sur des règles métier (par exemple déduire le secteur du nom) et sur des appels LLM pour les champs textuels. Il est exécuté en parallèle du pipeline de validation pour optimiser le temps total.

3.2.4 Validation

La validation vérifie la cohérence de chaque champ : validité syntaxique des emails (regex RFC), existence du domaine (résolution MX), validité des numéros +225 (longueur, opérateur), accessibilité des sites web (HTTP HEAD), et détection des établissements fermés (mentions « fermé », « définitivement fermé » dans les avis). Chaque champ reçoit un statut : valid, invalid, suspect, unknown.

3.2.5 Classification sectorielle

Chaque entreprise est classée dans l'un des 18 secteurs économiques ivoiriens prédéfinis. La classification est hybride : un moteur de règles basé sur les mots-clés du nom et de la description propose un secteur, et un LLM valide ou corrige la proposition en s'appuyant sur le contexte. Les 18 secteurs sont : Commerce de détail, Commerce de gros, Restauration, Hôtellerie, Santé, Éducation, BTP & construction, Transport & logistique, Services financiers, Télécom & tech, Industrie manufacturière, Agriculture, Artisanat, Beauté & bien-être, Loisirs & tourisme, Immobilier, Services professionnels, Autres.

3.2.6 Scoring de qualité

Le scoring attribue à chaque entreprise une note de 0 à 100 calculée comme une moyenne pondérée de 7 dimensions : complétude des champs (poids 25 %), validité des coordonnées (20 %), fraîcheur de la donnée (15 %), richesse de l'enrichissement (15 %), fiabilité des sources (10 %), cohérence interne (10 %), et présence en ligne (5 %). Le score est traduit en une catégorie A (≥ 80), B (65–79), C (50–64) ou D (< 50) qui guide la priorisation des actions commerciales.

Dimension	Poids	Description
Complétude des champs	25 %	Proportion de champs renseignés parmi les attendus

Dimension	Poids	Description
Validité des coordonnées	20 %	Tél et email validés techniquement
Fraîcheur de la donnée	15 %	Ancienneté depuis la dernière mise à jour
Richesse de l'enrichissement	15 %	Présence de description, horaires, site
Fiabilité des sources	10 %	Nombre et qualité des sources convergentes
Cohérence interne	10 %	Concordance nom/secteur/adresse
Présence en ligne	5 %	Site web actif et réseaux sociaux

3.3. Moteur de recherche Elasticsearch

Le moteur de recherche est bâti sur Elasticsearch et indexe l'ensemble des entreprises collectées et nettoyées. Il offre une recherche full-text rapide (< 150 ms), tolérante aux fautes (fuzzy matching), multi-critères et facetée. C'est le composant central de l'expérience utilisateur de découverte des données.

3.3.1 Capacités de recherche

- Recherche full-text sur nom, description, secteur, adresse, mots-clés
- Fuzzy matching (tolérance aux fautes de frappe, distance d'édition ≤ 2)
- Filtres : secteur, ville, commune, score, catégorie A/B/C/D, source, fraîcheur
- Recherche géographique : rayon autour d'un point, dans un polygone (commune)
- Tri : pertinence, score qualité, nom, date de mise à jour, distance
- Facettes agrégées : compte par secteur, par commune, par catégorie
- Suggestion automatique (autocomplete) sur les noms et secteurs
- Mise en surbrillance (highlight) des termes recherchés dans les résultats

3.3.2 Structure d'index Elasticsearch

```
// Mapping de l'index 'companies' (extrait)
{
  "mappings": {
    "properties": {
      "name": { "type": "text", "analyzer": "french" },
      "name_keyword": { "type": "keyword" },
      "description": { "type": "text", "analyzer": "french" },
      "sector": { "type": "keyword" },
      "sectorCode": { "type": "keyword" },
      "city": { "type": "keyword" },
      "commune": { "type": "keyword" },
      "phone": { "type": "keyword" },
      "email": { "type": "keyword" },
      "website": { "type": "keyword" },
      "score": { "type": "integer" },
      "grade": { "type": "keyword" },
      "location": { "type": "geo_point" },
      "sources": { "type": "keyword" },
      "updatedAt": { "type": "date" },
      "keywords": { "type": "text", "analyzer": "french" }
    }
  }
}
```

Figure 3.3 — Mapping Elasticsearch de l'index companies

3.3.3 Exemple de requête de recherche

```
// Recherche : pharmacies à Abidjan, score ≥ 65, tri par pertinence
GET /api/v1/companies/search
?q=pharmacie&city=Abidjan&minScore=65&sort=relevance&page=1&size=20

// DSL Elasticsearch correspondant
{
  "query": {
    "bool": {
      "must": [
        { "match": { "name": { "query": "pharmacie", "fuzziness": "AUTO" } } }
      ],
      "filter": [
        { "term": { "city": "Abidjan" } },
        { "range": { "score": { "gte": 65 } } }
      ]
    }
  },
  "sort": [ "_score", { "score": "desc" } ],
  "from": 0, "size": 20,
  "aggs": {
    "by_sector": { "terms": { "field": "sector" } },
    "by_commune": { "terms": { "field": "commune" } },
    "by_grade": { "terms": { "field": "grade" } }
  }
}
```

Figure 3.4 — Recherche multi-critères avec agrégations

3.4. Cartographie OpenStreetMap

La cartographie est un différenciateur fort de ScrapIQ CI. Elle s'appuie sur OpenStreetMap (OSM), solution libre et gratuite, pour afficher les entreprises géolocalisées, calculer des densités, dessiner des rayons et des zones, et produire des heatmaps. Le rendu utilise Leaflet côté frontend avec des tuiles OSM.

3.4.1 Fonctionnalités cartographiques

Fonctionnalité	Description	Cas d'usage
Affichage des marqueurs	Points colorés par catégorie A/B/C/D	Vue d'ensemble d'un secteur
Heatmap de densité	Intensité de couleur selon la concentration	Identifier les zones saturées / sous-desservies
Recherche par rayon	Cercle de rayon configurable autour d'un point	Prospection de proximité
Filtres géographiques	Sélection par commune (polygone)	Ciblage d'un quartier
Clustering	Regroupement des marqueurs proches au zoom arrière	Performance d'affichage à grande échelle
Détail au clic	Popup avec fiche entreprise résumée	Consultation rapide
Export visuel	Capture PNG de la carte avec légende	Inclusion dans un rapport
Itinéraire	Calcul de trajet entre points (OSRM)	Planification de tournées commerciales

3.4.2 Géocodage des adresses

Le géocodage transforme les adresses textuelles (souvent imprécises en Côte d'Ivoire) en coordonnées GPS exploitables. Il utilise le service Nominatim d'OSM avec une étape de pré-normalisation des adresses (commune, quartier, point de repère connu). Pour les adresses introuvables, un fallback utilise le centroïde

de la commune. Le taux de géocodage réussi cible est $\geq 92\%$.

3.5. Exports multi-formats

Le module d'exports permet à l'utilisateur de récupérer les données collectées et traitées dans le format le mieux adapté à son usage. Quatre formats natifs sont supportés : Excel (XLSX), CSV, PDF et JSON. L'utilisateur sélectionne les champs à exporter, applique d'éventuels filtres, et déclenche la génération asynchrone du fichier, notifié à la fin.

3.5.1 Formats et caractéristiques

Format	Usage privilégié	Particularités	Limite (plan Pro)
XLSX	Travail opérationnel (commerciaux)	En-têtes, filtres, onglets multiples, mise en forme	50 000 lignes
CSV	Import CRM / outils tiers	UTF-8, séparateur ; configurable	100 000 lignes
PDF	Rapports, présentations	Mise en page tableur + carte + légende	5 000 lignes
JSON	Intégration API / pipeline data	Structure hiérarchique complète	100 000 enregistrements

3.5.2 Sélection de champs à l'export

L'utilisateur choisit précisément les champs à inclure dans l'export parmi : nom, secteur, ville, commune, adresse, téléphone, email, site web, horaires, GPS (latitude, longitude), note, nombre d'avis, score, catégorie, sources, date de dernière mise à jour, description, mots-clés. Des modèles d'export réutilisables peuvent être sauvegardés par l'utilisateur.

3.5.3 Génération asynchrone et notifications

Les exports volumineux sont générés en arrière-plan par un worker dédié afin de ne pas bloquer l'interface. La progression est visible en temps réel, et une notification (in-app + email) est émise à l'achèvement. Les fichiers générés sont stockés temporairement (30 jours par défaut, configurable par plan) et téléchargeables depuis l'onglet Exports.

3.6. Notifications multi-canal

Le module de notifications informe les utilisateurs des événements clés de la plateforme via plusieurs canaux : in-app (cloche de notifications temps réel via WebSocket), email, push navigateur (PWA) et webhooks (pour intégration machine-to-machine). Chaque utilisateur configure ses préférences par type d'événement et par canal.

3.6.1 Types d'événements notifiables

Événement	Description	Canaux par défaut
job.completed	Un job de scraping s'est terminé avec succès	in-app, email
job.failed	Un job a échoué	in-app, email
export.ready	Un export est prêt au téléchargement	in-app, email
alert.triggered	Une règle d'alerte a détecté un changement	in-app, email, push
report.scheduled	Un rapport planifié a été généré	in-app, email

Événement	Description	Canaux par défaut
quota.threshold	Approche de la limite de quota (80 %, 95 %)	in-app, email
security.login	Connexion depuis un nouvel appareil / IP	in-app, email
security.2fa	Activation/désactivation de la 2FA	in-app, email
billing.invoice	Nouvelle facture émise	in-app, email
agent.completed	Le pipeline d'agents IA est terminé	in-app

3.6.2 Règles d'alerte personnalisées

Au-delà des notifications système, l'utilisateur peut définir des règles d'alerte personnalisées : surveillance d'un secteur ou d'une zone géographique, détection de nouveaux concurrents, fermeture d'un établissement, franchissement d'un seuil de densité. Chaque règle est évaluée périodiquement et déclenche une notification lorsque la condition est remplie.

3.6.3 Webhooks

Les webhooks permettent d'automatiser des actions externes (ajout dans un CRM, déclenchement d'une campagne, mise à jour d'un tableur) en temps réel. Chaque webhook possède une URL, un secret partagé (signature HMAC), une liste d'événements écoutés, et un statut actif/inactif. Les livraisons sont journalisées avec tentative de retry (5 essais avec backoff exponentiel).

3.7. API REST publique

L'API REST publique expose l'ensemble des capacités de la plateforme à des intégrations tierces (CRM, ERP, outils marketing, data warehouses). Elle est versionnée (/api/v1/), documentée via Swagger/OpenAPI 3.0, authentifiée par clé API ou JWT, et soumise à un rate limiting par plan. Le détail exhaustif des endpoints fait l'objet du chapitre 9.

3.7.1 Caractéristiques de l'API

- Versionnage explicite via préfixe /api/v1/
- Authentification : Bearer JWT (utilisateur) ou X-API-Key (application)
- Pagination cursor-based pour les grandes collections
- Filtrage, tri et sélection de champs via paramètres de requête
- Réponses JSON standardisées avec enveloppe { data, meta, error }
- Codes de statut HTTP conformes aux conventions REST
- Rate limiting par clé / par IP avec en-têtes X-RateLimit-*
- Idempotence via en-tête Idempotency-Key pour les POST/PUT
- Webhooks sortants pour les événements asynchrones
- Documentation Swagger interactive (try-it) intégrée à l'UI

3.7.2 Exemple de réponse standardisée

```
// GET /api/v1/companies/cix123
{
  "data": {
    "id": "cix123",
    "name": "Boutique du Centre",
    "sector": "Commerce de détail",
    "sectorCode": "RETAIL",
    "city": "Abidjan",
    "commune": "Cocody",
    "phone": "+225 07 00 11 22 33",
    "email": "contact@boutiqueduceentre.ci",
    "website": "https://boutiqueduceentre.ci",
    "location": { "lat": 5.3364, "lng": -4.0260 },
    "score": 84,
    "grade": "A",
    "sources": ["google_maps", "facebook"],
    "updatedAt": "2024-07-15T10:23:00Z"
  },
  "meta": { "requestId": "req_abc", "version": "v1" }
}
```

Figure 3.5 — Réponse API standardisée

3.8. Authentification et sécurité

L'authentification est un pilier de la plateforme. Elle combine plusieurs mécanismes pour assurer à la fois la sécurité et la flexibilité : mot de passe renforcé (bcrypt + politique de complexité), JWT pour les sessions stateless, OAuth 2.0 (Google, Microsoft) pour le SSO, 2FA TOTP pour la double authentification, gestion fine des sessions et révocation, et blacklist des tokens compromis. Le détail sécurité est traité au chapitre 11.

3.8.1 Méthodes d'authentification

Méthode	Usage	Sécurité	Notes
Email + mot de passe	Comptes standards	Moyenne	bcrypt cost 12, politique forte
OAuth Google	SSO entreprise	Élevée	OAuth 2.0, scopes email/profile
OAuth Microsoft	SSO entreprise	Élevée	Azure AD / comptes perso
2FA TOTP	Renforcement comptes sensibles	Très élevée	App Authenticator, codes de secours
Clé API	Intégrations machine-to-machine	Élevée	Hashée, rotation, scopes par clé

3.8.2 Gestion des sessions

Les sessions sont stateless côté serveur grâce aux JWT (access token courte durée 15 min + refresh token longue durée 30 jours). Les refresh tokens sont stockés en base et révocables individuellement. La déconnexion invalide le refresh token et ajoute l'access token à une blacklist jusqu'à expiration. Les sessions actives sont visibles dans le profil utilisateur et révocables à distance.

3.9. RBAC et gestion des rôles

Le contrôle d'accès basé sur les rôles (RBAC) est multi-tenant : chaque utilisateur appartient à une organisation et, optionnellement, à un ou plusieurs workspaces au sein de cette organisation. Au sein de chaque workspace, l'utilisateur se voit attribuer un rôle qui détermine ses permissions. Cinq rôles sont définis : Owner, Admin, Manager, Agent et Viewer.

3.9.1 Les cinq rôles

Rôle	Périmètre	Capacités principales
Owner	Organisation	Tout, y compris facturation, suppression org, transfert de propriété
Admin	Workspace	Gestion membres, configuration, tous modules, sécurité (hors facturation)
Manager	Workspace	Scraping, exports, agents IA, BI, rapports, équipe (lecture)
Agent	Workspace	Scraping, exports, recherche (pas de gestion équipe ni sécurité)
Viewer	Workspace	Lecture seule : recherche, carte, entreprises, exports limités

3.9.2 Matrice de permissions (extrait)

Action	Owner	Admin	Manager	Agent	Viewer
Lancer un job de scraping	✓	✓	✓	✓	—
Créer un export	✓	✓	✓	✓	Limité
Gérer les membres	✓	✓	—	—	—
Configurer la sécurité	✓	✓	—	—	—
Lancer le pipeline agents IA	✓	✓	✓	—	—
Consulter la BI	✓	✓	✓	—	✓
Gérer la facturation	✓	—	—	—	—
Consulter les audits	✓	✓	—	—	—

3.10. PWA et expérience mobile

ScrapIQ CI est une Progressive Web App (PWA) installable sur mobile et desktop, offrant une expérience quasi-native avec support hors-ligne, notifications push et accès direct depuis l'écran d'accueil. La PWA est particulièrement adaptée au contexte ivoirien où le mobile est le principal point d'accès à Internet.

3.10.1 Caractéristiques PWA

- Service Worker pour la mise en cache hors-ligne des assets et des données récentes
- Manifeste web pour l'installation (icône, couleur émeraude, nom court « ScrapIQ »)
- Notifications push web (même canal que les notifications in-app)
- Design responsive mobile-first (tailles tactiles $\geq 44\text{px}$, navigation adaptée)
- Support des gestes tactiles (zoom carte, swipe de listes)
- Légèreté : bundle optimisé, lazy loading des modules
- Fonctionnement en connectivité dégradée (2G/3G) avec cache intelligent

3.10.2 Objectifs de qualité PWA

Métrique Lighthouse	Cible	Méthode
Performance	≥ 85	Optimisation bundle, cache, lazy load
Accessibilité	≥ 90	Composants ARIA, contrastes, navigation clavier

Métrique Lighthouse	Cible	Méthode
Best Practices	≥ 90	HTTPS, en-têtes de sécurité, no console errors
SEO	≥ 90	Meta tags, sitemap, données structurées
PWA	≥ 90	Manifest, service worker, installable

3.11. Business Intelligence (BI)

Le module de Business Intelligence transforme les données collectées en insights actionnables via des tableaux de bord, des graphiques, des heatmaps et des rapports planifiés. Il s'adresse principalement aux Managers et Owners qui pilotent l'activité de prospection et l'analyse de marché.

3.11.1 Tableaux de bord

Tableau de bord	Indicateurs	Audience
Vue d'ensemble	Total entreprises, jobs, exports, score moyen	Tous
Activité de scraping	Jobs/jour, taux de succès, latence, sources	Manager+
Heatmap de densité	Concentration sectorielle par commune	Manager+
Qualité des données	Score moyen, taux de remplissage, fraîcheur	Manager+
Exports & consommation	Exports générés, consommation API, quotas	Manager+
Performance commerciale	Prospects, conversion, par agent/commercial	Owner/Admin

3.11.2 Rapports planifiés

Les rapports peuvent être planifiés (quotidien, hebdomadaire, mensuel) et envoyés automatiquement par email à une liste de destinataires. Chaque rapport combine graphiques, tableaux et commentaires automatiques générés par IA. Les formats PDF et Excel sont supportés. L'historique des exécutions est conservé pour audit.

3.12. Plateforme SaaS Enterprise

Le module SaaS gère l'ensemble du modèle d'abonnement, de facturation et de monétisation de la plateforme. Il supporte plusieurs plans (Starter, Pro, Enterprise, Custom), des quotas par fonctionnalité, une facturation récurrente avec moyens de paiement locaux (Mobile Money) et internationaux (carte), la gestion des licences, et une marketplace d'intégrations à venir.

3.12.1 Plans tarifaires

Plan	Prix mensuel (FCFA)	Quotas clés	Cible
Starter	15 000	5 jobs/mois, 2 000 entreprises, 10 exports	TPE / indépendants
Pro	49 000	50 jobs/mois, 20 000 entreprises, exports illimités	PME / agences
Enterprise	149 000	Jobs illimités, 500 000 entreprises, API élevée	ETI / grands comptes
Custom	Sur devis	Quotas et SLA sur mesure	Institutions / usage massif

3.12.2 Quotas et limites

Chaque plan définit des quotas par fonctionnalité : nombre de jobs de scraping par mois, nombre d'entreprises accessibles, nombre d'exports, nombre de requêtes API, nombre de membres, nombre de webhooks, fréquence des rapports planifiés. La consommation est tracée en temps réel et des alertes émettent à 80 % et 95 % du quota. Le dépassement peut être bloquant (par défaut) ou facturé en option overage.

3.12.3 Facturation et paiements

- Facturation mensuelle ou annuelle (2 mois offerts en annuel)
- Paiement Mobile Money : Orange Money, MTN MoMo, Moov Money, Wave
- Paiement carte : Visa, Mastercard (via passerelle)
- Génération automatique de factures PDF (numérotées, conformes)
- Historique factures téléchargeable
- Gestion des avoirs et remboursements
- Essai gratuit 14 jours sans carte (plan Pro)

3.13. Agents IA multi-agents

Le module d'agents IA orchestre un pipeline de 10 agents spécialisés qui coopèrent pour transformer une requête utilisateur en jeu de données final, propre, enrichi et scoré. L'architecture s'inspire du pattern « blackboard » : chaque agent lit et écrit dans un état partagé, et l'orchestrateur coordonne l'enchaînement séquentiel et parallèle.

3.13.1 Les 10 agents

#	Agent	Rôle	Entrées	Sorties
1	Sources	Sélection des sources et construction des requêtes	query, city, commune	selectedSources, queries
2	Scraping	Collecte multi-sources parallèle	selectedSources, queries	rawData
3	Nettoyage	Normalisation tél/email/nom/adresse	rawData	cleanedData
4	Dédoublonnage	Regroupement et fusion des doublons	cleanedData	uniqueEntities
5	Enrichissement	Complétion via LLM + règles (parallèle)	uniqueEntities	enrichedEntities
6	Validation	Validation technique des champs (parallèle)	uniqueEntities	validatedEntities
7	Géocodage	Complétion GPS et liens Maps	enriched + validated	geocodedEntities
8	Classification	Classification en 18 secteurs	geocodedEntities	classifiedEntities
9	Scoring	Score 0–100 sur 7 dimensions	classifiedEntities	scoredEntities
10	Export	Génération fichiers + notifications + audit	scoredEntities	finalExport

3.13.2 Orchestration et résilience

L'orchestrateur exécute les agents 1 à 4 séquentiellement (chacun dépend du précédent), puis lance les agents 5 et 6 en parallèle (ils consomment tous deux les données uniques et sont indépendants), puis enchaîne 7, 8, 9, 10 séquentiellement. Chaque agent dispose d'un timeout (30 s à 5 min), de retries (3 tentatives avec backoff exponentiel), d'un mécanisme de checkpoint (reprise depuis le dernier agent réussi), et d'un circuit breaker (agent marqué défaillant après 3 échecs consécutifs).

```
// Pipeline d'orchestration (simplifié)
async function runPipeline(input) {
  const shared = {};
  // Phase 1 – séquentiel
  await run(agent1_Sources, input, shared, { timeout: 60_000 });
  await run(agent2_Scraping, shared, { timeout: 300_000, parallel: true });
  await run(agent3_Clean, shared, { timeout: 120_000 });
  await run(agent4_Dedupe, shared, { timeout: 120_000 });
  // Phase 2 – parallèle (blackboard)
  await Promise.all([
    run(agent5_Enrich, shared, { timeout: 180_000 }),
    run(agent6_Validate, shared, { timeout: 120_000 }),
  ]);
  // Phase 3 – séquentiel
  await run(agent7_Geocode, shared, { timeout: 180_000 });
  await run(agent8_Classify, shared, { timeout: 90_000 });
  await run(agent9_Score, shared, { timeout: 60_000 });
  await run(agent10_Export, shared, { timeout: 120_000 });
  return shared.finalExport;
}
```

Figure 3.6 — Orchestration des 10 agents IA

3.13.3 Monitoring temps réel

L'UI des agents affiche en temps réel l'état de chaque agent (pending, running, completed, failed, skipped), sa durée d'exécution, le flux d'événements (start, progress, complete), et l'état partagé (blackboard) qui s'accumule au fil du pipeline. Cette transparence rassure l'utilisateur sur le bon déroulement et facilite le diagnostic en cas d'incident.

3.14. Sécurité globale

La sécurité est transverse à toute la plateforme. Elle couvre l'authentification (traitée en 3.8), le contrôle d'accès (3.9), mais aussi la protection infrastructurelle (WAF, anti-DDoS), la détection anti-bot (captcha), le chiffrement des données, la conformité réglementaire (RGPD/APIPD), l'audit et le rate limiting. Le détail exhaustif est au chapitre 11 ; cette section en présente la cartographie fonctionnelle.

3.14.1 Composants de sécurité

Composant	Rôle	Niveau
WAF (Web Application Firewall)	Filtrage des requêtes malveillantes (SQLi, XSS, LFI)	Edge
Anti-DDoS	Atténuation des attaques par déni de service	Edge / réseau
Captcha	Détection anti-bot sur formulaires sensibles	Application
Rate limiting	Limitation du nombre de requêtes par IP / par clé	Application
Chiffrement au repos	AES-256 pour données sensibles en base	Données
Chiffrement en transit	TLS 1.3 pour toutes communications	Réseau
Audit log	Journalisation des actions sensibles	Application

Composant	Rôle	Niveau
RBAC + 2FA	Contrôle d'accès et double authentification	Application
Secrets management	Gestion sécurisée des secrets (env / vault)	Infrastructure

3.14.2 Conformité RGPD / APIPD

ScrapIQ CI intègre dès sa conception les principes de la loi ivoirienne n° 2013-450 et du RGPD européen (pour les clients internationaux) : licéité et loyauté de la collecte, finalité déterminée, minimisation des données, exactitude, limitation de conservation, sécurité, et accountability. Des fonctionnalités dédiées sont implémentées : consentement, droit d'accès, droit à l'effacement, portabilité, journal d'audit, et procédure de notification de violation sous 72 h.

Synthèse du chapitre

Le périmètre fonctionnel de ScrapIQ CI couvre l'intégralité de la chaîne de valeur, de la collecte multi-sources à l'exploitation décisionnelle, en passant par le traitement IA, la recherche, la cartographie, les exports, l'API, la sécurité et le modèle SaaS. Les chapitres suivants détaillent l'architecture, les cas d'utilisation, les wireframes, les diagrammes et les spécifications techniques qui opérationnalisent ces fonctionnalités.

3.15. 3.15 Spécifications détaillées par module complémentaire

3.15.1 3.15.1 Module Cartographie Avancée

Le module de cartographie avancée offre des capacités d'analyse géospatiale au-delà de la simple affichage de marqueurs. Il intègre des couches de heatmap, des filtres par rayon, des calculs de distance haversine, et des clusters dynamiques.

Fonctionnalité	Description	Technologie	Performance
Heatmap	Visualisation de la densité d'entreprises par zone	leaflet.heat	60 points < 100ms
Rayon de recherche	Cercle cliquable avec rayon configurable (1-30 km)	Leaflet Circle	Instantané
Distance haversine	Calcul de distance entre 2 points GPS	Formule haversine JS	< 1ms pour 100 calculs
Clusters dynamiques	Regroupement automatique des marqueurs proches	MarkerCluster	500 marqueurs fluide
Filtres géo	Filtrage par commune, ville, quartier	PostGIS / JS	< 200ms
Export carte	Capture PNG de la carte avec marqueurs	leaflet-image	< 3s
Layers multiples	Couches OSM, satellite, heatmap toggle	Leaflet tile layers	Switch < 500ms

3.15.2 3.15.2 Module Assistant IA Conversationnel

L'assistant IA conversationnel permet aux utilisateurs de formuler des requêtes en langage naturel et de recevoir des résultats pertinents avec une réponse en langage naturel. Il utilise le LLM z-ai (GLM-4) pour l'analyse d'intention et la génération de réponses.

Composant	Description	Modèle IA	Latence
Analyse d'intention	Extrait secteur, ville, commune, filtres depuis le langage naturel	GLM-4 (z-ai)	2-5s
Fallback déterministe	Analyse par règles si LLM indisponible	Règles + synonymes	< 100ms
Recherche Elasticsearch	Recherche BM25 avec fuzzy matching sur 76+ entreprises	In-memory ES	< 50ms
Génération réponse	Réponse en langage naturel à partir des résultats	GLM-4 (z-ai)	2-5s
Suggestions contextuelles	Suggestions de requêtes suivantes basées sur l'analyse	Heuristiques	< 10ms

3.15.3 3.15.3 Module Architecture IA Multi-Agents

L'architecture multi-agents orchestre 10 agents spécialisés qui collaborent dans un pipeline coordonné. Chaque agent a un rôle précis, des entrées/sorties définies, et des mécanismes de reprise sur erreur.

Le pipeline s'exécute en 9 phases, avec une branche parallèle pour les agents 5 (Enrichissement) et 6 (Validation) qui s'exécutent simultanément après l'agent 4 (Déduplication). L'agent 7 (Géocodage) attend la

complétion des deux agents parallèles avant de démarrer.

Agent	Rôle	Dépendances	Critique	Retry
1. Sources	Sélectionne les sources de données	Aucune	Oui	3
2. Scraping	Collecte les données brutes	Agent 1	Oui	3
3. Nettoyage	Normalise et corrige	Agent 2	Oui	2
4. Dédup	Détecte et fusionne doublons	Agent 3	Oui	2
5. Enrichissement	Complète via LLM	Agent 4	Non	2
6. Validation	Vérifie qualité	Agent 4	Non	2
7. Géocodage	Adresses → GPS	Agents 5+6	Non	2
8. Classification	Détecte secteur	Agent 7	Non	2
9. Scoring	Score qualité 0-100	Agent 8	Non	1
10. Export	Fichiers + notifications	Agent 9	Non	2

3.15.4 3.15.4 Module SaaS Enterprise

Le module SaaS Enterprise gère les licences activables, les abonnements, la facturation en FCFA, le quota temps réel, et les clés API. Il supporte 4 plans (Starter, Pro, Enterprise, Custom) avec des limites différentes par plan.

Plan	Prix/mois	Users	Entreprises	API calls	Exports	Sources	Workspaces
Starter	25 000 FCFA	3	5 000	25 000	30	3	1
Pro	85 000 FCFA	20	50 000	100 000	100	6	5
Enterprise	250 000 FCFA	100	500 000	1 000 000	1 000	10	20
Custom	Sur devis	∞	∞	∞	∞	∞	∞

CHAPITRE 4

Architecture technique

Ce chapitre décrit l'architecture technique de ScrapIQ CI sous plusieurs angles complémentaires : vue d'ensemble, architecture logique (couches et responsabilités), architecture physique (déploiement et infrastructure), microservices et distribution, flux de données, et diagrammes d'architecture (rendus en ASCII art et tableaux structurés). L'architecture vise la scalabilité, la résilience, la sécurité et la maintenabilité, tout en restant pragmatique pour une mise en œuvre progressive.

4.1. Vue d'ensemble

ScrapIQ CI est une plateforme distribuée construite autour d'une application Next.js 16 (App Router) qui sert à la fois le frontend React et l'API REST, complétée par des mini-services spécialisés (workers de scraping, orchestrateur d'agents IA, service de notifications temps réel via WebSocket) et un ensemble de stores de données (PostgreSQL via Prisma, Elasticsearch, Redis). L'orchestration des tâches asynchrones est assurée par BullMQ au-dessus de Redis.



Figure 4.1 — Architecture globale de ScrapIQ CI

4.1.1 Principes d'architecture

- Modularité
- Frontend, API, workers et services clairement séparés mais co-déployés dans Next.js pour la partie synchrone
- Asynchrone par défaut
- Toutes les tâches longues (scraping, IA, exports) passent par BullMQ pour ne pas bloquer l'API
- Résilience

- Retry, circuit breaker, idempotence, dégradation gracieuse à tous les niveaux
- Observabilité
- Logs structurés JSON, métriques Prometheus, tracing distribué
- Sécurité multicouche
- Edge (WAF/DDoS), application (RBAC/2FA), données (chiffrement)
- Scalabilité horizontale
- Stateless partout où possible, workers scalables indépendamment

4.2. Architecture logique

L'architecture logique organise le système en couches aux responsabilités distinctes. Cette séparation facilite la maintenance, les tests et l'évolution. Chaque couche ne communique qu'avec la couche immédiatement inférieure ou avec des services latéraux clairement identifiés.

4.2.1 Les six couches logiques

Couche	Responsabilité	Technologies
Présentation	UI React, rendu SSR/CSR, PWA	Next.js 16, React 19, Tailwind 4, shadcn/ui
API / Application	Endpoints REST, validation, orchestration synchrone	Next.js Route Handlers, Zod
Domaine / Métier	Logique métier : scraping, IA, scoring, RBAC	Modules TypeScript, agents IA
Accès données	Persistance, recherche, cache	Prisma, Elasticsearch client, Redis
Infrastructure	Files de jobs, workers, services temps réel	BullMQ, mini-services Bun
Sécurité transverse	Auth, autorisation, audit, chiffrement	JWT, OAuth, bcrypt, WAF

4.2.2 Flux logique d'une requête métier

Lorsqu'un utilisateur lance un job de scraping, la requête traverse successivement la couche présentation (formulaire React), la couche API (validation Zod, authentification JWT, contrôle RBAC), la couche domaine (construction du job, appel à l'orchestrateur), puis la couche infrastructure qui publie le job dans BullMQ. Un worker asynchrone consomme le job, exécute le pipeline (scraping + IA), écrit les résultats en base et dans Elasticsearch, puis émet une notification via le service WebSocket temps réel. La couche présentation est informée en direct via WebSocket et rafraîchit l'UI.




Figure 4.2 — Flux logique d'une requête de scraping

4.3. Architecture physique

L'architecture physique décrit le déploiement concret des composants sur l'infrastructure. ScrapIQ CI est conçu pour un déploiement conteneurisé (Docker) orchestré par Kubernetes, avec une séparation nette entre les services stateless (scalables horizontalement) et les stores stateful (base, cache, search).

4.3.1 Composants déployés

Composant	Type	Instances (prod)	Ressources (par instance)
App Next.js (web + API)	Stateless	3	1 vCPU, 1 GiB
Worker scraping	Stateless	2–6 (autoscale)	1 vCPU, 1,5 GiB
Orchestrateur agents IA	Stateless	1–3	1 vCPU, 1 GiB
Service notifications WS	Stateless	2	0,5 vCPU, 0,5 GiB
PostgreSQL	Stateful	1 primaire + 1 réplique	2 vCPU, 4 GiB
Redis	Stateful	1 (+ sentinel)	1 vCPU, 2 GiB
Elasticsearch	Stateful	3 nœuds	2 vCPU, 4 GiB
Edge (WAF / LB)	Managé	—	—

4.3.2 Topologie réseau



Figure 4.3 — Topologie réseau physique

La segmentation réseau isole les stores de données dans un sous-réseau privé non exposé à Internet ; seuls les services applicatifs y accèdent. Le service de notifications WebSocket écoute sur un port dédié (3003) exposé via l'Ingress approprié. Les workers de scraping sortent vers Internet via un NAT avec rotation d'IP / proxies pour limiter les blocages.

4.4. Microservices et distribution

ScrapIQ CI adopte une approche « modulaire monolithe + mini-services » : l'application principale (Next.js) est un monolithe modulaire pour la partie synchrone (UI + API), tandis que les composants intensifs ou temps réel sont extraits en mini-services indépendants (workers BullMQ, orchestrateur d'agents, service WebSocket). Ce compromis évite la complexité d'un microservices complet tout en permettant la scalabilité ciblée des points chauds.

4.4.1 Mini-services

Mini-service	Rôle	Port	Runtime	Scaling
queue-worker	Consommation des jobs BullMQ (scraping, exports, IA)	—	Bun	Horizontal
notifications-ws	Notifications temps réel via Socket.io	3003	Bun	Horizontal (sticky)
agents-orchestrator	Exécution du pipeline 10 agents	—	Worker BullMQ	Horizontal

4.4.2 Communication inter-services

- Synchrones
 - API REST interne pour les appels directs entre l'app et les services
- Asynchrones
 - BullMQ / Redis pour la file de jobs et les événements
- Temps réel
 - Socket.io pour les notifications push vers les clients connectés
- Partage d'état
 - Redis pour l'état partagé éphémère (blackboard agents, sessions)

4.4.3 Pattern blackboard pour les agents IA

L'orchestrator d'agents IA utilise un pattern blackboard : un espace d'état partagé (objet TypeScript enrichi au fil du pipeline) sert de tableau noir que chaque agent lit et écrit. Ce découplage permet d'ajouter, réordonner ou paralléliser des agents sans coupler fortement leurs entrées/sorties. L'état partagé est également exposé en lecture dans l'UI pour le monitoring temps réel.

4.5. Flux de données

Le flux de données décrit le cheminement d'une donnée depuis sa collecte jusqu'à sa restitution à l'utilisateur, en passant par toutes les étapes de traitement. Comprendre ce flux est essentiel pour diagnostiquer les problèmes de qualité et optimiser les performances.

4.5.1 Cycle de vie d'une donnée entreprise

Étape	Source → Destination	Transformation	Lieu
1. Collecte	Sources → Worker	Extraction brute (Playwright)	Worker scraping
2. Normalisation	Brut → Intermédiaire	Format commun (nom, tél, GPS...)	Worker
3. Nettoyage	Intermédiaire → Nettoyé	Normalisation +225, email, nom	Agent 3
4. Dédoublement	Nettoyé → Unique	Fusion par similarité	Agent 4
5. Enrichissement	Unique → Enrichi	LLM + règles	Agent 5
6. Validation	Unique → Validé	Regex, MX, HTTP HEAD	Agent 6
7. Géocodage	Enrichi+Validé → Géocodé	Nominatim OSM	Agent 7
8. Classification	Géocodé → Classifié	Règles + LLM (18 secteurs)	Agent 8
9. Scoring	Classifié → Scoré	7 dimensions pondérées	Agent 9

Étape	Source → Destination	Transformation	Lieu
10. Persistance	Scoré → PostgreSQL + ES	Upsert + indexation	Agent 10
11. Restitution	ES → UI / API	Recherche, carte, export	App

4.5.2 Diagramme de flux



Figure 4.4 — Flux de données de bout en bout

4.5.3 Gestion de la cohérence

La persistance suit un modèle « source de vérité PostgreSQL, index de recherche Elasticsearch ». Chaque écriture en base déclenche une indexation Elasticsearch (via événement BullMQ) pour garantir la cohérence à terme. En cas de désynchronisation, un job de réindexation complet peut être déclenché. Le cache Redis accélère les lectures fréquentes (sessions, quotas, résultats de recherche courte durée) avec une TTL adaptée à chaque type de donnée.

4.6. Diagrammes d'architecture

Cette section présente plusieurs diagrammes d'architecture complémentaires, rendus en ASCII art pour leur lisibilité dans ce document. Les versions Mermaid exploitables sont disponibles au chapitre 8.

4.6.1 Diagramme de composants



Figure 4.5 — Diagramme de composants

4.6.2 Diagramme de déploiement (Kubernetes)




Figure 4.6 — Diagramme de déploiement Kubernetes

4.6.3 Matrice de dépendances technologies

Besoin	Technologie choisie	Justification
Framework fullstack	Next.js 16 (App Router)	SSR/CSR, API routes, écosystème React
Typage	TypeScript 5	Sûreté, DX, refactoring
UI	Tailwind 4 + shadcn/ui	Cohérence visuelle, rapidité
Scraping	Playwright	Multi-browser, robuste sur sites dynamiques
Recherche	Elasticsearch	Full-text, fuzzy, géo, agrégations
Carte	Leaflet + OpenStreetMap	Libre, gratuit, performant
Files de jobs	BullMQ + Redis	Performant, retries, schedules
ORM	Prisma	Typé, migrations, multi-DB

Besoin	Technologie choisie	Justification
Auth	NextAuth.js v4	Intégré Next.js, OAuth, JWT
State client	Zustand + TanStack Query	Léger + server state
Runtime services	Bun	Rapide, TS natif, hot reload
Conteneurs	Docker	Standard de fait
Orchestration	Kubernetes	Scalabilité, écosystème
Monitoring	Prometheus + Grafana	Open source, standard

4.6.4 Choix d'architecture justifiés

Le choix d'un monolithe modulaire Next.js plutôt que des microservices purs dès le départ s'explique par la volonté de minimiser la complexité opérationnelle tout en gardant la possibilité d'extraire des services. Les seuls composants extraits en mini-services sont ceux qui en ont réellement besoin : les workers de scraping (intensifs CPU/réseau, scalables indépendamment), l'orchestrateur d'agents (longue durée) et le service WebSocket (connexions persistantes). Cette approche pragmatique accélère le time-to-market tout en préservant l'évolutivité.

Synthèse du chapitre

L'architecture de ScrapIQ CI combine un monolithe modulaire Next.js pour la partie synchrone et des mini-services spécialisés pour l'asynchrone et le temps réel, le tout orchestré par BullMQ au-dessus de Redis, avec PostgreSQL comme source de vérité et Elasticsearch comme moteur de recherche. Cette architecture est scalable, résiliente, observable et sécurisée, tout en restant pragmatique.

4.7. 4.10 Architecture de monitoring et observabilité

Le monitoring de ScrapIQ CI repose sur une stack complète d'observabilité couvrant les métriques, les logs et les traces distribuées. Cette stack permet de détecter proactivement les anomalies, diagnostiquer les incidents, et optimiser les performances.

Couche	Outil	Métriques surveillées	Alerte seuil
Infrastructure	Prometheus + Grafana	CPU, RAM, disque, réseau	CPU > 80%, RAM > 85%
Application	Sentry	Erreurs JS/Python, crashes	Taux erreur > 1%
API	Middleware logging	Latence, statut HTTP, throughput	P95 > 500ms
Base de données	Prisma logging + pg_stat	Query time, connections	Query > 1s
Scraping	BullMQ monitoring	Queue length, job duration, failures	Queue > 50 jobs
Sécurité	Security module logs	Rate limit hits, WAF blocks, DDoS	WAF blocks > 10/h
Uptime	UptimeRobot	HTTP status, response time	Downtime > 1 min
UX	Hotjar (V2)	Session recordings, heatmaps	Drop-off > 50%

4.8. 4.11 Architecture de scaling

ScrapIQ CI est conçu pour scaler horizontalement. Chaque composant peut être répliqué indépendamment pour absorber la charge croissante.

Composant	Scaling	Min	Max	Trigger
Next.js app	Horizontal (pods K8s)	2	20	CPU > 70%
API routes	Horizontal (pods K8s)	2	15	RPS > 1000
Scraper workers	Horizontal (BullMQ)	2	50	Queue > 20 jobs
PostgreSQL	Read replicas	1 primaire	5 replicas	Query/sec > 500
Redis	Cluster mode	1	6 shards	Memory > 70%
Elasticsearch	Horizontal	1	5 nodes	Index size > 10M docs

CHAPITRE 5

Cas d'utilisation

Ce chapitre décrit les cas d'utilisation (use cases) de la plateforme ScrapIQ CI pour chacun des cinq acteurs du système : Owner, Admin, Manager, Agent et Viewer. Chaque cas d'utilisation est présenté selon un format standardisé : identifiant, acteur principal, acteurs secondaires, préconditions, scénario nominal, scénarios alternatifs, postconditions et règles métier. Cette spécification sert de référence pour la conception détaillée, les tests fonctionnels et la documentation utilisateur.

5.1. Acteurs du système

Les acteurs de ScrapIQ CI sont de deux types : les acteurs humains (utilisateurs authentifiés selon leur rôle) et les acteurs systèmes (services externes et internes qui interagissent avec la plateforme de manière automatisée).

5.1.1 Acteurs humains

Acteur	Description	Objectifs principaux
Owner	Propriétaire de l'organisation	Gérer l'org, la facturation, piloter l'usage
Admin	Administrateur du workspace	Configurer, gérer l'équipe, superviser la sécurité
Manager	Responsable d'équipe / d'activité	Piloter le scraping, les exports, la BI, les agents IA
Agent	Opérateur / commercial	Collecter et exporter des données rapidement
Viewer	Consultant / lecteur	Consulter les données, la carte, la BI (lecture seule)

5.1.2 Acteurs systèmes

Acteur	Rôle
Service de scraping	Collecte les données auprès des sources externes
Orchestrateur d'agents IA	Exécute le pipeline de 10 agents
Service de notifications	Délivre les notifications in-app/email/push/webhook
Fournisseur LLM	Fournit l'enrichissement, la classification, le scoring IA
Sources externes	Google Maps, Facebook, LinkedIn, sites web, RCCM
Passerelle de paiement	Mobile Money + carte pour la facturation SaaS
Service OSM / Nominatim	Géocodage des adresses et tuiles cartographiques

5.2. Cas d'utilisation Owner

5.2.1 UC-O1 — Créer et configurer une organisation

Acteur principal	Owner
Préconditions	L'utilisateur s'est inscrit et a confirmé son email
Scénario nominal	1. Saisie du nom d'organisation 2. Choix du slug 3. Sélection du plan 4. Validation 5. Organisation créée, utilisateur devient Owner

Postconditions	Organisation existante avec un workspace par défaut
Règles	Slug unique ; 1 organisation par compte par défaut (extensible)

5.2.2 UC-O2 — Gérer la facturation et l'abonnement

Acteur principal	Owner
Préconditions	Organisation existante
Scénario nominal	1. Ouverture de l'onglet Facturation 2. Choix/changement de plan 3. Saisie du moyen de paiement (Mobile Money/carte) 4. Validation 5. Facture émise, quotas mis à jour
Alternatives	Échec paiement → retour au choix ; downgrad → ajustement des quotas en fin de période
Postconditions	Abonnement actif, facture disponible

5.2.3 UC-O3 — Gérer les licences et invitations

Acteur principal	Owner
Scénario nominal	1. Invitation d'un membre par email 2. Attribution d'un rôle 3. Envoi de l'invitation 4. Acceptation par l'invité 5. Membre ajouté au workspace
Règles	Nombre de membres limité par plan ; Owner peut transférer la propriété

5.2.4 UC-O4 — Transférer la propriété de l'organisation

Acteur principal	Owner
Préconditions	Au moins un autre membre Admin/Manager
Scénario nominal	1. Sélection du successeur 2. Confirmation (2FA requis) 3. Transfert effectif 4. Ancien Owner devient Admin
Postconditions	Nouveau Owner défini, journalisé dans l'audit

5.2.5 UC-O5 — Consulter la BI et les rapports consolidés

Acteur principal	Owner
Scénario nominal	1. Ouverture du module BI 2. Consultation des KPIs consolidés 3. (Option) Planification d'un rapport 4. Téléchargement
Postconditions	Insights disponibles pour la décision

5.3. Cas d'utilisation Admin

5.3.1 UC-A1 — Gérer les membres et rôles

Acteur principal	Admin
Préconditions	Workspace existant, rôle Admin
Scénario nominal	1. Ouverture Équipe 2. Invitation / modification / suppression de membres 3. Attribution de rôles 4. Sauvegarde
Alternatives	Suppression d'un membre → ses données restent dans le workspace ; retrait de son propre rôle Admin interdit
Postconditions	Équipe à jour, modifications journalisées

5.3.2 UC-A2 — Configurer la sécurité du workspace

Acteur principal	Admin
Scénario nominal	1. Ouverture Sécurité 2. Activation/renforcement de la politique mot de passe 3. Obligation 2FA (option) 4. Configuration IP allowlist (option) 5. Sauvegarde
Postconditions	Politique de sécurité appliquée aux connexions suivantes

5.3.3 UC-A3 — Gérer les clés API et webhooks

Acteur principal	Admin
Scénario nominal	1. Création d'une clé API (nom, scopes, TTL) 2. Affichage unique de la clé 3. Configuration d'un webhook (URL, secret, événements) 4. Test 5. Activation
Règles	Clé affichée une seule fois ; hash stocké ; scopes limités par rôle

5.3.4 UC-A4 — Consulter les journaux d'audit

Acteur principal	Admin
Scénario nominal	1. Ouverture Audit 2. Filtrage par acteur/date/action 3. Consultation détaillée 4. (Option) Export du journal
Postconditions	Traçabilité des actions disponible

5.3.5 UC-A5 — Configurer les sources de scraping

Acteur principal	Admin
Scénario nominal	1. Ouverture configuration sources 2. Activation/désactivation de sources 3. Ajustement des rate limits 4. Sauvegarde
Règles	Respect des garde-fous globaux (robots.txt, délais minimaux)

5.4. Cas d'utilisation Manager

5.4.1 UC-M1 — Lancer un job de scraping multi-sources

Acteur principal	Manager
Préconditions	Quota de jobs disponible
Scénario nominal	1. Ouverture Scraper 2. Saisie query + city + commune 3. Sélection sources 4. Lancement 5. Suivi progression temps réel 6. Notification de fin
Alternatives	Quota dépassé → proposition d'upgrade ; erreur scraping → retry automatique puis notification
Postconditions	Données collectées, nettoyées, indexées, consultables

5.4.2 UC-M2 — Lancer le pipeline d'agents IA

Acteur principal	Manager
Scénario nominal	1. Ouverture Agents IA 2. Saisie query + city + commune 3. Lancement pipeline 4. Suivi des 10 agents en temps réel 5. Consultation du résultat final
Alternatives	Échec d'un agent → retry puis skip/abort selon configuration
Postconditions	Pipeline terminé, données enrichies et scorées disponibles

5.4.3 UC-M3 — Créer et télécharger un export

Acteur principal	Manager
Scénario nominal	1. Sélection des données (filtre/recherche) 2. Choix du format 3. Sélection des champs 4. Lancement 5. Notification de disponibilité 6. Téléchargement
Règles	Limite de lignes par plan ; génération asynchrone ; retention 30 j

5.4.4 UC-M4 — Configurer des règles d'alerte

Acteur principal	Manager
Scénario nominal	1. Ouverture Alertes 2. Création d'une règle (type, secteur, zone, seuil) 3. Choix des canaux 4. Activation
Postconditions	Règle évaluée périodiquement, notifications déclenchées

5.4.5 UC-M5 — Consulter et planifier des rapports BI

Acteur principal	Manager
Scénario nominal	1. Ouverture BI 2. Consultation des tableaux de bord 3. Création d'un rapport planifié 4. Choix destinataires 5. Activation

5.5. Cas d'utilisation Agent

5.5.1 UC-G1 — Rechercher des entreprises

Acteur principal	Agent
Scénario nominal	1. Ouverture Recherche 2. Saisie critères 3. Exécution 4. Consultation résultats (liste + carte) 5. (Option) Ouverture fiche détaillée

5.5.2 UC-G2 — Lancer un scraping simple

Acteur principal	Agent
Scénario nominal	1. Saisie query + localisation 2. Lancement 3. Consultation des résultats
Règles	Accès aux sources définies par l'Admin ; quota surveillé

5.5.3 UC-G3 — Exporter une sélection

Acteur principal	Agent
Scénario nominal	1. Sélection de résultats 2. Export (format, champs) 3. Téléchargement
Règles	Exports limités par plan ; pas d'accès aux exports avancés (PDF multi-onglets)

5.5.4 UC-G4 — Sauvegarder une recherche

Acteur principal	Agent
Scénario nominal	1. Exécution d'une recherche 2. Sauvegarde nommée 3. Réutilisation ultérieure

5.6. Cas d'utilisation Viewer

5.6.1 UC-V1 — Consulter le tableau de bord

Acteur principal	Viewer
Scénario nominal	1. Connexion 2. Consultation des KPIs globaux 3. Navigation dans les modules en lecture

5.6.2 UC-V2 — Rechercher et consulter des entreprises

Acteur principal	Viewer
Scénario nominal	1. Recherche multi-critères 2. Consultation liste + carte 3. Ouverture fiche détaillée
Règles	Pas de lancement de scraping ni d'agents IA

5.6.3 UC-V3 — Consulter la BI (lecture)

Acteur principal	Viewer
Scénario nominal	1. Ouverture BI 2. Consultation des tableaux de bord 3. (Option) Téléchargement d'un rapport existant
Règles	Pas de création ni planification de rapports

5.6.4 UC-V4 — Exporter en lecture limitée

Acteur principal	Viewer
Scénario nominal	1. Sélection de résultats 2. Export CSV limité (ligne/quota réduit)

5.6.5 Synthèse croisée des cas d'utilisation par acteur

Cas d'utilisation	Owner	Admin	Manager	Agent	Viewer
Gérer org & facturation	✓	—	—	—	—
Gérer membres & rôles	✓	✓	—	—	—
Configurer sécurité	✓	✓	—	—	—
Lancer scraping	✓	✓	✓	✓	—
Lancer agents IA	✓	✓	✓	—	—
Configurer alertes	✓	✓	✓	—	—
Créer exports avancés	✓	✓	✓	Limité	Limité
Consulter BI	✓	✓	✓	—	✓
Planifier rapports	✓	✓	✓	—	—
Consulter audit	✓	✓	—	—	—
Rechercher (lecture)	✓	✓	✓	✓	✓

Synthèse du chapitre

Les cas d'utilisation couvrent l'ensemble du périmètre fonctionnel pour les cinq rôles. Chaque use case est documenté avec préconditions, scénarios et postconditions, fournissant une base solide pour la conception, les tests et la formation. La matrice croisée récapitule les droits par acteur et use case.

5.7. 5.10 Cas d'utilisation avancés

5.7.1 5.10.1 UC-15 : Owner configure une licence d'entreprise

Étape	Action	Système	Résultat
1	Owner clique 'SaaS Enterprise' dans sidebar	Affiche vue SaaS	8 onglets visibles
2	Clique 'Générer licence' → plan Enterprise	Génère clé SQCI-XXXX-XXXX-XXXX	Licence créée (inactive)
3	Owner copie la clé et l'envoie au client	Clé dans presse-papier	Clé prête à activer
4	Client saisit la clé + son org ID	Valide la clé (statut, expiration)	Clé valide
5	Client clique 'Activer'	Active licence + crée abonnement + met à jour org plan	Licence active, plan Enterprise
6	Système vérifie quota Enterprise	100 users, 500k entreprises, 1M API	Quotas appliqués

5.7.2 5.10.2 UC-16 : Manager lance un pipeline multi-agents

Étape	Action	Système	Résultat
1	Manager clique 'IA Multi-Agents' dans sidebar	Affiche vue agents	10 agents visibles + formulaire
2	Saisit 'restaurant' + 'Abidjan' + 'Cocody'	Validation entrées	Formulaire valide
3	Clique 'Lancer le pipeline'	Crée job + démarre orchestrator	Pipeline running
4	Agent 1 (Sources) s'exécute	Analyse requête → 5 sources sélectionnées	Sources: Google Maps, FB, LinkedIn, Web, RCCM
5	Agent 2 (Scraping) collecte	Scrape parallèle 5 sources	65 entreprises brutes collectées
6	Agent 3 (Nettoyage) normalise	Normalise tél/email/noms/adresses	65 entreprises nettoyées
7	Agent 4 (Dédup) fusionne	Embeddings + Jaro-Winkler + GPS	52 entreprises uniques
8	Agents 5+6 (parallèle)	Enrichissement IA + Validation	52 enrichies + validées
9	Agent 7 (Géocodage)	GPS + liens Google Maps	52 géocodées
10	Agent 8 (Classification)	18 secteurs, hybride règles+LLM	52 classifiées
11	Agent 9 (Scoring)	7 dimensions → score 0-100	52 scorées (avg 78)
12	Agent 10 (Export)	Génère xlsx + notifie	Export + notification envoyée

CHAPITRE 6

Wireframes

Ce chapitre décrit textuellement et en détail les wireframes de chacun des écrans majeurs de la plateforme ScrapIQ CI. Pour chaque écran sont précisés : la structure globale (en-tête, navigation, zone principale, pied), les composants clés, les interactions principales, les états (vide, chargement, erreur, succès) et les considérations responsive (mobile / desktop). Ces descriptions servent de référence aux designers et développeurs frontend.

6.0.1 Conventions de description

Chaque wireframe est décrit selon une grille standardisée : objectif de l'écran, structure visuelle (du haut vers le bas), composants shadcn/ui utilisés, interactions, états et règles d'accès (rôle minimum). Une maquette ASCII synthétique illustre l'agencement général.

6.1. Tableau de bord

L'écran de tableau de bord est la page d'accueil après connexion. Il offre une vue synthétique de l'activité du workspace.




Figure 6.1 — Wireframe tableau de bord

6.1.1 Composants et interactions

- Sidebar de navigation (collapsible sur mobile) avec icônes Lucide
- Barre de recherche globale (command palette Cmd+K)
- Sélecteur de ville/commune (filtre global)
- Cloche de notifications avec badge compteur
- Cartes KPI (Card) avec tendance vs période précédente
- Graphiques (Recharts) : activité scraping, répartition sectorielle
- Tableau des derniers jobs (statut, source, durée, résultats)
- Accès : tous les rôles (contenu adapté au rôle)

6.2. Recherche

L'écran de recherche permet de trouver des entreprises selon des critères multi-dimensionnels et bascule entre vue liste et vue carte.




Figure 6.2 — Wireframe recherche (vue liste)

6.2.1 Détails

- Panneau de filtres latéral (Sidebar) : secteur, commune, score min, source, fraîcheur
- Barre de recherche full-text avec suggestions (autocomplete)
- Bascule vue liste / vue carte (Toggle Group)
- Tri (pertinence, score, nom, date, distance)
- Carte de résultat : nom, secteur, commune, catégorie (badge coloré), téléphone, score
- Pagination ou scroll infini (20 par page)
- Sélection multiple pour export groupé
- Accès : tous les rôles

6.3. Carte interactive

La carte affiche les entreprises géolocalisées avec heatmap, clusters et filtres géographiques.




Figure 6.3 — Wireframe carte interactive

6.3.1 Détails

- Carte Leaflet plein écran avec tuiles OpenStreetMap
- Marqueurs colorés par catégorie (A vert, B émeraude clair, C orange, D gris)
- Mode heatmap (densité) basculable
- Outil rayon (cercle draggable, rayon ajustable)
- Clusters au zoom arrière (marker cluster)
- Popup au clic : fiche résumée + lien vers fiche complète
- Filtres latéraux : rayon, commune, secteur, score
- Export de la vue (PNG) et de la sélection

6.4. Entreprises

L'écran Entreprises liste l'ensemble des entreprises du workspace avec gestion détaillée et fiche complète.

- Tableau dense (DataTable) avec colonnes triables : nom, secteur, ville, commune, tél, score, catégorie, MAJ
- Recherche, filtres, sélection multiple, actions groupées (export, tag, supprimer)
- Fiche détaillée (drawer latéral ou page) : tous les champs, sources, historique, score détaillé par dimension
- Édition (rôle Manager+) : correction manuelle d'un champ, marquage vérifié
- Accès : tous les rôles (édition restreinte)

Nom	Secteur	Commune	Tél	Score	Grade
Pharmacie X	Santé	Cocody	+225 07...	88	A
Quincaillerie Y	Commerce	Yopougon	+225 05...	72	B
...					

Figure 6.4 — Wireframe liste entreprises

6.5. Jobs de scraping

L'écran Jobs liste l'historique des jobs de scraping avec statut, détails et relance.

- Tableau des jobs : ID, requête, sources, statut (badge), résultats, durée, date, lancé par
- Filtres par statut, source, date, utilisateur
- Détail d'un job (drawer) : logs, événements, erreurs, résultats partiels
- Actions : relancer (avec même params), dupliquer, supprimer, planifier
- Vue planning des jobs récurrents (Admin/Manager)

6.6. Scraper multi-sources

L'écran Scraper est l'interface de lancement d'un job de scraping multi-sources.

Figure 6.5 — Wireframe formulaire de scraping

- Formulaire (Form) avec validation Zod
- Sélection multiple des sources (Checkboxes / Toggle)
- Options avancées repliables (Collapse)
- Barre de progression temps réel après lancement
- Onglets : Nouveau / En cours / Historique / Planifiés
- Accès : Manager+, Agent (sources restreintes)

6.7. Exports

L'écran Exports permet de générer et gérer les exports de données.

- Liste des exports générés (tableau) : nom, format, lignes, statut, date, télécharger
- Bouton « Nouvel export » : sélection source (recherche/job), format, champs, options
- Progression temps réel des exports en cours
- Modèles d'export sauvegardés (réutilisables)
- Retention info (30 j) et purge manuelle

6.8. API REST Explorer

L'écran API REST offre un explorateur interactif (try-it) + documentation Swagger.




Figure 6.6 — Wireframe API Explorer

- Onglet Endpoints : liste arborescente des routes par ressource
- Onglet Swagger : documentation OpenAPI 3.0 interactive
- Onglet Try-it : formulaire d'exécution d'une requête avec affichage réponse
- Onglet Clés : gestion des clés API
- Onglet Webhooks : configuration et historique des livraisons

6.9. Notifications

L'écran Notifications centralise les notifications in-app et les préférences.

- Liste des notifications (marquées lues/non lues) avec filtre par type
- Cloche globale (header) avec compteur et dropdown rapide
- Onglet Préférences : activation par type d'événement × canal
- Onglet Webhooks : configuration (voir 6.8)
- Notifications temps réel via WebSocket (push instantané)

6.10. Équipe et permissions

L'écran Équipe gère les membres du workspace et leurs rôles.

Membre	Rôle	Statut	Dernière connexion
aicha@mail.com	Owner	Actif	il y a 2 h
konan@mail.com	Admin	Actif	il y a 1 j
marc@mail.com	Manager	Actif	il y a 30 min
...			

Figure 6.7 — Wireframe équipe

- Tableau des membres avec rôle (editable), statut, dernière connexion
- Bouton Inviter (modal : email + rôle + message)
- Gestion des invitations en attente
- Suppression / suspension d'un membre
- Accès : Owner, Admin

6.11. Back office

Le back office est réservé aux Admins et Owners ; il supervise la plateforme.

- Vue d'ensemble : statistiques globales (comptes, jobs, volumes)
- Gestion des organisations et workspaces
- Supervision des workers et files BullMQ (queue monitoring)
- Gestion des sources (activation, rate limits, statut)
- Journal d'audit complet (filtrable, exportable)
- Gestion des licences et quotas globaux

Back office	[Stats]	[Queues]	[Sources]	[Audit]	[Licences]
Workers actifs : 8	Jobs en file : 23	Latence moy : 1,2s			
Queue monitoring (BullMQ)					
scraping : 80%	agents : 30%				

Figure 6.8 — Wireframe back office

6.12. Sécurité

L'écran Sécurité centralise la configuration et le suivi de sécurité.

- Politique de mot de passe (longueur, complexité, expiration)
- Activation 2FA (TOTP) avec QR code + codes de secours
- Sessions actives (appareil, IP, dernière activité, révoquer)
- IP allowlist / blocklist
- Journaux de connexion (réussis / échoués)
- Clés API et secrets (rotation, révocation)

6.13. PWA mobile

La PWA mobile adapte l'expérience aux smartphones, priorité à la consultation rapide.




Figure 6.9 — Wireframe PWA mobile

- Navigation par bottom bar (Recherche, Carte, Jobs, Profil)
- Cards empilées verticalement, tailles tactiles $\geq 44\text{px}$
- Pull-to-refresh sur les listes
- Notifications push natives (PWA)
- Mode hors-ligne : consultation des dernières données mises en cache

6.14. Business Intelligence

Le module BI présente les tableaux de bord analytiques.

- Sélecteur de tableau de bord (vue d'ensemble, activité, heatmap, qualité, exports, commercial)
- Plage de dates (date range picker)
- Graphiques Recharts (lignes, barres, donut, heatmap)
- Filtres croisés (secteur, commune, période)
- Export du tableau de bord (PNG, PDF)
- Création / planification de rapports

6.15. SaaS Enterprise

L'espace SaaS gère abonnement, facturation, licences et quotas.

- Vue plan courant + comparatif des plans
- Changement de plan (upgrade/downgrade)
- Facturation : historique, téléchargement, moyen de paiement
- Quotas : consommation temps réel par fonctionnalité, alertes
- Licences : attribution, activation, révocation
- Marketplace d'intégrations (à venir, V2)

6.16. Agents IA

L'écran Agents IA pilote et monitor le pipeline des 10 agents.




Figure 6.10 — Wireframe agents IA

- Barre de progression globale (X/10 agents terminés)
- Liste des 10 agents avec : numéro coloré, nom, rôle, statut, durée
- Flux d'événements temps réel (console noire colorée)
- État partagé (blackboard) affiché en repliable
- Diagramme d'architecture du pipeline (séquentiel + parallèle)
- Actions : relancer, abort, consulter les détails d'un agent
- Accès : Manager+

6.16.1 États d'un agent

Statut	Couleur	Signification
pending	Gris	En attente de démarrage
running	Orange	En cours d'exécution
completed	Vert	Terminé avec succès
failed	Rouge	Échec (après retries)
skipped	Gris clair	Ignoré (dépendance manquante ou circuit breaker)

Synthèse du chapitre

Les wireformes couvrent les 16 écrans majeurs de la plateforme, du tableau de bord aux agents IA. Chaque écran est décrit avec sa structure, ses composants, ses interactions et ses règles d'accès. L'approche mobile-first et la cohérence visuelle (shadcn/ui, palette émeraude/orange) assurent une expérience unifiée.

6.17. 6.11 Wireframes — Vues additionnelles

6.17.1 6.11.1 Vue Architecture Distribuée

Cette vue affiche le monitoring temps réel des queues BullMQ et des workers. Elle est organisée en 4 sections principales : statut Redis, métriques globales (7 cartes), cartes de queues (5 queues avec stats détaillées), et liste des workers (13 workers avec statut busy/idle). Un bouton 'Tester les queues' envoie 5 jobs de test simultanés. Un auto-refresh (2 secondes) met à jour les métriques en temps réel.

6.17.2 6.11.2 Vue Centre de Sécurité

Le Centre de Sécurité est organisé en 10 onglets : Vue d'ensemble (8 cartes), Rate Limiting (6 configs avec barres de progression), WAF (10 règles + bouton tester), DDoS (IPs bloquées), Captcha (stats + exemple), Journalisation (feed temps réel), Audit (blockchain immuable), Chiffrement (AES-256-GCM + masquage), RGPD (checklist conformité APIPD), Protection API (7 headers + CORS + CSP). Un badge 'Score: 85/100' est affiché dans le header.

6.17.3 6.11.3 Vue SaaS Enterprise

La vue SaaS Enterprise contient 8 onglets : Vue d'ensemble (6 KPIs + plans), Licences (générer + activer + liste), Plans (4 cards avec prix FCFA), Quota (4 barres avec %), Utilisateurs (5 rôles RBAC), Permissions (matrice 6x5), API Keys (créer + révoquer + scopes), Facturation (factures INV-XXXX + TVA 18%). Tous les montants sont en FCFA avec support Mobile Money (Orange Money, MTN MoMo, Moov).

6.17.4 6.11.4 Vue IA Multi-Agents

La vue IA Multi-Agents affiche : un formulaire de lancement (query, city, commune), une barre de progression (X/10 agents terminés), une liste des 10 agents avec statut temps réel (pending/running/completed/failed/skipped), un flux d'événements (console noire colorée), les données partagées (shared state), et un diagramme d'architecture avec flux séquentiel + branche parallèle.

CHAPITRE 7

Diagrammes UML

Ce chapitre présente les diagrammes UML de la plateforme ScrapIQ CI : diagramme de cas d'utilisation, diagramme de classes, diagrammes de séquence, diagramme d'activité, diagramme d'état et diagramme de composants. Les diagrammes sont décrits en texte structuré accompagné de tables et de représentations ASCII pour leur lisibilité dans ce document. Les versions Mermaid exploitables figurent au chapitre 8.

7.1. Diagramme de cas d'utilisation

Le diagramme de cas d'utilisation représente les interactions entre les acteurs (humains et systèmes) et les cas d'utilisation de la plateforme. Il offre une vue macro du périmètre fonctionnel et des responsabilités de chaque acteur.




Figure 7.1 — Diagramme de cas d'utilisation (synthèse)

7.1.1 Relations d'inclusion et d'extension

Cas de base	Relation	Cas cible	Condition
Lancer scraping	«include»	Nettoyer IA	Toujours
Lancer scraping	«include»	Géocoder adresses	Toujours
Lancer agents IA	«include»	Lancer scraping	Toujours
Créer export	«extend»	Planifier rapport	Optionnel
Rechercher	«extend»	Sauvegarder recherche	Optionnel
Gérer membres	«extend»	Inviter membre	Optionnel

7.2. Diagramme de classes

Le diagramme de classes décrit la structure statique du modèle de données et les relations entre entités. Il est directement lié au schéma Prisma (chapitre 10).

7.2.1 Classes principales et relations



Figure 7.2 — Diagramme de classes (extrait)

7.2.2 Attributs des classes clés

Classe	Attributs principaux	Relations
Organization	id, name, slug, plan, ownerId, settings	1→N Workspace, 1→1 User(owner)
Workspace	id, name, slug, organizationId	N→1 Organization, 1→N Member, 1→N Company
User	id, email, passwordHash, 2FA, status, locale	1→N Member, 1→N Session, 1→N ApiKey
Member	id, userId, workspaceId, role	N→1 User, N→1 Workspace
Company	id, name, sector, city, commune, phone, email, gps, score, grade	N→1 Workspace, 1→N ScrapedJobResult
ScrapedJob	id, query, city, sources, status, results, userId	N→1 User, 1→N Company
ApiKey	id, name, hash, scopes, expiresAt, userId	N→1 User
Notification	id, type, payload, channel, status, userId	N→1 User
Subscription	id, orgId, plan, status, currentPeriodEnd	N→1 Organization
AuditLog	id, actorId, action, target, metadata, ip, createdAt	N→1 User

7.2.3 Multiplicités et cardinalités

- Organization 1 — N Workspace (une org a plusieurs workspaces)
- User 1 — N Member (un user peut être membre de plusieurs workspaces)
- Workspace 1 — N Company (un workspace contient plusieurs entreprises)
- User 1 — N Session (un user a plusieurs sessions actives)
- ScrapedJob 1 — N Company (un job produit plusieurs entreprises)
- Subscription 1 — 1 Organization (une org a un abonnement courant)

7.3. Diagrammes de séquence

Les diagrammes de séquence décrivent les interactions temporelles entre objets pour réaliser un cas d'utilisation. Trois séquences clés sont détaillées : le lancement d'un job de scraping, l'authentification avec 2FA, et la création d'un export.

7.3.1 Séquence 1 — Lancement d'un job de scraping




Figure 7.3 — Séquence : lancement d'un job de scraping

7.3.2 Séquence 2 — Authentification avec 2FA




Figure 7.4 — Séquence : authentification 2FA

7.3.3 Séquence 3 — Création d'un export

Étape	Émetteur	Récepteur	Action
1	User	UI	Sélectionne données + format
2	UI	API	POST /exports
3	API	DB	Crée l'enregistrement Export (status=queued)
4	API	BullMQ	Publie le job d'export
5	API	UI	Retourne 202 (export en cours)
6	Worker	DB/ES	Récupère les données
7	Worker	FS/Storage	Génère le fichier (XLSX/CSV/PDF/JSON)
8	Worker	DB	Marque Export status=ready, stocke l'URL
9	Worker	NotifWS	Émet event export.ready
10	NotifWS	User	Push in-app + email

7.4. Diagramme d'activité

Le diagramme d'activité décrit le flux d'activités du pipeline d'agents IA, depuis la requête utilisateur jusqu'à l'export final.



Figure 7.5 — Diagramme d'activité du pipeline agents IA

7.5. Diagramme d'état

Le diagramme d'état décrit le cycle de vie d'un job de scraping, de sa création à sa terminaison.




Figure 7.6 — Diagramme d'état d'un job de scraping

7.5.1 Transitions d'état

De	Vers	Événement	Garde
—	created	POST /scraping/jobs	Quota suffisant
created	queued	Publication BullMQ	—
queued	running	Worker consomme le job	—
running	completed	Succès du pipeline	—
running	error	Échec d'une étape	Retry < 3
error	queued	Retry avec backoff	Retry < 3
error	failed	Épuisement des retries	Retry ≥ 3
running	aborted	Annulation utilisateur	—
failed	queued	Relance manuelle	—

7.6. Diagramme de composants

Le diagramme de composants montre les composants logiciels et leurs interfaces (fournies / requises). Il complète le diagramme d'architecture du chapitre 4.




Figure 7.7 — Diagramme de composants

7.6.1 Interfaces fournies et requises

Composant	Interfaces fournies	Interfaces requises
Web App	UI, REST API	Auth, Data, Jobs, Search, Push
Auth Service	AuthN/AuthZ, JWT, OAuth, 2FA	Data (users)
Data Layer	CRUD, Search	PostgreSQL, Elasticsearch, Redis
Job Queue	Enqueue, Schedule	Redis
Scraping Workers	ScrapeResult	Sources externes, Data
Agents Orchestrator	PipelineResult	LLM, Data, Jobs
Notifications WS	Push (WS)	Events (Jobs/Workers)
Export Workers	FileReady	Data, FS/Storage


Synthèse du chapitre

Les six types de diagrammes UML offrent une vue complète et complémentaire du système : structure statique (classes, composants), comportement dynamique (séquences, activité, état) et périmètre fonctionnel (cas d'utilisation). Ensemble, ils constituent la documentation de conception de référence de ScrapIQ CI.

7.7. 7.6 Diagrammes UML complémentaires

7.7.1 7.6.1 Diagramme de déploiement

Le diagramme de déploiement montre la répartition physique des composants sur les serveurs :



7.7.2 7.6.2 Diagramme de composants détaillé

Composant	Technologie	Responsabilités	Interfaces
Auth Service	Next.js API + jose + bcrypt	Login, JWT, 2FA, OAuth, sessions	POST /api/auth/*
Search Engine	In-memory Elasticsearch	Index inversé, BM25, fuzzy, aggregations	POST /api/search
Scraping Engine	Playwright + stealth	Scraping Google Maps, FB, LinkedIn, Web	POST /api/scrapper/*
IA Cleaner	z-ai SDK + pgvector	Dédup, enrichissement, scoring, fermetures	POST /api/scrapper/ai-cleaner
Export Engine	xlsx + json2csv + JSZip + PDF	Excel, CSV, PDF, JSON, ZIP multi-format	POST /api/export
Notification Engine	Multi-provider (6 canaux)	Email, SMS, WhatsApp, push, webhook, in-app	POST /api/v1/notifications
Queue Manager	BullMQ + Redis (fallback mémoire)	5 queues, 13 workers, retry, priorités	GET /api/v1/queue
Security Module	WAF + DDoS + captcha + audit	10 règles WAF, rate limiting, blockchain audit	GET /api/v1/security

Composant	Technologie	Responsabilités	Interfaces
SaaS Engine	Prisma + licences + facturation	Licences, abonnements, quota, API keys	GET/POST /api/v1/saas
Agent Orchestrator	10 agents spécialisés	Pipeline coordonné, checkpoint, reprise	POST /api/v1/agents

CHAPITRE 8

Diagrammes Mermaid

Ce chapitre présente les diagrammes clés de ScrapIQ CI sous forme de code Mermaid, format textuel standard largement supporté par les outils de documentation (GitHub, GitLab, Notion, etc.). Quatre familles de diagrammes sont couvertes : flowcharts, diagrammes de séquence, diagrammes entité-association (ER) et diagrammes de Gantt. Le code Mermaid est affiché dans des blocs monospace et peut être copié directement dans tout éditeur compatible pour rendu graphique.

8.1. Flowcharts

8.1.1 Flowchart 1 — Pipeline global de traitement

```

flowchart TD
    A([Requête utilisateur]) --> B[Agent 1: Sources]
    B --> C[Agent 2: Scraping multi-sources]
    C --> D[Agent 3: Nettoyage]
    D --> E[Agent 4: Dédoublement]
    E --> F[Parallèle]
    F --> G[Agent 5: Enrichissement LLM]
    F --> H[Agent 6: Validation]
    G --> I[Agent 7: Géocodage]
    H --> I
    I --> J[Agent 8: Classification]
    J --> K[Agent 9: Scoring]
    K --> L[Agent 10: Export & Notification]
    L --> M([Résultat final])
    C -.->|erreur| X((Retry x3))
    X -.-> C
    X -.->|échec| Y((Circuit Breaker))
  
```

Figure 8.1 — Flowchart du pipeline de traitement

8.1.2 Flowchart 2 — Authentification avec 2FA

```

flowchart TD
    Start([Utilisateur]) --> Pwd[Saisie email + mot de passe]
    Pwd --> CheckPwd{Vérif bcrypt}
    CheckPwd -->|invalid| ErrPwd[Erreur 401]
    CheckPwd -->|valide| Check2FA{2FA activé?}
    Check2FA -->|non| GenJWT[Génération JWT]
    Check2FA -->|oui| AskCode[Demande code TOTP]
    AskCode --> VerifyCode{Code valide?}
    VerifyCode -->|non| ErrCode[Erreur 401]
    VerifyCode -->|oui| GenJWT
    GenJWT --> Session[Session active]
    Session --> End([Tableau de bord])
  
```

Figure 8.2 — Flowchart de l'authentification 2FA

8.1.3 Flowchart 3 — Gestion d'un quota

```

flowchart TD
    Req([Requête API]) --> Q1{Quota dépassé?}
    Q1 -->|non| Incr[Incrémenter compteur]
    Q1 -->|oui| Q2{Overage autorisé?}
    Q2 -->|oui| Bill[Billeter overage]
    Q2 -->|non| Block[Erreur 429 Quota]
    Incr --> Exec[Exécuter requête]
    Bill --> Exec
    Exec --> Resp([Réponse])
    Block --> Resp

```

Figure 8.3 — Flowchart de gestion des quotas

8.1.4 Flowchart 4 — Décision de fusion de doublons

```

flowchart TD
    A[Deux fiches A et B] --> B1{Tel identique?}
    B1 -->|oui| P1[+0.45]
    B1 -->|non| B2{Email identique?}
    B2 -->|oui| P2[+0.35]
    B2 -->|non| B3[Similarité nom * 0.30]
    P1 --> C[Score cumulé]
    P2 --> C
    B3 --> C
    A --> D{Distance GPS < 100m?}
    D -->|oui| P3[+0.20]
    P3 --> C
    C --> E{Score >= 0.82?}
    E -->|oui| F[Fusion A+B]
    E -->|non| G[Garder séparées]

```

Figure 8.4 — Flowchart de décision de fusion

8.2. Diagrammes de séquence

8.2.1 Séquence 1 — Recherche d'entreprises

```

sequenceDiagram
    actor U as Utilisateur
    participant UI as Interface
    participant API as API REST
    participant ES as Elasticsearch
    participant DB as PostgreSQL
    U->>UI: Saisit critères + lance recherche
    UI->>API: GET /companies/search?q=...&city=...
    API->>API: Authentification JWT + RBAC
    API->>ES: Recherche full-text + filtres
    ES-->>API: Résultats + agrégations
    API->>DB: Enrichir avec données propriétaires
    DB-->>API: Données complètes
    API-->>UI: 200 OK { data, meta, facets }
    UI-->>U: Affiche liste + carte + filtres

```

Figure 8.5 — Séquence : recherche d'entreprises

8.2.2 Séquence 2 — Pipeline d'agents IA

```
sequenceDiagram
    actor M as Manager
    participant UI
    participant API
    participant ORC as Orchestrateur
    participant A1 as Agent Sources
    participant A2 as Agent Scraping
    participant A5 as Agent Enrich
    participant A6 as Agent Valid
    participant LLM
    participant WS as NotifWS
    M->>UI: Lance pipeline
    UI->>API: POST /agents
    API->>ORC: start(input)
    ORC->>A1: run
    A1-->>ORC: sources + queries
    ORC->>A2: run (parallèle multi-sources)
    A2-->>ORC: rawData
    par Branches parallèles
        ORC->>A5: run
        A5->>LLM: enrichir
        LLM-->>A5: description
    and
        ORC->>A6: run
        A6-->>ORC: validation
    end
    ORC->>WS: events (temps réel)
    WS-->>UI: push progression
    UI-->>M: 8/10 ... 10/10
    ORC-->>API: finalExport
    API-->>UI: 201 résultat
```

Figure 8.6 — Séquence : pipeline d'agents IA

8.2.3 Séquence 3 — Livraison d'un webhook

```
sequenceDiagram
    participant W as Worker
    participant DB
    participant WH as Webhook (client)
    W->>DB: Événement job.completed
    DB-->>W: Liste webhooks abonnés
    W->>WH: POST (payload + signature HMAC)
    alt Succès (2xx)
        WH-->>W: 200 OK
        W->>DB: delivery = delivered
    else Échec
        WH-->>W: 5xx / timeout
        W->>W: Retry (backoff) x5
        W->>DB: delivery = failed
    end
end
```

Figure 8.7 — Séquence : livraison d'un webhook

8.3. Diagramme entité-association

8.3.1 ER complet du modèle de données (extrait)


```

erDiagram
    ORGANIZATION ||--o{ WORKSPACE : possède
    ORGANIZATION ||--|| USER : owner
    WORKSPACE ||--o{ MEMBER : contient
    WORKSPACE ||--o{ COMPANY : regroupe
    USER ||--o{ MEMBER : membre
    USER ||--o{ SESSION : a
    USER ||--o{ API_KEY : détient
    USER ||--o{ SCRAPE_JOB : lance
    SCRAPE_JOB ||--o{ COMPANY : produit
    COMPANY ||--o{ AUDIT_LOG : audité
    ORGANIZATION ||--|| SUBSCRIPTION : abonne
    SUBSCRIPTION ||--o{ INVOICE : facture
    USER ||--o{ NOTIFICATION : reçoit
    WORKSPACE ||--o{ WEBHOOK : configure

    ORGANIZATION {
        string id PK
        string name
        string slug UK
        string plan
        string ownerId FK
    }
    COMPANY {
        string id PK
        string name
        string sector
        string city
        string commune
        string phone
        float lat
        float lng
        int score
        string grade
    }
    SCRAPE_JOB {
        string id PK
        string query
        string city
        string status
        int results
        string userId FK
    }

```

Figure 8.8 — Diagramme entité-association

8.3.2 Description des associations

Entité source	Cardinalité	Entité cible	Relation
ORGANIZATION	1 — N	WORKSPACE	possède
WORKSPACE	1 — N	MEMBER	contient
WORKSPACE	1 — N	COMPANY	regroupe
USER	1 — N	MEMBER	est membre
USER	1 — N	SESSION	possède
SCRAPE_JOB	1 — N	COMPANY	produit
ORGANIZATION	1 — 1	SUBSCRIPTION	abonné
SUBSCRIPTION	1 — N	INVOICE	facturé
WORKSPACE	1 — N	WEBHOOK	configure

8.4. Diagramme de Gantt

8.4.1 Gantt du projet (18 mois — MVP à V2)




Figure 8.9 — Diagramme de Gantt du projet

8.4.2 Lecture du Gantt

Phase	Durée	Livrable majeur	Jalon
Cadrage	≈ 3 mois	Spec + architecture	Validation comité
MVP	≈ 4 mois	Produit utilisable	Bêta privée
V1	≈ 5 mois	Produit commercial	Lancement
V2	≈ 6 mois	Agents IA + marketplace	Release V2

Synthèse du chapitre

Les diagrammes Mermaid offrent une représentation standardisée et exploitable du pipeline, de l'authentification, des quotas, de la fusion de doublons, des séquences clés, du modèle de données et du planning. Leur format textuel permet une intégration native dans la documentation technique et le suivi de projet.

8.5. 8.5 Diagrammes Mermaid complémentaires

8.5.1 8.5.1 Diagramme d'état — Job de scraping

```
stateDiagram-v2
    [*] --> Queued: POST /api/scrapper
    Queued --> Running: Worker pickup
    Running --> Completed: Success
    Running --> Failed: Error
    Running --> Cancelled: User cancel
    Failed --> Queued: Retry (max 3)
    Failed --> [*]: Max retries
    Completed --> [*]
    Cancelled --> [*]
```

8.5.2 8.5.2 Diagramme de séquence — Authentification 2FA

```
sequenceDiagram
    participant U as Utilisateur
    participant F as Frontend
    participant A as Auth API
    participant D as Database
    participant T as TOTP

    U->>F: Email + Mot de passe
    F->>A: POST /api/auth/login
    A->>D: Lookup user
    D-->>A: User (2FA enabled)
    A-->>F: { requiresTwoFactor: true, userId }
    F->>U: Demande code 2FA
    U->>T: Open Google Authenticator
    T-->>U: 6-digit code
    U->>F: Code 2FA
    F->>A: POST /api/auth/verify-2fa
    A->>T: Verify TOTP
    T-->>A: Valid
    A->>D: Create session + tokens
    D-->>A: Session created
    A-->>F: Set cookies (access + refresh)
    F-->>U: Redirect to dashboard
```

8.5.3 8.5.3 Diagramme de flux — Pipeline IA multi-agents

```
flowchart TD
    A[Requête utilisateur] --> B[Agent 1: Sources]
    B --> C[Agent 2: Scraping]
    C --> D[Agent 3: Nettoyage]
    D --> E[Agent 4: Déduplication]

    E --> F[Agent 5: Enrichissement]
    E --> G[Agent 6: Validation]

    F --> H[Agent 7: Géocodage]
    G --> H

    H --> I[Agent 8: Classification]
    I --> J[Agent 9: Scoring]
    J --> K[Agent 10: Export]

    style F fill:#06b6d4,stroke:#06b6d4
    style G fill:#ef4444,stroke:#ef4444
    style F fill:#06b6d4,stroke:#06b6d4
    style K fill:#a16207,stroke:#a16207
```


CHAPITRE 9

API REST

Ce chapitre spécifie l'API REST publique de ScrapIQ CI. Elle expose l'ensemble des capacités de la plateforme à des intégrations tierces (CRM, ERP, outils marketing, data warehouses). L'API est versionnée, documentée via OpenAPI 3.0, authentifiée par clé API ou JWT, et soumise à un rate limiting. Sont décrites : les conventions, l'authentification, et l'ensemble des endpoints par ressource (entreprises, scraping, exports, agents IA, notifications, SaaS, sécurité), ainsi que les webhooks et la documentation Swagger.

9.1. Conventions et versioning

9.1.1 URL de base et versionning

Base URL : `https://api.scrapiq.ci/api/v1`

Le versioning est explicite via le préfixe `/api/v1/`.

Les changements cassants (breaking changes) impliquent `/api/v2/`.

Les ajouts non cassants (champs, endpoints) sont rétro-compatibles.

9.1.2 Conventions de réponse

- Enveloppe standard : `{ data, meta, error }`
- `data` : objet ou tableau selon l'endpoint
- `meta` : pagination, requêteld, version
- `error` : `{ code, message, details }` en cas d'erreur
- Codes HTTP : 200 OK, 201 Created, 202 Accepted, 204 No Content, 400 Bad Request, 401 Unauthorized, 403 Forbidden, 404 Not Found, 409 Conflict, 422 Unprocessable, 429 Too Many, 500 Internal

9.1.3 Pagination

La pagination est cursor-based pour les grandes collections. Les paramètres `limit` (défaut 20, max 100) et `cursor` (opaque) sont utilisés. La réponse inclut `meta.nextCursor` (null si dernière page). Pour les petites collections, une pagination offset (`page/size`) est également supportée.

```
// Exemple de pagination cursor
GET /api/v1/companies?limit=50&cursor=eyJpZCI6ImNpeDEyMyJ9
```

```
{
  "data": [ { "id": "cix124", ... }, ... ],
  "meta": {
    "limit": 50,
    "nextCursor": "eyJpZCI6ImNpeDE3NCJ9",
    "hasMore": true,
    "requestId": "req_abc"
  }
}
```

9.1.4 Filtrage, tri, sélection de champs

Paramètre	Usage	Exemple
q	Recherche full-text	?q=pharmacie
{field}	Filtre exact	?city=Abidjan
minScore / maxScore	Filtre de plage	?minScore=65
sort	Tri (champ:ordre)	?sort=score:desc
fields	Sélection de champs	?fields=id,name,phone
sources	Filtre multi-valeurs	?sources=google_maps,facebook

9.2. Authentification

9.2.1 Méthodes d'authentification

Méthode	Header	Usage
JWT (Bearer)	Authorization: Bearer	Sessions utilisateur (UI, integrations user)
Clé API	X-API-Key:	Intégrations machine-to-machine
OAuth 2.0	Authorization: Bearer	SSO Google/Microsoft

9.2.2 Endpoints d'authentification

Méthode	Endpoint	Description	Auth
POST	/auth/register	Création de compte	Aucune
POST	/auth/login	Connexion (email + password)	Aucune
POST	/auth/2fa/verify	Vérification code TOTP	Jeton temporaire 2FA
POST	/auth/2fa/setup	Activation 2FA (génère secret)	JWT
POST	/auth/2fa/disable	Désactivation 2FA	JWT + code
POST	/auth/refresh	Rafraîchit l'access token	Refresh token
POST	/auth/logout	Déconnexion (révocation)	JWT
GET	/auth/oauth/google	Initie OAuth Google	Aucune
GET	/auth/oauth/microsoft	Initie OAuth Microsoft	Aucune
GET	/auth/sessions	Liste sessions actives	JWT
DELETE	/auth/sessions/:id	Révoque une session	JWT

```
// POST /api/v1/auth/login
// Requête
{
  "email": "user@example.ci",
  "password": "*****"
}

// Réponse 200 (2FA désactivée)
{
  "data": {
    "accessToken": "eyJhbGciOi...",
    "refreshToken": "rty...",
    "expiresIn": 900,
    "user": { "id": "u1", "email": "..." }
  }
}

// Réponse 200 (2FA activée – étape 2 requise)
{
  "data": {
    "twoFactorRequired": true,
    "twoFactorToken": "tmp_2fa_abc",
    "expiresIn": 300
  }
}
```

Figure 9.1 — Authentification login

9.3. Endpoints Entreprises

9.3.1 CRUD et recherche d'entreprises

Méthod e	Endpoint	Description	Rôle min.
GET	/companies	Liste paginée (filtres)	Viewer
GET	/companies/search	Recherche full-text + facets	Viewer
GET	/companies/:id	Détail d'une entreprise	Viewer
POST	/companies	Création manuelle	Manager
PATCH	/companies/:id	Mise à jour partielle	Manager
DELETE	/companies/:id	Suppression	Admin
GET	/companies/:id/geo	Coordonnées + carte	Viewer
GET	/companies/stats	Statistiques agrégées	Viewer

9.3.2 Exemple — Recherche avec facets

```
GET /api/v1/companies/search?q=pharmacie&city=Abidjan&minScore=65&size=20
Authorization: Bearer <jwt>

200 OK
{
  "data": [
    {
      "id": "cix1",
      "name": "Pharmacie du Plateau",
      "sector": "Santé",
      "sectorCode": "HEALTH",
      "city": "Abidjan",
      "commune": "Cocody",
      "phone": "+225 07 00 11 22 33",
      "location": { "lat": 5.34, "lng": -4.02 },
      "score": 88,
      "grade": "A",
      "sources": ["google_maps", "facebook"]
    }
  ],
  "meta": {
    "total": 142,
    "facets": {
      "by_sector": [ { "key": "Santé", "count": 142 } ],
      "by_commune": [ { "key": "Cocody", "count": 58 }, ... ],
      "by_grade": [ { "key": "A", "count": 41 }, ... ]
    }
  }
}
```

Figure 9.2 — Recherche d'entreprises avec facets

9.4. Endpoints Scraping

Méthod e	Endpoint	Description	Rôle min.
GET	/scraping/sources	Liste sources disponibles	Viewer
POST	/scraping/jobs	Lance un job de scraping	Agent
GET	/scraping/jobs	Liste des jobs	Viewer
GET	/scraping/jobs/:id	Détail + statut d'un job	Viewer
GET	/scraping/jobs/:id/results	Résultats d'un job	Viewer
POST	/scraping/jobs/:id/retry	Relance un job échoué	Manager
DELETE	/scraping/jobs/:id	Annule un job	Manager
POST	/scraping/schedule	Planifie un job récurrent	Manager
GET	/scraping/schedule	Liste des planifications	Manager
DELETE	/scraping/schedule/:id	Supprime une planification	Manager

9.4.1 Schéma de requête de création de job


```
// POST /api/v1/scraping/jobs
{
  "query": "quincaillerie",      // requis
  "city": "Abidjan",            // requis
  "commune": "Yopougon",        // optionnel
  "sources": ["google_maps","facebook","website"], // défaut: toutes
  "maxResults": 200,            // défaut 200, max 1000
  "enrich": true,               // défaut true
  "dedupe": true,               // défaut true
  "geocode": true,              // défaut true
  "webhookUrl": "https://..." // optionnel
}

// 201 Created
{
  "data": {
    "jobId": "job_a1b2",
    "status": "queued",
    "estimatedDuration": 75,
    "createdAt": "2024-07-15T10:00:00Z"
  }
}
```

Figure 9.3 — Création d'un job de scraping

9.5. Endpoints Exports

Méthod e	Endpoint	Description	Rôle min.
GET	/exports	Liste des exports	Viewer
POST	/exports	Crée un export	Agent
GET	/exports/:id	Statut + métadonnées	Viewer
GET	/exports/:id/download	Télécharge le fichier	Viewer
DELETE	/exports/:id	Supprime un export	Manager
GET	/exports/templates	Modèles sauvegardés	Viewer
POST	/exports/templates	Crée un modèle	Manager

```
// POST /api/v1/exports
{
  "source": { "type": "search", "query": "pharmacie", "city": "Abidjan" },
  "format": "xlsx",           // xlsx | csv | pdf | json
  "fields": ["id","name","sector","phone","email","score","grade"],
  "options": { "includeMap": false, "locale": "fr" }
}

// 202 Accepted
{ "data": { "exportId": "exp_x1", "status": "queued" } }

// Suivi puis téléchargement
GET /api/v1/exports/exp_x1/download → fichier binaire
```

9.6. Endpoints Agents IA

Méthod e	Endpoint	Description	Rôle min.
GET	/agents	Liste des 10 agents (définitions)	Manager
POST	/agents	Lance le pipeline complet	Manager
GET	/agents/:pipelineId	État du pipeline (temps réel)	Manager
GET	/agents/:pipelineId/events	Flux d'événements (SSE)	Manager
POST	/agents/:pipelineId/abort	Annule le pipeline	Manager
GET	/agents/:pipelineId/result	Résultat final	Manager

```
// POST /api/v1/agents
{ "query": "restaurant", "city": "Bouaké", "commune": null }

// 201 Created
{ "data": { "pipelineId": "agents-dbc18d7", "status": "running" } }

// GET /api/v1/agents/agents-dbc18d7
{
  "data": {
    "pipelineId": "agents-dbc18d7",
    "status": "completed",
    "progress": 10,
    "total": 10,
    "duration": 5433,
    "agents": [
      { "n": 1, "name": "Sources", "status": "completed", "duration": 1200 },
      ...
    ]
  }
}
```

Figure 9.4 — Pipeline d'agents IA

9.7. Endpoints Notifications

Méthod e	Endpoint	Description	Rôle min.
GET	/notifications	Liste des notifications	Viewer
PATCH	/notifications/:id/read	Marquer comme lue	Viewer
POST	/notifications/read-all	Tout marquer lu	Viewer
GET	/notifications/preferences	Préférences par canal	Viewer
PUT	/notifications/preferences	Mettre à jour préférences	Viewer
GET	/notifications/stream	Flux temps réel (WebSocket)	Viewer
GET	/alerts	Liste des règles d'alerte	Manager
POST	/alerts	Crée une règle d'alerte	Manager
PATCH	/alerts/:id	Modifie une règle	Manager
DELETE	/alerts/:id	Supprime une règle	Manager

9.8. Endpoints SaaS & facturation

Méthode	Endpoint	Description	Rôle min.
GET	/saas/plans	Liste des plans tarifaires	Viewer
GET	/saas/subscription	Abonnement courant	Owner
POST	/saas/subscription	Souscrit / change de plan	Owner
DELETE	/saas/subscription	Résilie l'abonnement	Owner
GET	/saas/invoices	Liste des factures	Owner
GET	/saas/invoices/:id	Détail + PDF	Owner
GET	/saas/usage	Consommation des quotas	Manager
GET	/saas/licenses	Liste des licences	Owner
POST	/saas/licenses	Active une licence	Owner
POST	/saas/payment/method	Ajoute un moyen de paiement	Owner

```
// GET /api/v1/saas/plans
{
  "data": [
    { "code": "starter", "price": 15000, "currency": "XOF", "quotas": {...} },
    { "code": "pro", "price": 49000, "currency": "XOF", "quotas": {...} },
    { "code": "enterprise", "price": 149000, "currency": "XOF", "quotas": {...} }
  ]
}
```

9.9. Endpoints Sécurité

Méthode	Endpoint	Description	Rôle min.
GET	/security/audit	Journal d'audit (filtrable)	Admin
GET	/security/sessions	Sessions actives	Admin
DELETE	/security/sessions/:id	Révoque une session	Admin
GET	/security/api-keys	Liste des clés API	Admin
POST	/security/api-keys	Crée une clé API	Admin
DELETE	/security/api-keys/:id	Révoque une clé	Admin
GET	/security/webhooks	Liste des webhooks	Admin
POST	/security/webhooks	Crée un webhook	Admin
GET	/security/webhooks/:id/deliveries	Historique des livraisons	Admin
POST	/security/webhooks/:id/test	Teste un webhook	Admin
GET	/security/ip-rules	Règles IP allow/block	Admin
PUT	/security/ip-rules	Met à jour les règles	Admin

9.9.1 Rate limiting

Chaque clé API et chaque IP sont soumises à un rate limiting. Les limites varient par plan (ex. Starter : 100 req/min, Pro : 600 req/min, Enterprise : 3 000 req/min). Les en-têtes de réponse informent en temps réel de la consommation.

```
X-RateLimit-Limit: 600
X-RateLimit-Remaining: 412
X-RateLimit-Reset: 1721041200

// En cas de dépassement : 429 Too Many Requests
Retry-After: 12
```

9.10. Webhooks & Swagger

9.10.1 Événements webhook

Événement	Description	Payload
job.completed	Job de scraping terminé	jobId, results, duration
job.failed	Job échoué	jobId, error
export.ready	Export prêt	exportId, format, downloadUrl
agent.completed	Pipeline agents terminé	pipelineId, results
alert.triggered	Règle d'alerte déclenchée	alertId, condition, entities
billing.invoice	Facture émise	invoiceId, amount, dueDate

9.10.2 Sécurité des webhooks

```
// Signature HMAC SHA-256 de chaque payload
X-Webhook-Event: job.completed
X-Webhook-Signature: sha256=<hex_hmac>
X-Webhook-Timestamp: 1721041200

// Vérification côté client
expected = hmac_sha256(secret, timestamp + '.' + raw_body)
if not constant_time_eq(expected, received_signature):
    reject()
```

9.10.3 Documentation Swagger

L'API est entièrement documentée au format OpenAPI 3.0. La spécification est générée automatiquement à partir des handlers et des schémas Zod, puis servie sur `/api/v1/docs` (Swagger UI interactif) et `/api/v1/openapi.json` (spécification brute). Le Swagger UI intègre un « Try it » permettant d'exécuter des requêtes directement depuis le navigateur, avec gestion du token JWT.

9.10.4 Exemple de définition OpenAPI (extrait)

```
openapi: 3.0.3
info:
  title: ScrapIQ CI API
  version: 1.0.0
paths:
  /companies/search:
    get:
      summary: Recherche d'entreprises
      security:
        - bearerAuth: []
      parameters:
        - name: q
          in: query
          schema: { type: string }
        - name: city
          in: query
          schema: { type: string }
      responses:
        '200':
          description: Résultats de recherche
          content:
            application/json:
              schema: { $ref: '#/components/schemas/SearchResponse' }
        '401': { description: Non authentifié }
        '429': { description: Quota dépassé }
```

Figure 9.5 — Extrait OpenAPI 3.0

Synthèse du chapitre

L'API REST de ScrapIQ CI couvre l'ensemble des ressources de la plateforme avec une centaine d'endpoints, une authentification flexible (JWT, clé API, OAuth), un rate limiting par plan, des webhooks sécurisés par signature HMAC et une documentation Swagger interactive. Elle constitue le vecteur d'intégration principal de la plateforme avec l'écosystème d'outils tiers.

9.11. 9.11 API — Endpoints de monitoring et santé

Endpoint	Méthod e	Description	Auth
/api/v1	GET	Info API (version, endpoints, auth methods)	Non
/api/v1/docs	GET	Spec OpenAPI 3.0.3 (JSON)	Non
/api/v1/docs/ui	GET	Swagger UI interactif (HTML)	Non
/api/v1/queue	GET	Metrics queues (waiting, active, completed, failed)	Oui
/api/v1/queue?view=workers	GET	Stats workers (busy, idle, error, uptime)	Oui
/api/v1/queue	POST	Ajoute un job ou lance un test (5 jobs)	Oui
/api/v1/security	GET	Overview sécurité (9 modules)	Oui
/api/v1/security?view=events	GET	Événements de sécurité (filtrés)	Oui
/api/v1/security?view=audit	GET	Trail d'audit (blockchain)	Oui
/api/v1/security?view=waf	GET	Règles WAF (10 règles)	Oui
/api/v1/security?view=ddos	GET	IPs bloquées (DDoS)	Oui
/api/v1/security?view=gdpr	GET	Demandes RGPD/APIPD	Oui
/api/v1/security	POST	Actions (test WAF, create GDPR, simulate attack)	Oui
/api/v1/saas	GET	Overview SaaS (stats + plans + licences)	Oui
/api/v1/saas?view=quota	GET	Quota organisation (usage temps réel)	Oui
/api/v1/saas?view=api-keys	GET	Liste clés API	Oui
/api/v1/saas?view=billing	GET	Factures	Oui
/api/v1/saas	POST	Actions (generate/activate license, create/revoke key, invoice)	Oui
/api/v1/agents	GET	Définitions des 10 agents	Oui
/api/v1/agents	POST	Lance pipeline multi-agents	Oui
/api/v1/agents/[id]	GET	État pipeline en cours	Oui
/api/v1/notifications	GET	Liste notifications (paginée)	Oui
/api/v1/notifications/test	POST	Test multi-canal (5 canaux)	Oui
/api/v1/notifications/stats	GET	Stats par canal/statut	Oui
/api/v1/alerts	GET	Liste règles d'alerte	Oui
/api/v1/alerts/check	POST	Évaluation manuelle des alertes	Oui
/api/v1/reports	GET	Liste rapports planifiés	Oui
/api/v1/reports/[id]/run	POST	Génération manuelle d'un rapport	Oui
/api/v1/export	GET	Liste jobs d'export	Oui
/api/v1/export	POST	Lance un export (5 formats)	Oui
/api/v1/export/bulk	POST	Export massif multi-formats ZIP	Oui

Endpoint	Méthod e	Description	Auth
/api/v1/export/[id]	GET	État + téléchargement export	Oui
/api/search	POST	Recherche intelligente (IA + ES)	Oui
/api/assistant	POST	Assistant IA conversationnel	Oui

**CHAPITRE
10****Base de données**

Ce chapitre décrit le modèle de données de ScrapIQ CI. La persistance s'appuie sur PostgreSQL via l'ORM Prisma. Le modèle compte plus de 30 entités couvrant les domaines multi-tenant (organisations, workspaces, membres), utilisateurs et authentification, métier (entreprises), scraping et jobs, exports, notifications, SaaS et facturation, sécurité et audit. Sont détaillées : la vue d'ensemble, les modèles par domaine, les index et optimisations, et la stratégie de partitionnement et d'archivage.

10.1. Vue d'ensemble du schéma

Le schéma Prisma est organisé en blocs thématiques avec des commentaires de section. Chaque modèle utilise des identifiants CUID (collision-resistant, incrémentaux dans le temps), des timestamps createdAt/updatedAt automatiques, et des index ciblés pour les requêtes fréquentes. L'isolation multi-tenant est assurée par la présence de organizationId ou workspaceId sur les modèles métier.

10.1.1 Liste des modèles (30+)

Domaine	Modèles
Multi-tenant	Organization, Workspace
Utilisateurs & RBAC	User, Member, Account (OAuth), MemberRole (enum)
Auth & sessions	Session, RefreshToken, JwtBlacklist, ApiKey
SaaS & facturation	License, Subscription, Invoice, QuotaUsage
Audit & sécurité	AuditLog
Métier	Company
API & intégrations	RestApiLog, Webhook, WebhookDelivery
Notifications	Notification, AlertRule
Rapports	ScheduledReport, ReportExecution
Scraping & jobs	ScrapeJob, ScrapeJobItem, ScrapeSource, SourceConfig
Agents IA	AgentRun, AgentEvent, PipelineRun
Exports	Export, ExportTemplate
Référentiels	Sector, City, Commune

10.1.2 Configuration Prisma


```
// prisma/schema.prisma - en-tête
generator client {
  provider = "prisma-client-js"
}

datasource db {
  provider = "postgresql"
  url      = env("DATABASE_URL")
}

// Conventions :
// - id : String @id @default(cuid())
// - timestamps : createdAt / updatedAt @updatedAt
// - index sur clés étrangères et champs filtrés fréquemment
// - @@unique pour les contraintes d'unicité composées
```

10.2. Modèles multi-tenant

10.2.1 Organization

```
model Organization {
  id          String   @id @default(cuid())
  name        String
  slug        String   @unique
  plan        String   @default("starter")
  ownerId     String
  settings    String   @default("{}") // JSON
  createdAt   DateTime @default(now())
  updatedAt   DateTime @updatedAt
  members     Member[]
  workspaces  Workspace[]
  owner       User     @relation("OrgOwner", fields: [ownerId], references: [id])
  @@index([slug])
}
```

10.2.2 Workspace

```
model Workspace {
  id          String   @id @default(cuid())
  name        String
  slug        String
  organizationId String
  organization Organization @relation(fields: [organizationId], references: [id], onDelete: Cascade)
  createdAt   DateTime @default(now())
  updatedAt   DateTime @updatedAt
  members     Member[]
  companies   Company[]
  @@unique([organizationId, slug])
  @@index([organizationId])
}
```

10.2.3 User & Member

```
model User {
  id          String    @id @default(cuid())
  email       String    @unique
  emailVerified DateTime?
  passwordHash String?   // null si OAuth-only
  name        String?
  avatarUrl   String?
  locale      String    @default("fr")
  timezone    String    @default("Africa/Abidjan")
  twoFactorEnabled Boolean @default(false)
  twoFactorSecret String? // chiffré au repos
  twoFactorBackupCodes String? // JSON hashed
  twoFactorEnabledAt DateTime?
  status      String    @default("active")
  lastLoginAt DateTime?
  lastLoginIp String?
  failedLoginAttempts Int    @default(0)
  lockedUntil DateTime?
  createdAt   DateTime @default(now())
  updatedAt   DateTime @updatedAt
  @@index([email])
  @@index([status])
}

enum MemberRole {
  OWNER
  ADMIN
  MANAGER
  AGENT
  VIEWER
}

model Member {
  id          String    @id @default(cuid())
  userId      String
  workspaceId String
  role        MemberRole @default(VIEWER)
  createdAt   DateTime @default(now())
  @@unique([userId, workspaceId])
  @@index([workspaceId])
}
```

10.3. Modèles métier (entreprises)

10.3.1 Company

```
model Company {
  id          String   @id @default(cuid())
  workspaceId String
  name        String
  nameNormalized String // pour le dédoublement
  sector      String?
  sectorCode  String?
  city        String?
  commune     String?
  address     String?
  phone       String?   // +225 ...
  phoneRaw    String?   // valeur originale
  email       String?
  website     String?
  description  String?
  hours       String?   // JSON horaires
  lat         Float?
  lng         Float?
  rating      Float?
  reviewsCount Int?
  score       Int       @default(0) // 0-100
  grade       String    @default("D") // A|B|C|D
  sources     String    @default("[]") // JSON array
  keywords    String    @default("[]") // JSON array
  status      String    @default("active") // active|closed|suspect
  verified    Boolean   @default(false)
  lastScrapedAt DateTime?
  createdAt   DateTime @default(now())
  updatedAt   DateTime @updatedAt
  @@index([workspaceId])
  @@index([workspaceId, sector])
  @@index([workspaceId, city])
  @@index([workspaceId, commune])
  @@index([workspaceId, grade])
  @@index([nameNormalized])
  @@index([phone])
  @@index([status, lastScrapedAt])
}
```

10.3.2 Score détaillé (modèle associé)

```
model CompanyScore {
  id          String   @id @default(cuid())
  companyId   String   @unique
  completeness Float    // 25%
  validity    Float    // 20%
  freshness   Float    // 15%
  enrichment  Float    // 15%
  sourceReliability Float // 10%
  coherence   Float    // 10%
  onlinePresence Float  // 5%
  total       Int       // score agrégé 0-100
  grade       String    // A|B|C|D
  computedAt  DateTime @default(now())
  @@index([total])
}
```

10.4. Modèles scraping et jobs

10.4.1 ScrapeJob et ScrapeJobItem

```
model ScrapeJob {
  id          String    @id @default(cuid())
  workspaceId String
  userId      String
  query       String
  city        String?
  commune     String?
  sources     String    @default("[]") // JSON
  maxResults  Int       @default(200)
  status      String    @default("queued") // queued|running|completed|failed|aborted
  results     Int       @default(0)
  errors      String?   // JSON
  duration    Int?      // ms
  startedAt   DateTime?
  finishedAt  DateTime?
  createdAt   DateTime @default(now())
  @@index([workspaceId, status])
  @@index([userId, createdAt])
}

model ScrapeJobItem {
  id          String    @id @default(cuid())
  jobId       String
  source      String    // google_maps|facebook|linkedin|website
  raw         String    // JSON données brutes
  status      String    @default("pending")
  companyId   String?   // lien après fusion
  @@index([jobId])
  @@index([source])
}
```

10.4.2 Agents IA (PipelineRun, AgentRun, AgentEvent)

```
model PipelineRun {
  id          String    @id @default(cuid())
  workspaceId String
  userId      String
  query       String
  city        String?
  commune     String?
  status      String    @default("running")
  progress    Int       @default(0)
  total       Int       @default(10)
  sharedData  String    @default("{}") // blackboard JSON
  duration    Int?
  startedAt   DateTime @default(now())
  finishedAt  DateTime?
  @@index([workspaceId, status])
}

model AgentRun {
  id          String    @id @default(cuid())
  pipelineId  String
  agentNumber Int       // 1..10
  agentName   String
  status      String    @default("pending")
  duration    Int?
  error       String?
  retries     Int       @default(0)
  startedAt   DateTime?
  finishedAt  DateTime?
  @@index([pipelineId])
}

model AgentEvent {
  id          String    @id @default(cuid())
  pipelineId  String
  agentNumber Int?
  type        String    // start|progress|complete|error
  message     String
  data        String?   // JSON
  createdAt   DateTime @default(now())
  @@index([pipelineId, createdAt])
}
```

10.5. Index et optimisations

10.5.1 Stratégie d'indexation

L'indexation cible les requêtes fréquentes : filtrage par workspace (toujours présent car multi-tenant), par secteur/ville/commune, recherche par nom normalisé et téléphone (dédoublonnage), tri par score et date. Les index composites (workspaceId + champ) évitent les scans complets sur les grandes tables.

Table	Index	Usage
Company	(workspaceId, sector)	Filtre secteur dans un workspace
Company	(workspaceId, city)	Filtre ville
Company	(workspaceId, commune)	Filtre commune
Company	(workspaceId, grade)	Filtre catégorie A/B/C/D
Company	(nameNormalized)	Dédoublonnage par nom
Company	(phone)	Dédoublonnage par téléphone

Table	Index	Usage
Company	(status, lastScrapedAt)	Fraîcheur / re-scraping
ScrapeJob	(workspaceId, status)	Suivi des jobs par workspace
AuditLog	(actorId, createdAt)	Audit par utilisateur
Notification	(userId, readAt)	Notifications non lues

10.5.2 Optimisations des requêtes

- Utilisation systématique de select pour limiter les colonnes retournées
- Pagination cursor plutôt qu'offset sur les grandes listes
- Recherche full-text déléguée à Elasticsearch (PostgreSQL non sollicité)
- Cache Redis pour les lectures fréquentes (sessions, quotas, configs)
- Requetes préparées via Prisma (paramétrées, anti-injection)
- Transactions pour les opérations multi-tables (fusion de doublons)
- Batch inserts pour les résultats de scraping (bulkCreate)

10.5.3 Exemple de requête optimisée

```
// Liste des entreprises d'un workspace, filtrées et paginées
const companies = await db.company.findMany({
  where: {
    workspaceId,
    sector: sector ?? undefined,
    commune: commune ?? undefined,
    score: minScore ? { gte: minScore } : undefined,
  },
  orderBy: { score: 'desc' },
  take: limit,
  cursor: cursor ? { id: cursor } : undefined,
  skip: cursor ? 1 : 0,
  select: { id: true, name: true, sector: true, phone: true, score: true, grade: true },
});
```

10.6. Partitionnement et archivage

10.6.1 Stratégie de partitionnement

Les tables à forte croissance (AuditLog, AgentEvent, RestApiLog, ScrapeJobItem, WebhookDelivery) sont partitionnées par période (mois) au niveau PostgreSQL. Cela accélère les requêtes récentes (partition pruning) et facilite l'archivage des données anciennes (détachement de partitions).

Table	Critère	Rétention active	Archivage
AuditLog	Mois	12 mois	Déplacement vers table archive après 12 mois
AgentEvent	Mois	6 mois	Suppression après 6 mois
RestApiLog	Mois	3 mois	Agrégation puis suppression
ScrapeJobItem	Mois	6 mois	Suppression (données brutes)
WebhookDelivery	Mois	3 mois	Suppression

Table	Critère	Rétention active	Archivage
Notification	Mois	6 mois	Suppression des lues anciennes

10.6.2 Archivage et RGPD / APIPD

L'archivage respecte les principes de minimisation et de limitation de conservation. Les données personnelles des utilisateurs sont conservées tant que le compte est actif, puis anonymisées ou supprimées à la demande (droit à l'effacement). Les données business collectées publiquement sont conservées tant qu'elles sont pertinentes et actualisées ; un re-scraping périodique maintient leur fraîcheur et les établissements fermés sont marqués puis archivés.

10.6.3 Procédure de purge

```
-- Job cron mensuel : archivage des partitions anciennes
CREATE OR REPLACE FUNCTION archive_old_audit() RETURNS void AS $$
BEGIN
  -- Détacher la partition de plus de 12 mois
  EXECUTE format(
    'ALTER TABLE "AuditLog" DETACH PARTITION %I',
    'audit_' || to_char(now() - interval '13 months', 'YYYY-MM')
  );
  -- Exporter vers table archive (ou object storage)
  -- puis DROP la partition détachée
END;
$$ LANGUAGE plpgsql;
```

10.6.4 Sauvegarde et restauration

- Sauvegarde physique quotidienne (pg_basebackup) + WAL archivés (PITR)
- Dump logique hebdomadaire (pg_dump) pour restaurations ciblées
- Réplica en lecture pour la BI et les requêtes lourdes
- Restauration testée mensuellement (procédure documentée)
- RPO ≤ 24 h (point-in-time), RTO ≤ 4 h

Synthèse du chapitre

Le modèle de données de ScrapIQ CI comprend plus de 30 entités organisées par domaine, avec une isolation multi-tenant rigoureuse, une indexation ciblée et une stratégie de partitionnement/archivage pour les tables à forte croissance. La conformité RGPD/APIPD est intégrée aux procédures de purge. PostgreSQL reste la source de vérité, complétée par Elasticsearch pour la recherche et Redis pour le cache.

10.7. 10.6 Optimisations PostgreSQL avancées

ScrapIQ CI utilise PostgreSQL 16 avec plusieurs optimisations Enterprise pour supporter la volumétrie (100K+ entreprises, 1M+ logs) tout en maintenant des performances optimales.

Optimisation	Description	Impact
Partitionnement	Tables logs partitionnées par mois (RANGE sur created_at)	Requêtes 10x plus rapides sur période récente
Index HNSW (pgvector)	Index vectoriel pour recherche ANN (dédup IA)	Recherche similarité < 10ms sur 10M vecteurs
Index GIN trigramme	gin_trgm_ops sur name pour fuzzy matching	Recherche floue < 50ms
Row-Level Security	Isolation multi-tenant au niveau moteur	Sécurité garantie, pas de fuite tenant
Connection pooling	PgBouncer en mode transaction	Support 200+ connexions concurrentes
Read replicas	1 primaire + 2 replicas synchrones	Read throughput x3
VACUUM automatique	autovacuum agressif (scale_factor 0.05)	Pas de bloat sur tables à écriture intensive
Index partiels	Index sur conditions (WHERE deleted_at IS NULL)	Index plus petits, plus rapides

**CHAPITRE
11****Sécurité**

La sécurité est un pilier transverse de ScrapIQ CI, intégré dès la conception (« security by design »). Ce chapitre détaille l'ensemble des mesures de sécurité : authentification (JWT, OAuth), double authentification (2FA), contrôle d'accès (RBAC), protection infrastructurelle (WAF, anti-DDoS), chiffrement des données, conformité réglementaire (RGPD/APIPD), audit et traçabilité, et rate limiting. L'objectif est d'atteindre un niveau de maturité élevé (aligné OWASP Top 10) tout en restant conforme au cadre réglementaire ivoirien.

11.1. Authentification JWT & OAuth

11.1.1 Tokens JWT

L'authentification repose sur des JSON Web Tokens (JWT) signés HS256. Deux tokens sont émis à la connexion : un access token de courte durée (15 minutes) utilisé pour authentifier chaque requête API, et un refresh token de longue durée (30 jours) permettant d'obtenir un nouvel access token sans reconnecter l'utilisateur. Les refresh tokens sont stockés en base (hashés) et révocables individuellement, ce qui permet la déconnexion à distance et la révocation en cas de compromission.

Token	Usage	Durée	Stockage
Access token	Authentifier chaque requête	15 min	Mémoire client (non localStorage XSS-safe)
Refresh token	Obtenir un nouvel access token	30 jours	Base (hashé), HttpOnly cookie
2FA temp token	Transporter l'étape 2FA	5 min	Mémoire serveur + JWT signé
Email verification	Confirmer un email	24 h	Base (jeton unique)
Password reset	Réinitialiser mot de passe	1 h	Base (jeton unique)

11.1.2 Cycle de vie d'un JWT

```
// Émission à la connexion
const accessToken = jwt.sign(
  { sub: user.id, org: orgId, role, scope },
  process.env.JWT_SECRET,
  { expiresIn: '15m', algorithm: 'HS256' }
);

// Vérification à chaque requête (middleware)
const payload = jwt.verify(token, JWT_SECRET, { algorithms: ['HS256'] });
if (await isBlacklisted(token)) throw new Unauthorized();
req.user = payload;

// Rafraîchissement
POST /auth/refresh { refreshToken } → { accessToken, refreshToken }
```

11.1.3 OAuth 2.0 (Google, Microsoft)

Le SSO OAuth 2.0 permet aux utilisateurs de se connecter avec leur compte Google ou Microsoft. Le flux Authorization Code avec PKCE est utilisé. À l'issue du flux, un compte utilisateur est créé (ou lié) et une session JWT est émise. Les scopes demandés sont limités au strict nécessaire (openid, email, profile). Les

tokens OAuth ne sont pas stockés en clair : seul l'identité vérifiée est conservée.

11.1.4 Politique de mot de passe

Règle	Valeur	Justification
Longueur minimale	12 caractères	Résistance au force-brute
Complexité	3 des 4 classes (maj, min, chiffre, spécial)	Éviter les mots du dictionnaire
Hachage	bcrypt cost 12	Lenteur volontaire anti-offline
Verrouillage	5 échecs → 15 min	Anti force-brute
Historique	5 derniers interdits	Anti réutilisation
Expiration	Optionnelle (90 j)	Selon politique org
Pwned check	k-anonymité HaveIBeenPwned	Détection de fuites

11.2. Double authentification (2FA)

La double authentification renforce la sécurité des comptes, en particulier pour les rôles privilégiés (Owner, Admin). ScrapIQ CI implémente le 2FA TOTP (Time-based One-Time Password) selon la RFC 6238, compatible avec les applications Authenticator (Google Authenticator, Microsoft Authenticator, Authy, FreeOTP).

11.2.1 Activation de la 2FA

```
// 1. Génération du secret TOTP
const secret = generateTOTPSecret(); // base32, 20 bytes
const qrUrl = `otpauth://totp/ScrapIQ:${email}?secret=${secret}&issuer=ScrapIQ`;
// 2. Affichage QR + codes de secours (10 codes à usage unique)
// 3. L'utilisateur valide en saisissant un code courant
// 4. Secret chiffré puis stocké en base, 2FA activée
```

11.2.2 Vérification à la connexion

- Étape 1 : email + mot de passe → si OK, émission d'un 2FA temp token (5 min)
- Étape 2 : l'utilisateur saisit un code TOTP (6 chiffres) → vérification
- En cas d'indisponibilité de l'app : utilisation d'un code de secours (hashé, à usage unique)
- Après 5 codes erronés : verrouillage temporaire et notification email
- À succès : émission du JWT (access + refresh) et journalisation

11.2.3 Codes de secours

Dix codes de secours à usage unique sont générés à l'activation, hashés puis stockés. Ils permettent l'accès en cas de perte du dispositif TOTP. Chaque utilisation invalide le code. L'utilisateur peut régénérer les codes à tout moment (invalidant les précédents).

11.3. Contrôle d'accès RBAC

Le contrôle d'accès basé sur les rôles (RBAC) est multi-tenant et hiérarchique. Chaque action est protégée par une permission, et chaque rôle regroupe un ensemble de permissions. L'évaluation se fait à chaque

requête via un middleware qui vérifie le rôle du membre dans le workspace concerné.

11.3.1 Matrice permissions × rôles (extrait étendu)

Permission	Owner	Admin	Manager	Agent	Viewer
org:read	✓	✓	✓	✓	✓
org:billing	✓	—	—	—	—
org:delete	✓	—	—	—	—
workspace:create	✓	✓	—	—	—
member:invite	✓	✓	—	—	—
member:role:edit	✓	✓	—	—	—
member:delete	✓	✓	—	—	—
security:config	✓	✓	—	—	—
audit:read	✓	✓	—	—	—
scrape:run	✓	✓	✓	✓	—
agents:run	✓	✓	✓	—	—
export:create	✓	✓	✓	✓	limité
alert:config	✓	✓	✓	—	—
report:schedule	✓	✓	✓	—	—
company:edit	✓	✓	✓	—	—
company:delete	✓	✓	—	—	—
api-key:manage	✓	✓	—	—	—
webhook:manage	✓	✓	—	—	—
bi:read	✓	✓	✓	—	✓

11.3.2 Principe du moindre privilège

Les rôles par défaut suivent le principe du moindre privilège : un Viewer ne peut que consulter, un Agent peut collecter et exporter mais pas gérer, un Manager pilote l'activité mais ne configure pas la sécurité, un Admin gère le workspace, et l'Owner garde le contrôle total y compris la facturation. Les clés API héritent d'un sous-ensemble de permissions configurable (scopes).

11.4. WAF et protection DDoS

11.4.1 Web Application Firewall (WAF)

Un WAF en edge filtre les requêtes malveillantes avant qu'elles n'atteignent l'application. Il applique un ensemble de règles gérées (OWASP Core Rule Set) détectant les attaques courantes : injections SQL, cross-site scripting (XSS), inclusion de fichiers (LFI/RFI), traversée de répertoires, exécution de code à distance, et anomalies de protocole. Les requêtes suspectes sont bloquées (403) ou mises en défi (captcha).

Catégorie d'attaque	Détection	Action
Injection SQL	Patterns SQL dans paramètres	Blocage 403
XSS	Scripts dans paramètres/headers	Blocage 403
LFI / RFI	Chemins ../, http:// dans params	Blocage 403
Bot scanning	User-agents suspects, vitesse	Défi captcha
Brute force login	Tentatives répétées	Rate limit + verrouillage
Anomalies protocole	Headers/requêtes malformés	Rejet

11.4.2 Protection anti-DDoS

La protection anti-DDoS opère à plusieurs niveaux : au niveau réseau (L3/L4) pour absorber les attaques volumétriques (SYN floods, UDP floods) via mitigation anycast et scrubbing, et au niveau application (L7) pour limiter les requêtes par IP et par route. Les seuils sont ajustables et des alertes sont émises en cas de pic anormal de trafic.

- Mitigation L3/L4 managée par le fournisseur edge (absorption anycast)
- Rate limiting L7 par IP et par route (token bucket)
- Défi JavaScript / captcha pour les pics suspects
- Liste de blocage dynamique des IP malveillantes
- Alerting temps réel sur seuils de trafic

11.5. Chiffrement des données

Donnée	En transit	Au repos	Remarque
Communications HTTP	TLS 1.3	—	HSTS, certificats Let's Encrypt
Mots de passe	TLS	bcrypt cost 12	Jamais en clair
Secrets 2FA TOTP	TLS	AES-256-GCM	Chiffré avec clé KMS
Tokens (refresh)	TLS	Hash SHA-256	Hashé en base
Données business (PG)	TLS	Chiffrement disque (LUKS/EBS)	Volume chiffré
Backups	TLS	AES-256	Chiffrés côté serveur
Secrets applicatifs	—	Vault / secrets manager	Rotation périodique
Clés API	TLS	Hash SHA-256	Affichées une fois

11.5.1 Gestion des secrets

Les secrets applicatifs (clés JWT, credentials DB, tokens OAuth, clés API fournisseurs) sont gérés via un secrets manager (variable d'environnement chiffrée en développement, vault dédié en production). La rotation des secrets est planifiée (trimestrielle pour les clés sensibles, immédiate en cas d'incident). L'accès aux secrets est journalisé.

11.6. Conformité RGPD / APIPD

ScrapIQ CI intègre les principes de la loi ivoirienne n° 2013-450 sur la protection des données personnelles (régie par l'APIPD) et du RGPD européen pour les clients internationaux. La conformité est assurée par conception et documentée.

11.6.1 Principes respectés

Principe	Mise en œuvre
Licéité & loyauté	Collecte sur sources publiques, consentement utilisateurs, transparence
Finalité	Finalités clairement définies (prospection, analyse), non détournement
Minimisation	Seules les données utiles sont collectées et conservées
Exactitude	Mise à jour par re-scraping, correction possible
Limitation conservation	Rétention définie par type de donnée, purge automatique
Sécurité	Chiffrement, RBAC, audit, WAF (voir sections précédentes)
Accountability	Documentation, registre des traitements, journal d'audit

11.6.2 Droits des personnes

- Droit d'accès
 - L'utilisateur consulte ses données personnelles dans son profil
- Droit à l'effacement
 - Procédure de suppression de compte avec anonymisation
- Droit de rectification
 - Édition du profil par l'utilisateur
- Droit à la portabilité
 - Export JSON des données utilisateur
- Droit d'opposition
 - Désinscription possible, gestion des consentements
- Notification de violation
 - Procédure de notification sous 72 h à l'APIPD et aux personnes

11.6.3 Registre des traitements

Un registre des traitements documente chaque finalité de traitement : données concernées, base légale, destinataires, durées de conservation, mesures de sécurité. Il est tenu à jour et disponible pour l'APIPD. Une mention de confidentialité (privacy policy) et des conditions d'utilisation sont accessibles publiquement.

11.7. Audit et traçabilité

Le journal d'audit enregistre toutes les actions sensibles effectuées sur la plateforme : authentifications, changements de rôle, modifications de configuration sécurité, accès aux données sensibles, lancement de jobs, exports, suppressions. Chaque entrée contient l'acteur, l'action, la cible, l'horodatage, l'IP, le user-agent et un contexte (metadata JSON).

11.7.1 Événements audités

Catégorie	Événements	Rétention
Authentification	login, logout, 2FA enable/disable, OAuth link	12 mois
Autorisation	role change, permission grant/revoke	12 mois
Configuration	security config change, IP rules change	12 mois
Données	company create/update/delete, bulk export	12 mois
Système	source enable/disable, key rotation	12 mois
API	api key create/revoke, webhook create/delete	12 mois

11.7.2 Intégrité du journal

Le journal d'audit est append-only (aucune modification/suppression directe) et stocké sur un volume distinct. Les entrées sont horodatées et signées (chaîne de hachage) pour détecter toute altération. Un export du journal est disponible pour les Admins et Owners, et une intégration SIEM est prévue pour les plans Enterprise.

11.8. Rate limiting et anti-abus

11.8.1 Rate limiting multicouche

Niveau	Portée	Limite typique	Algorithme
Edge / WAF	Par IP globale	1000 req/min	Token bucket
Application — auth	Par IP sur /auth/*	10 req/min	Sliding window
Application — API	Par clé API / par IP	Selon plan (100–3000/min)	Token bucket
Scraping jobs	Par workspace	Quota mensuel (plan)	Compteur
Exports	Par workspace	Concurrents limités	Sémaphore

11.8.2 Anti-abus supplémentaires

- Captcha sur inscription, login après échecs, et formulaires sensibles
- Détection de comptes multiples depuis une même IP (anti-fraude)
- Validation d'email obligatoire (jeton à usage unique)
- Limitation de la taille des payloads (body size limit)
- Sanitization des entrées (anti-XSS, anti-injection)
- CORS strict (origines autorisées uniquement)
- En-têtes de sécurité : CSP, X-Frame-Options, X-Content-Type-Options, Referrer-Policy

11.8.3 Alignement OWASP Top 10

Risque OWASP	Mesure
A01 Broken Access Control	RBAC strict, vérification par requête, tests
A02 Cryptographic Failures	TLS 1.3, bcrypt, AES-256, gestion secrets
A03 Injection	Requêtes paramétrées (Prisma), WAF, validation Zod

Risque OWASP	Mesure
A04 Insecure Design	Threat modeling, revue de design, principes sécurisés
A05 Security Misconfiguration	Hardening, images minimales, secrets hors code
A06 Vulnerable Components	Dépendances scannées (SCA), mise à jour continue
A07 Auth Failures	Politique mot de passe, 2FA, verrouillage, rotation
A08 Software/Data Integrity	Signatures webhooks, CI/CD signé, intégrité audit
A09 Logging/Monitoring Failures	Audit, logs centralisés, alerting SIEM
A10 SSRF	Validation des URLs sortantes, allowlist, pas de redirect libre

Synthèse du chapitre

La sécurité de ScrapIQ CI est multicouche et conforme aux bonnes pratiques OWASP et au cadre réglementaire ivoirien (APIPD). Elle couvre l'authentification (JWT, OAuth, 2FA), le contrôle d'accès (RBAC), la protection edge (WAF, anti-DDoS), le chiffrement, l'audit et le rate limiting. Cette posture sécurisée constitue un différenciateur majeur et une condition de confiance pour les clients entreprise et institutionnels.

11.9. 11.9 Conformité réglementaire détaillée

11.9.1 11.9.1 Loi n°2013-450 (Côte d'Ivoire)

Article	Exigence	Implémentation ScrapIQ CI
Art. 3	Consentement pour collecte de données personnelles	Données publiques uniquement (pas de données personnelles nominatives)
Art. 7	Droit d'accès aux données	API /api/v1/saas?view=gdpr (type: access)
Art. 8	Droit de rectification	API /api/v1/companies PUT (modification)
Art. 9	Droit à l'effacement	Soft delete + anonymisation (deleted_at)
Art. 12	Notification de violation (72h)	Webhook + email automatique + audit log
Art. 15	Registre des traitements	Audit blockchain (immutable, hash chaîné SHA-256)
Art. 17	Sécurité des données	AES-256-GCM + bcrypt + TLS 1.3 + WAF
Art. 20	Declaration à l'APIPD	Documentation + registre de traitement intégré

**CHAPITRE
12**

Déploiement

Ce chapitre décrit la stratégie de déploiement de ScrapIQ CI : conteneurisation Docker, orchestration Kubernetes, pipeline CI/CD, infrastructure cloud, monitoring et observabilité, et scalabilité. L'objectif est un déploiement reproductible, automatisé, sécurisé et capable de supporter la montée en charge prévue par la roadmap.

12.1. Conteneurisation Docker

Chaque composant de ScrapIQ CI est conteneurisé avec Docker. Les images sont construites à partir de Dockerfiles multi-stage pour minimiser la taille et la surface d'attaque. Les images de production sont basées sur des images slim / alpine, exécutées en utilisateur non-root, et scannées pour les vulnérabilités.

12.1.1 Images Docker

Image	Base	Taille	Usage
scraapiq/app	node:20-slim	~280 Mo	Application Next.js (web + API)
scraapiq/worker-scraping	node:20-slim + Playwright	~1,2 Go	Workers de scraping
scraapiq/agents-orchestrator	node:20-slim	~300 Mo	Orchestrator agents IA
scraapiq/notifications-ws	oven/bun:latest	~120 Mo	Service WebSocket
scraapiq/postgres	postgres:16	—	Base (image officielle)
scraapiq/redis	redis:7-alpine	—	Cache + BullMQ

12.1.2 Dockerfile de l'application (extrait)

```
# syntax=docker/dockerfile:1.7
FROM node:20-slim AS deps
WORKDIR /app
COPY package.json bun.lock ./
RUN npm ci --omit=dev

FROM node:20-slim AS builder
WORKDIR /app
COPY --from=deps /app/node_modules ./node_modules
COPY . .
RUN npm run build

FROM node:20-slim AS runner
WORKDIR /app
ENV NODE_ENV=production
RUN addgroup --system --gid 1001 nodejs \
  && adduser --system --uid 1001 nextjs
COPY --from=builder --chown=nextjs:nodejs /app/.next/standalone ./
COPY --from=builder --chown=nextjs:nodejs /app/.next/static ./next/static
COPY --from=builder --chown=nextjs:nodejs /app/public ./public
USER nextjs
EXPOSE 3000
CMD ["node", "server.js"]
```

Figure 12.1 — Dockerfile multi-stage de l'application

12.2. Orchestration Kubernetes

Kubernetes orchestre le déploiement en production. Les composants stateless (app, workers, orchestrator, notifications) sont des Deployments scalables horizontalement via HPA (Horizontal Pod Autoscaler) sur la métrique CPU et la longueur de file BullMQ. Les composants stateful (PostgreSQL, Redis, Elasticsearch) sont des StatefulSets avec stockage persistant.

12.2.1 Manifeste de déploiement (extrait)

```
apiVersion: apps/v1
kind: Deployment
metadata:
  name: scraapiq-app
  namespace: scraapiq-prod
spec:
  replicas: 3
  selector:
    matchLabels: { app: scraapiq-app }
  template:
    metadata:
      labels: { app: scraapiq-app }
    spec:
      containers:
        - name: app
          image: scraapiq/app:v1.2.3
          ports: [{ containerPort: 3000 }]
          envFrom:
            - secretRef: { name: scraapiq-secrets }
            - configMapRef: { name: scraapiq-config }
          resources:
            requests: { cpu: 250m, memory: 512Mi }
            limits: { cpu: 1000m, memory: 1Gi }
          readinessProbe:
            httpGet: { path: /api/health, port: 3000 }
            periodSeconds: 10
          livenessProbe:
            httpGet: { path: /api/health, port: 3000 }
            periodSeconds: 30
```

Figure 12.2 — Deployment Kubernetes

12.2.2 Autoscaling (HPA)

Composant	Min	Max	Métrique de scale
App	3	10	CPU > 70 %
Worker scraping	2	12	Longueur file BullMQ > 20
Agents orchestrator	1	5	Pipelines concurrents > 3
Notifications WS	2	6	Connexions > 5000 / pod

12.2.3 Stratégies de déploiement

- Rolling update (défaut) : maxSurge 1, maxUnavailable 0 (zéro downtime)
- Blue/green pour les releases majeures (bascule via Ingress)
- Canary pour les fonctionnalités risquées (progressive 5 % → 100 %)
- Rollback automatique en cas d'échec des health checks

12.3. Pipeline CI/CD

Le pipeline CI/CD automatise l'intégration et le déploiement continu. À chaque push sur une branche, le pipeline exécute lint, tests, build, scan de sécurité, et construction d'images. Sur la branche main, il déploie en staging automatiquement, puis en production après validation manuelle (gate).

12.3.1 Étapes du pipeline




Figure 12.3 — Pipeline CI/CD

12.3.2 Extrait de pipeline (GitHub Actions)

```
name: CI/CD
on:
  push:
    branches: [main, develop]
jobs:
  quality:
    runs-on: ubuntu-latest
    steps:
      - uses: actions/checkout@v4
      - uses: actions/setup-node@v4
        with: { node-version: 20 }
      - run: npm ci
      - run: npm run lint
      - run: npm test -- --coverage
  build:
    needs: quality
    runs-on: ubuntu-latest
    steps:
      - uses: actions/checkout@v4
      - run: docker build -t scraapiq/app:${{ github.sha }} .
      - run: docker push scraapiq/app:${{ github.sha }}
  deploy-staging:
    needs: build
    if: github.ref == 'refs/heads/main'
    runs-on: ubuntu-latest
    steps:
      - run: kubectl set image deployment/scraapiq-app app=scraapiq/app:${{ github.sha }}
```

12.4. Infrastructure cloud

ScrapIQ CI est déployé sur une infrastructure cloud (AWS, Azure ou OVH selon le contexte) avec une architecture portable (conteneurs + Kubernetes) évitant le vendor lock-in. Le choix du cloud prend en compte la souveraineté des données (hébergement en région proche de la Côte d'Ivoire) et la conformité APIPD.

12.4.1 Composants d'infrastructure

Composant	Service cloud	Rôle
Cluster K8s	EKS / AKS / OVH Managed K8s	Orchestration des conteneurs
Base PostgreSQL	RDS / Azure DB / Managed	Source de vérité

Composant	Service cloud	Rôle
Elasticsearch	Cloud ES / self-hosted	Moteur de recherche
Redis	ElastiCache / self-hosted	Cache + file BullMQ
Stockage objets	S3 / Blob / Swift	Exports, backups, assets
CDN / Edge	CloudFront / Cloudflare	WAF, anti-DDoS, cache statique
DNS	Route53 / Azure DNS	Résolution de noms
Monitoring	Prometheus + Grafana	Métriques, dashboards
Logs	Loki / ELK	Centralisation des logs

12.4.2 Environnements

Environnement	Usage	Données	Accès
dev	Développement local	Jeu de test synthétique	Développeurs
staging	Pré-production, validation	Anonymisée, sous-ensemble	Équipe + QA
prod	Production	Réelles	Restreint (SSO + 2FA)
sandbox	Démonstration	Synthétique réaliste	Public (compte démo)

12.5. Monitoring et observabilité

L'observabilité couvre trois piliers : les métriques (Prometheus + Grafana), les logs (centralisés, structurés JSON) et les traces (tracing distribué). Des tableaux de bord opérationnels et des alertes (Alertmanager) permettent de détecter et diagnostiquer les incidents rapidement.

12.5.1 Métriques surveillées

Catégorie	Métriques	Seuil d'alerte
App	req/s, latence P95/P99, taux d'erreur	P95 > 500 ms ou erreur > 1 %
Workers	jobs en file, durée, taux d'échec	File > 100 ou échec > 5 %
DB	connexions, latence requête, réplication lag	Lag > 5 s
ES	latence recherche, taille index, santé cluster	Latence > 200 ms
Redis	mémoire, hits/misses, latence	Mémoire > 80 %
Infra	CPU, mémoire, disque, réseau	CPU > 85 % pendant 5 min

12.5.2 Tableaux de bord Grafana

- Vue d'ensemble (SLO, uptime, taux d'erreur global)
- Détail application (par route, par code)
- Workers et files BullMQ
- Base de données et Elasticsearch
- Sécurité (tentatives de connexion, blocages WAF)
- Business (comptes actifs, jobs, exports, quotas)

12.5.3 Alerting et on-call

Les alertes critiques (indisponibilité, saturation, incident sécurité) déclenchent une notification immédiate (PagerDuty / Opsgenie) à l'équipe d'astreinte. Les alertes de niveau warning sont agrégées et notifiées par canal dédié. Une procédure d'astreinte (runbook) documente la réponse à chaque type d'incident.

12.6. Stratégie de scalabilité

La scalabilité de ScrapIQ CI est principalement horizontale : les composants stateless se répliquent sous charge, et les workers de scraping scalent en fonction de la demande (longueur de file). Les stores stateful utilisent le sharding (Elasticsearch) et la réplication read (PostgreSQL) pour absorber la charge de lecture.

12.6.1 Capacités cibles

Ressource	Capacité initiale	Capacité cible (3 ans)	Mécanisme
Entreprises indexées	1 million	5 millions	Sharding ES
Jobs de scraping / jour	5 000	50 000	Workers HPA
Utilisateurs concurrents	500	5 000	App HPA + sticky WS
Requêtes API / min	1 000	10 000	App HPA + cache
Exports / jour	2 000	20 000	Workers export

12.6.2 Optimisations de scalabilité

- Stateless : aucune session serveur (JWT + Redis pour l'état partagé)
- Cache multi-niveau : Redis (app) + CDN (assets statiques)
- Read replicas PostgreSQL pour la BI et les exports lourds
- Sharding Elasticsearch par région/plage temporelle si besoin
- Asynchrone : toutes les tâches longues via BullMQ
- Connection pooling : PgBouncer devant PostgreSQL
- Compression des réponses (gzip / brotli)

Synthèse du chapitre

Le déploiement de ScrapIQ CI s'appuie sur Docker, Kubernetes, un pipeline CI/CD automatisé, une infrastructure cloud portable et une observabilité complète. La scalabilité horizontale et l'architecture asynchrone permettent d'absorber la croissance prévue sur 3 ans sans refonte majeure. Les stratégies de déploiement (rolling, blue/green, canary) assurent des mises en production sans interruption.

12.7. 12.6 Strategy de disaster recovery

Scénario	RTO	RPO	Strategy
Perte serveur app	< 5 min	0	K8s auto-restart sur autre node
Perte base PostgreSQL	< 30 min	< 5 min	Failover vers replica synchrone
Perte Redis	< 1 min	< 1 min	Fallback mémoire automatique
Perte zone cloud	< 2h	< 15 min	Multi-AZ, restauration backup
Perte datacenter	< 4h	< 1h	DRP multi-région, backup S3 cross-region
Corruption données	< 1h	< 15 min	PITR (Point-in-Time Recovery) via WAL
Ransomware	< 4h	< 1h	Backup immutable + restauration propre

CHAPITRE
13

Tests

Ce chapitre décrit la stratégie de test de ScrapIQ CI, couvrant les tests unitaires, d'intégration, end-to-end (E2E), de performance, de sécurité et de charge. L'objectif est de garantir la qualité, la fiabilité et la sécurité du produit tout au long de son cycle de vie, avec une automatisation maximale intégrée au pipeline CI/CD. La couverture cible est de 75 % sur la logique métier critique.

13.1. Tests unitaires

Les tests unitaires vérifient le comportement isolé des fonctions et modules métier (normalisation, dédoublonnage, scoring, classification, RBAC, validation). Ils s'exécutent en millisecondes et doivent être déterministes. La bibliothèque Vitest (compatible Jest) est utilisée côté frontend et backend TypeScript.

13.1.1 Périmètre des tests unitaires

Module	Fonctions testées	Couverture cible
Normalisation	formatPhone, normalizeEmail, cleanName, normalizeAddress	≥ 90 %
Dédoublonnage	similarity, shouldMerge, merge, fusionScore	≥ 90 %
Scoring	computeScore, weightedDimensions, gradeFromScore	≥ 90 %
Classification	classifyByRules, classifyByLLM, mapSector	≥ 85 %
RBAC	can(user, action, resource), rolePermissions	≥ 95 %
Validation	schemas Zod, validators	≥ 85 %
Géocodage	normalizeForGeocode, parseResult	≥ 80 %

13.1.2 Exemple de test unitaire

```
// src/lib/ai/normalize.test.ts
import { describe, it, expect } from 'vitest';
import { formatPhone } from './normalize';

describe('formatPhone', () => {
  it('formate un numéro ivoirien à 10 chiffres', () => {
    expect(formatPhone('0700112233')).toBe('+225 07 00 11 22 33');
  });
  it('ajoute le préfixe +225 si absent', () => {
    expect(formatPhone('07 00 11 22 33')).toBe('+225 07 00 11 22 33');
  });
  it('retourne null pour un numéro invalide', () => {
    expect(formatPhone('123')).toBeNull();
  });
});
```

Figure 13.1 — Test unitaire de normalisation

13.1.3 Bonnes pratiques

- Arrange / Act / Assert (AAA) pour la lisibilité
- Un test = un cas (atomique)

- Mock des dépendances externes (DB, LLM, sources)
- Snapshots pour les sorties stables (exports)
- Tests paramétrés pour couvrir les cas limites
- Couverture mesurée et seuil en CI (échec si < 75 %)

13.2. Tests d'intégration

Les tests d'intégration vérifient l'interaction entre plusieurs modules ou avec des dépendances réelles (base de test, Redis, Elasticsearch, mocks de sources). Ils s'assurent que les composants fonctionnent correctement ensemble (ex. : un job de scraping complet, de la création à l'indexation).

13.2.1 Périmètre des tests d'intégration

Scénario	Composants impliqués	Vérifications
Création + exécution job	API, BullMQ, worker, DB, ES	Job créé, exécuté, résultats indexés
Auth + RBAC	API, Auth, DB, RBAC	Token émis, permissions respectées
Pipeline agents IA	Orchestrateur, agents, LLM mock	10 agents enchaînés, résultat final
Export complet	API, worker export, storage	Fichier généré, téléchargeable
Webhook delivery	Worker, webhook, signature	Payload signé, retry sur échec
Recherche + facets	API, ES	Résultats corrects, facets cohérentes

13.2.2 Environnement de test d'intégration

Les tests d'intégration s'exécutent contre une base PostgreSQL, un Redis et un Elasticsearch dédiés (conteneurs Docker éphémères levés pour la suite puis détruits). Les sources externes (Google Maps, Facebook) sont mockées avec des fixtures réalistes. Le LLM est mocké pour la reproductibilité et la rapidité.

13.3. Tests end-to-end

Les tests E2E valident les parcours utilisateur complets à travers l'interface réelle, dans un navigateur headless. Ils utilisent Playwright pour simuler les interactions (clics, saisies, navigation) et vérifier le rendu et le comportement attendus. Ils s'exécutent sur l'environnement de staging après chaque déploiement.

13.3.1 Parcours E2E critiques

Parcours	Étapes	Assertions
Inscription + connexion	Signup → email verify → login → dashboard	Session active, KPIs visibles
Lancer un scraping	Scraper → saisie → lancer → progression → résultats	Résultats indexés, notification reçue
Recherche + export	Recherche → filtres → sélection → export CSV	Fichier téléchargeable
Pipeline agents IA	Agents → lancer → suivre 10/10 → résultat	Progression 10/10, données enrichies
Gestion membre	Équipe → inviter → accepter → rôle modifié	Membre actif, rôle appliqué
2FA	Sécurité → activer 2FA → QR → code → confirmation	2FA active, codes de secours affichés

13.3.2 Stratégie E2E

- Playwright multi-browser (Chromium, Firefox, WebKit)
- Données de test seedées (fixtures déterministes)
- Screenshots et vidéo en cas d'échec
- Ré-exécution automatique des tests flaky (retry 2)
- Exécution parallèle pour réduire la durée

13.4. Tests de performance

Les tests de performance mesurent les temps de réponse, le débit et la consommation de ressources sous charge. Ils identifient les goulots d'étranglement et valident le respect des SLO (latence P95 < 300 ms, uptime ≥ 99,5 %). L'outil k6 est utilisé.

13.4.1 Scénarios de performance

Scénario	Charge	Métrique	Cible
Recherche API	100 req/s pendant 5 min	Latence P95	< 300 ms
Recherche API (pic)	500 req/s pendant 1 min	Taux d'erreur	< 1 %
Lancement jobs	20 jobs/s	Latence création	< 200 ms
Carte 10k marqueurs	1 utilisateur	FPS / render	Fluide (≥ 30 FPS)
Export 50k lignes	1 utilisateur	Durée génération	< 60 s
Pipeline agents	10 concurrents	Durée moyenne	< 90 s

13.4.2 Extrait de scénario k6

```
import http from 'k6/http';
import { check, sleep } from 'k6';

export const options = {
  stages: [
    { duration: '30s', target: 100 },
    { duration: '5m', target: 100 },
    { duration: '30s', target: 0 },
  ],
  thresholds: {
    http_req_duration: ['p(95)<300'],
    http_req_failed: ['rate<0.01'],
  },
};

export default function () {
  const res = http.get(`${__ENV.BASE}/api/v1/companies/search?q=pharmacie`, {
    headers: { Authorization: `Bearer ${__ENV.TOKEN}` },
  });
  check(res, { 'status 200': r => r.status === 200 });
  sleep(0.1);
}
```

Figure 13.2 — Scénario de test de charge k6

13.5. Tests de sécurité

Les tests de sécurité identifient les vulnérabilités avant la production. Ils combinent analyse statique (SAST), analyse des dépendances (SCA), analyse dynamique (DAST) et tests manuels ciblés (pen-testing). L'objectif est zéro vulnérabilité critique en production.

13.5.1 Types de tests de sécurité

Type	Outil	Fréquence	Cible
SAST	SonarQube / Semgrep	À chaque commit	Code source
SCA	Dependabot / Snyk	Quotidien + CI	Dépendances
DAST	OWASP ZAP	Sur staging (hebdo)	Application en exécution
Secrets scan	GitLeaks / TruffleHog	À chaque commit	Secrets dans le code
Container scan	Trivy / Grype	À chaque build image	Images Docker
Pen-test	Prestataire externe	Annuel + avant V2	Application globale

13.5.2 Cas de test sécurité spécifiques

- Injection SQL / NoSQL via paramètres API
- XSS stocké et réfléchi (champs entreprise, descriptions)
- Broken access control (IDOR : accès à données d'un autre workspace)
- Élévation de privilège (modification de rôle via API)
- JWT manipulation (alg none, signature faible, expiration)
- Rate limiting (contournement, enumeration)
- CSRF sur actions sensibles
- SSRF via URLs de scraping / webhooks
- Fuite de secrets dans les réponses / logs

13.6. Tests de charge

Les tests de charge (et de stress) valident le comportement de la plateforme sous des charges extrêmes et identifier les limites de rupture. Ils complètent les tests de performance en poussant les ressources jusqu'à la saturation pour observer la dégradation et la récupération.

13.6.1 Types de tests de charge

Type	Objectif	Méthode
Charge normale	Valider le SLO en régime nominal	Charge soutenue égale au pic attendu
Charge de pointe	Absorber un pic soudain	Montée rapide à 2x le pic
Stress	Identifier la limite de rupture	Augmentation progressive jusqu'à cassure
Spike	Résister à un pic extrême bref	Saut à 5x pendant 1 min
Endurance (soak)	Détecter les fuites mémoire	Charge modérée 24 h
Récupération	Valider le retour à la normale	Charge puis arrêt, mesure de récupération

13.6.2 Résultats attendus

- Aucune dégradation de l'uptime sous charge normale et de pointe
- Dégradation gracieuse sous stress (ralentissement, pas d'indisponibilité)
- Récupération complète < 5 min après arrêt de la charge
- Aucune fuite mémoire sur 24 h d'endurance
- Scale-out automatique effectif sous pic (HPA réactif)

13.6.3 Plan de test de charge (extrait)

```
# Plan de charge – pic de fin de mois (prospection intensive)
Phase 1 (0-5 min) : 100 utilisateurs, recherche + visualisation carte
Phase 2 (5-10 min) : montée à 500 utilisateurs, lancements de jobs
Phase 3 (10-15 min) : 1000 utilisateurs, exports simultanés
Phase 4 (15-20 min) : pic à 2000 utilisateurs (spike)
Phase 5 (20-30 min) : retour à 500, mesure de récupération

Métriques : latence P95/P99, taux d'erreur, CPU/mémoire, HPA events
```

Synthèse du chapitre

La stratégie de test de ScrapIQ CI est pyramidale : une base large de tests unitaires rapides, des tests d'intégration pour les interactions, des tests E2E pour les parcours critiques, et des tests spécialisés (performance, sécurité, charge) pour valider les exigences non-fonctionnelles. L'automatisation et l'intégration CI/CD garantissent une qualité continue.

13.7. 13.6 Strategy de test E2E

Test	Outil	Couverture	Fréquence
Login + logout	Playwright	Email/password + 2FA + OAuth	Chaque PR
Recherche multicritère	Playwright	Recherche par mot-clé, filtre, tri	Chaque PR
Scraping Google Maps	Playwright	Lancement job + résultats + export	Quotidien
IA Cleaner pipeline	Playwright	Lancement + progression + résultats	Quotidien
Carte OpenStreetMap	Playwright	Marqueurs + heatmap + rayon	Hebdomadaire
API REST CRUD	curl/scripts	Tous les endpoints /api/v1/*	Chaque PR
Export multi-format	Scripts	xlsx, csv, json, pdf, zip	Hebdomadaire
RBAC navigation	Playwright	Owner vs Agent (sections masquées)	Chaque PR
PWA offline	Lighthouse	Service worker + cache + offline	Hebdomadaire
Sécurité (WAF, DDoS)	OWASP ZAP	Injection, XSS, path traversal	Mensuel

**CHAPITRE
14****Planning**

Ce chapitre présente le planning du projet ScrapIQ CI : les phases de développement, le diagramme de Gantt détaillé, et les jalons avec leurs livrables. Le projet est découpé en quatre phases principales (Cadrage, MVP, V1, V2) s'étalant sur 18 mois, avec une extension V3 sur 12 mois supplémentaires.

14.1. Phases du projet**14.1.1 Découpage par phases**

Phase	Durée	Période	Objectif	Livrable clé
Phase 0 — Cadrage	3 mois	Mois 1–3	Spec + architecture	Document validé
Phase 1 — MVP	4 mois	Mois 4–7	Produit utilisable	Bêta privée
Phase 2 — V1	5 mois	Mois 8–12	Produit commercial	Lancement
Phase 3 — V2	6 mois	Mois 13–18	Agents IA + marketplace	Release V2
Phase 4 — V3	12 mois	Mois 19–30	Expansion régionale	Présence UEMOA

14.1.2 Phase 0 — Cadrage (mois 1–3)

- Étude de marché approfondie (interviews, questionnaire)
- Analyse concurrentielle et positioning
- Rédaction du cahier des charges (ce document)
- Conception de l'architecture technique
- Maquettes UX/UI et validation personas
- Mise en place de l'environnement de développement

14.1.3 Phase 1 — MVP (mois 4–7)

- Authentification + RBAC (5 rôles)
- Scraping Google Maps (Playwright)
- IA cleaner : nettoyage + dédoublonnage
- Recherche Elasticsearch + UI
- Exports Excel/CSV
- Tableau de bord + carte OSM
- Bêta privée avec 50 utilisateurs pilotes

14.1.4 Phase 2 — V1 (mois 8–12)

- Multi-sources (Facebook, LinkedIn, Web)
- API REST publique + Swagger
- SaaS : plans, facturation, Mobile Money
- Notifications multi-canal + WebSocket

- Business Intelligence + rapports planifiés
- 2FA + sécurité entreprise (WAF, audit)
- Lancement commercial (100 comptes payants)

14.1.5 Phase 3 — V2 (mois 13–18)

- Agents IA multi-agents (10 agents orchestrés)
- Marketplace d'intégrations
- PWA offline + push natifs
- Alertes personnalisées avancées
- Scalabilité et optimisations performance
- Release V2 publique

14.1.6 Phase 4 — V3 (mois 19–30)

- Expansion régionale UEMOA (Sénégal, Mali, Burkina)
- Adaptation contextuelle par pays
- Modèle de scoring IA personnalisable
- Connecteurs CRM/ERP natifs
- Module de data marketplace

14.2. Diagramme de Gantt




Figure 14.1 — Diagramme de Gantt détaillé

14.2.1 Lecture du planning

Phase	Mois	Effectif moyen	Charge (hommemois)
Cadrage	1–3	3	9
MVP	4–7	4	16
V1	8–12	5	25
V2	13–18	5	30
V3	19–30	6	72
Total	30	—	152

14.3. Jalons et livrables

14.3.1 Jalons majeurs

Jalon	Mois	Critère de validation	Livrables
J0 — Cadrage validé	3	Comité de pilotage	CDC, architecture, maquettes
J1 — MVP en bêta	7	50 pilotes, NPS $\geq$ 30	Produit MVP, doc utilisateur
J2 — Lancement V1	12	100 comptes payants	V1, API, SaaS, BI
J3 — Release V2	18	1 800 comptes, agents IA	V2, marketplace, PWA
J4 — Expansion V3	30	Présence 3 pays UEMOA	V3, connecteurs, marketplace data

14.3.2 Livrables par phase (détail)

Phase	Livrables
Cadrage	Étude marché · CDC · Doc architecture · Maquettes UX · Plan de test · Backlog initial
MVP	Code MVP · Doc API v0 · Guide utilisateur · Plan de bêta · Retours consolidés
V1	Code V1 · Doc API v1 (Swagger) · Doc SaaS · Guide admin · Rapport QA · Site marketing
V2	Code V2 · Doc agents IA · Doc marketplace · Guide intégrateur · Rapport perf
V3	Code V3 · Docs par pays · Connecteurs CRM · Doc marketplace data

14.3.3 Risques planning et mitigation

Risque	Impact	Probabilité	Mitigation
Retard intégration multi-sources	Moyen	Moyenne	Prioriser Maps, mock sources tôt
Blocage IP d'une source	Élevé	Élevée	Multi-sources, proxies, fallback
Performance ES sous volume	Moyen	Moyenne	Tests perf dès le MVP, sharding
Adoption bêta lente	Moyen	Moyenne	Programme early-adopter incitatif
Dépendance LLM (coût/dispo)	Moyen	Moyenne	Multi-fournisseur, cache, fallback règles
Turnover équipe	Moyen	Faible	Documentation, pair programming, Backup

14.3.4 Gouvernance du projet

- Comité de pilotage mensuel (validation jalons, arbitrages)
- Revue hebdomadaire d'équipe (avancement, blocages)
- Stand-up quotidien (coordination)
- Rétrospective bimensuelle (amélioration continue)
- Gestion des risques mise à jour mensuellement
- Tableau de bord projet (avancement, charge, risques)

Synthèse du chapitre

Le projet ScrapIQ CI est planifié sur 30 mois en cinq phases (Cadrage, MVP, V1, V2, V3), jalonnées par des livrables clairs et des critères de validation. La charge totale est estimée à 152 homme-mois. La gouvernance et la gestion des risques encadrent l'exécution pour respecter les engagements.

14.4. 14.6 Planning détaillé — Phase par phase

Semaine	Phase	Activités	Livrables
S1-S2	MVP	Setup projet, Prisma, auth	Repo Git, DB schema, login
S3-S4	MVP	Scraping Google Maps (Playwright)	Scraper fonctionnel
S5-S6	MVP	Dashboard + KPIs + carte SVG	Dashboard basique
S7-S8	MVP	Export Excel + tableau résultats	Export .xlsx
S9-S10	MVP	Tests, polish, déploiement	MVP en production
S11-S12	MVP	Beta-test (10 utilisateurs)	Retours + corrections
S13-S16	V1	Multi-tenant + RBAC + API REST	API v1 + Swagger
S17-S20	V1	Scraping FB + LinkedIn + Web	4 scrapers
S21-S24	V1	IA Cleaner + Elasticsearch	Dédup + enrichissement
S25-S28	V1	Notifications + 2FA + OAuth	Multi-canal + sécurité
S29-S32	V1	PWA + tests + déploiement V1	V1 production
S33-S40	V2	Architecture distribuée (Redis/BullMQ)	5 queues + 13 workers
S41-S44	V2	BI + SaaS Enterprise + Sécurité	BI + licences + WAF
S45-S48	V2	Agents IA + Back Office + tests V2	10 agents + admin
S49-S56	V3	Assistant IA + VLM + Mobile Money	Innovation
S57-S64	V3	Expansion régionale + marketplace	Sénégal + Mali + API publique

CHAPITRE
15

Budget

Ce chapitre présente le budget du projet ScrapIQ CI : coûts de développement, coûts d'infrastructure, licences et services tiers, maintenance et exploitation, et enfin l'analyse de retour sur investissement (ROI). Les montants sont exprimés en FCFA (XOF) et constituent des estimations de référence, à affiner lors de la phase de cadrage opérationnelle.

15.1. Coûts de développement

Les coûts de développement couvrent la rémunération de l'équipe sur les 18 premiers mois (Cadrage + MVP + V1 + V2). L'équipe est composée de profils techniques et produit, avec un effectif moyen de 4–5 personnes.

15.1.1 Composition de l'équipe

Rôle	Effectif	Coût mensuel (FCFA)	Mois	Total (FCFA)
Lead Tech / Architecte	1	1 200 000	18	21 600 000
Développeur Fullstack	2	800 000	18	28 800 000
Développeur IA / Data	1	900 000	15	13 500 000
UX/UI Designer	1	700 000	8	5 600 000
Product Manager	1	900 000	18	16 200 000
QA / Test	1	600 000	12	7 200 000
Total développement	7 ETP	—	—	92 900 000

15.1.2 Coûts annexes de développement

Poste	Détail	Montant (FCFA)
Outils de dev	Licences IDE, GitHub, Figma, Notion	3 500 000
Formation	Veille, certifications, ateliers	2 000 000
Prestations externes	Audit sécurité, UX research	5 000 000
Legal & admin	Statuts, marques, contrats	2 500 000
Contingence (10 %)	Imprévus	10 590 000
Total annexes	—	23 590 000

15.1.3 Total développement (18 mois)

Le coût total de développement sur 18 mois s'élève à environ **116,5 millions FCFA** (92,9 M équipe + 23,6 M annexes).

15.2. Coûts d'infrastructure

15.2.1 Infrastructure cloud (annuelle)

Composant	Spécification	Coût annuel (FCFA)
Cluster Kubernetes	3 nœuds managed	4 800 000
PostgreSQL	Managed, 4 vCPU, 8 Go	3 600 000
Elasticsearch	3 nœuds, 8 Go	5 400 000
Redis	Managed, 2 Go	1 200 000
Stockage objets	1 To + trafic	900 000
CDN / Edge / WAF	Cloudflare Business	1 800 000
DNS + certificats	Managés	300 000
Monitoring	Grafana Cloud / self-hosted	1 200 000
Backups	Stockage + PITR	600 000
Sortie réseau (egress)	Trafic scraping	2 400 000
Total infra annuel	—	22 200 000

15.2.2 Évolution des coûts d'infrastructure

Année	Charge estimée	Coût infra (FCFA)	Ratio CA
Année 1 (lancement)	Faible	22 200 000	≈ 25 %
Année 2 (croissance)	Moyenne	38 000 000	≈ 18 %
Année 3 (scale)	Élevée	62 000 000	≈ 12 %

15.3. Licences et services tiers

Service	Usage	Coût annuel (FCFA)
Fournisseur LLM	Enrichissement, classification, scoring IA	12 000 000
Proxy rotating	Rotation IP pour scraping	3 600 000
Passerelle paiement	Mobile Money + carte (commission incluse)	2 400 000
Email transactionnel	Notifications email	1 200 000
Service de cartes	Tuiles OSM premium (option)	1 800 000
Service captcha	Anti-bot	900 000
Error monitoring	Sentry	900 000
Analytics produit	PostHog / Mixpanel	1 200 000
Total tiers annuel	—	24 000 000

15.4. Maintenance et exploitation

Au-delà du développement initial, l'exploitation et la maintenance représentent un coût récurrent. Elles couvrent l'équipe d'exploitation (SRE, support), la maintenance corrective et évolutive, et les évolutions continues.

Poste	Détail	Coût annuel (FCFA)
Équipe d'exploitation	1 SRE + 1 support (partiel)	18 000 000
Maintenance corrective	Bugs, correctifs sécurité	6 000 000
Maintenance évolutive	Petites évolutions, optimisations	9 000 000
Veille & mises à jour	Sources, dépendances, LLM	3 000 000
Support client	Outils, processus	2 000 000
Total maintenance annuel	—	38 000 000

15.5. Retour sur investissement (ROI)

15.5.1 Hypothèses de revenus

Année	Comptes payants	MRR moyen (FCFA)	ARR (FCFA)
Année 1	650	70 000	546 000 000
Année 2	1 800	75 000	1 620 000 000
Année 3	4 500	80 000	4 320 000 000

15.5.2 Coûts totaux par année

Année	Développement	Infra	Tiers	Maintenance	Total (FCFA)
Année 1	92 900 000	22 200 000	24 000 000	—	139 100 000
Année 2	23 600 000	38 000 000	24 000 000	38 000 000	123 600 000
Année 3	—	62 000 000	30 000 000	48 000 000	140 000 000

15.5.3 Projection de rentabilité

Année	Revenus (FCFA)	Coûts (FCFA)	Résultat (FCFA)	Cumul (FCFA)
Année 1	546 000 000	139 100 000	+406 900 000	+406 900 000
Année 2	1 620 000 000	123 600 000	+1 496 400 000	+1 903 300 000
Année 3	4 320 000 000	140 000 000	+4 180 000 000	+6 083 300 000

Synthèse budgétaire

Le projet ScrapIQ CI représente un investissement de développement d'environ 116,5 millions FCFA sur 18 mois, complété par des coûts d'infrastructure et de tiers d'environ 46 millions FCFA par an. Le retour sur investissement est atteint dès la première année grâce à un modèle SaaS récurrent à forte marge (> 70 %), avec une projection de résultat cumulé dépassant 6 milliards FCFA à 3 ans.

Sensibilités

Le scénario présenté est central. Un scénario pessimiste (adoption 30 % plus lente) reste rentable dès l'année 1. Le risque principal est la montée en charge des coûts LLM, mitigée par la mise en cache, le fallback sur règles et la négociation de volume.

15.6. 15.6 Budget détaillé par poste (3 ans)

Poste	Année 1	Année 2	Année 3	Total 3 ans
Développeurs (4)	48 M FCFA	60 M FCFA	72 M FCFA	180 M FCFA
Infrastructure cloud	6 M FCFA	15 M FCFA	30 M FCFA	51 M FCFA
Licences (z-ai, Sentry...)	3 M FCFA	5 M FCFA	8 M FCFA	16 M FCFA
Marketing + vente	5 M FCFA	15 M FCFA	25 M FCFA	45 M FCFA
Bureaux + admin	6 M FCFA	8 M FCFA	10 M FCFA	24 M FCFA
Légal + conformité	2 M FCFA	3 M FCFA	4 M FCFA	9 M FCFA
Total	70 M FCFA	106 M FCFA	149 M FCFA	325 M FCFA

15.6.1 15.6.1 Projection de revenus (3 ans)

Métrique	Année 1	Année 2	Année 3
Clients payants	50	300	1000
MRR moyen (FCFA)	85 000	120 000	150 000
MRR total (FCFA)	4 250 000	36 000 000	150 000 000
ARR (FCFA)	51 000 000	432 000 000	1 800 000 000
Coûts totaux (FCFA)	70 000 000	106 000 000	149 000 000
Résultat (FCFA)	-19 000 000	326 000 000	1 651 000 000
Break-even	Mois 14	—	—

CHAPITRE
16

Roadmap

La roadmap de ScrapIQ CI s'articule autour de quatre phases majeures s'étalant sur une période de 18 mois, du MVP jusqu'à la version Enterprise complète. Chaque phase a des objectifs clairs, des livrables définis et des critères de validation précis. Cette roadmap est conçue pour être itérative, permettant d'ajuster les priorités en fonction des retours utilisateurs et de l'évolution du marché ivoirien.

16.1. 16.1 Phase 1 — MVP (Mois 1-4)

La phase MVP (Minimum Viable Product) a pour objectif de livrer une plateforme fonctionnelle permettant de valider le concept auprès des premiers utilisateurs. Cette phase se concentre sur les fonctionnalités essentielles : recherche d'entreprises par mot-clé et zone géographique, scraping Google Maps, affichage des résultats en tableau et sur carte, export Excel basique, et authentification simple (email/mot de passe).

Le MVP cible spécifiquement le marché d'Abidjan avec ses 13 communes. Il doit démontrer la valeur du produit en permettant à un utilisateur de trouver 50+ entreprises en moins de 5 minutes, avec des coordonnées vérifiées (téléphone, adresse, GPS). L'interface doit être responsive et utilisable sur mobile, car la majorité des utilisateurs ivoiriens accèdent à internet via smartphone.

16.1.1 16.1.1 Livrables MVP

Livrable	Description	Critère d'acceptation
Authentification	Inscription/connexion email + mot de passe, JWT	Login < 2s, session 30j
Recherche	Recherche par mot-clé + commune + secteur	Résultats < 3s pour 100 entreprises
Scraping Google Maps	Scraper Playwright avec extraction complète	50 entreprises/scan, 0 blocage
Tableau de résultats	Liste triable avec colonnes configurables	10 colonnes, tri multi-critères
Carte OpenStreetMap	Carte Leaflet avec marqueurs et clusters	60 marqueurs, clusters actifs
Export Excel	Export .xlsx avec colonnes sélectionnées	1000 lignes < 5s
Dashboard basique	KPIs (entreprises, jobs, sources) + 2 graphiques	Temps réel, actualisation 5s

16.1.2 16.1.2 Critères de validation MVP

Le MVP est considéré comme validé lorsque les critères suivants sont remplis :

- 10 utilisateurs actifs (beta-testeurs) utilisent la plateforme quotidiennement
- 500+ entreprises indexées et vérifiées manuellement (taux d'erreur < 5%)
- Taux de réussite des jobs de scraping > 90%
- Temps de réponse moyen de l'API < 500ms
- Score NPS (Net Promoter Score) > 30 auprès des beta-testeurs
- Documentation API basique disponible (README + 5 endpoints documentés)

16.2. 16.2 Phase 2 — V1 Production (Mois 5-8)

La version 1 (V1) transforme le MVP en produit production-ready. Cette phase ajoute le multi-tenant, le RBAC complet, l'API REST documentée (Swagger), les webhooks, les notifications multi-canal, et le scraping multi-sources (Facebook, LinkedIn, sites web). L'objectif est de passer de 10 à 100 utilisateurs payants.

16.2.1 16.2.1 Fonctionnalités V1

Module	Fonctionnalités	Priorité
Multi-tenant	Organisations, workspaces, isolation RLS	P0
RBAC	5 rôles (Owner/Admin/Manager/Agent/Viewer), 22 permissions	P0
API REST v1	CRUD companies, webhooks, pagination, filtres, tri, Swagger	P0
Scraping Facebook	Scraper pages Facebook avec cookies de session	P1
Scraping LinkedIn	Identification entreprises + dirigeants/employés	P1
Scraping sites web	Robot visiteur automatique (accueil, contact, mentions)	P1
Notifications	Email, SMS, WhatsApp, push, webhook, in-app	P1
IA Cleaner	Dédup, enrichissement, scoring, détection fermetures	P0
Elasticsearch	Recherche full-text avec BM25, fuzzy matching	P0
2FA TOTP	Authentification à deux facteurs (Google Authenticator)	P1
OAuth	Google + Microsoft (SSO)	P2
PWA	Offline, background sync, notifications push, installation	P1

16.2.2 16.2.2 Objectifs business V1

À la fin de la V1, ScrapIQ CI doit atteindre les objectifs business suivants :

- 100 utilisateurs payants répartis sur 20 organisations
- 10 000+ entreprises indexées (Abidjan + 5 grandes villes)
- Revenu mensuel récurrent (MRR) > 850 000 FCFA (équivalent 10 abonnements Pro)
- Taux de rétention > 80% après 3 mois
- Taux de conversion essai → payant > 25%
- Support client < 24h de réponse moyenne

16.3. 16.3 Phase 3 — V2 Scale (Mois 9-14)

La version 2 (V2) fait passer ScrapIQ CI à l'échelle Enterprise. Elle introduit l'architecture distribuée (Redis, BullMQ, workers), l'auto-scaling, le monitoring avancé, la BI (Business Intelligence), et le SaaS Enterprise complet (licences, facturation, quota). L'objectif est de supporter 1000+ utilisateurs et 100 000+ entreprises.

16.3.1 16.3.1 Architecture distribuée V2

L'architecture distribuée V2 repose sur Redis comme message broker, BullMQ pour les queues, et des workers indépendants pour le traitement asynchrone. Cinq queues spécialisées gèrent les jobs de scraping, l'IA cleaner, les exports, les notifications et les rapports. Chaque queue a sa propre configuration de concurrence, retry et priorité.

Le monitoring temps réel permet de suivre l'état de toutes les queues, le statut des workers (idle/busy/error), le throughput (jobs/min), et de déclencher l'auto-scaling quand le nombre de jobs en attente dépasse un seuil. Un circuit breaker protège contre les cascades d'échecs.

```
# Architecture V2 – Queues et workers
queues:
  scraping:      3 workers, retry 3, backoff exponential 2s, priority 10
  ai-cleaner:    2 workers, retry 2, backoff exponential 3s, priority 5
  export:        2 workers, retry 2, backoff fixed 1s, priority 10
  notifications: 5 workers, retry 3, backoff exponential 0.5s, priority 1
  reports:       1 worker,  retry 1, backoff fixed 5s, priority 20
```

16.3.2 16.3.2 Fonctionnalités V2

Module	Fonctionnalités	Objectif
Architecture distribuée	Redis + BullMQ + 13 workers + auto-scaling	5 000 jobs simultanés
BI	Power BI Ready, prévisions, scoring, 7 types de graphiques	Tableaux de bord décisionnels
SaaS Enterprise	Licences activables, facturation FCFA, quota temps réel	Monétisation complète
Sécurité avancée	WAF (10 règles), DDoS, captcha, audit blockchain	Conformité APIPD
Agents IA	10 agents spécialisés (pipeline coordonné)	Automatisation complète
Back Office	9 modules admin (users, billing, logs, audit...)	Administration centralisée
Carte avancée	Heatmap, rayon de recherche, distance haversine	Analyse géospatiale

16.4. 16.4 Phase 4 — V3 Innovation (Mois 15-18)

La version 3 (V3) introduit des innovations différenciantes : assistant IA conversationnel, recherche en langage naturel, enrichissement par VLM (vision language model), intégration Mobile Money native, et marketplace de connecteurs. L'objectif est de consolider la position de leader sur le marché ivoirien et d'envisager l'expansion régionale (Afrique de l'Ouest).

16.4.1 16.4.1 Innovations V3

- Assistant IA conversationnel : compréhension du langage naturel (FR), traduction automatique en requête structurée, réponse en langage naturel avec résultats
- VLM (Vision Language Model) : analyse de captures d'écran de sites web pour extraire des informations visuelles (logos, horaires affichés, certifications)
- Marketplace de connecteurs : API publique permettant à des tiers de créer des connecteurs de sources personnalisées
- Mobile Money natif : intégration Orange Money, MTN MoMo, Moov Africa pour la facturation et les paiements in-app
- Expansion régionale : support multi-pays (Sénégal, Mali, Burkina Faso, Guinée) avec adaptation des sources et référentiels
- IA prédictive : prédiction des tendances sectorielles, recommandation de prospection, scoring prédictif de succès commercial

16.4.2 16.4.2 Vision long terme (24+ mois)

Au-delà de 18 mois, ScrapIQ CI vise à devenir la plateforme de référence pour la données d'entreprises en Afrique de l'Ouest. Les évolutions envisagées incluent :

- Réseau de 50+ sources de données couvrant 10 pays d'Afrique de l'Ouest
- 1 million+ d'entreprises indexées avec données enrichies en temps réel
- API publique avec 1000+ développeurs tiers (marketplace d'applications)
- Intelligence business : recommandations de prospection, scoring prédictif, analyse de marché automatisée
- Blockchain pour la traçabilité des données (preuve d'origine, horodatage immuable)
- IA générative pour la création automatique de rapports personnalisés

16.5. 16.5 Timeline visuelle

Gantt simplifié – Roadmap ScrapIQ CI

Phase 1: MVP |■■■■■■■■■■■■■■■■■■■■| (Mois 1-4)
Phase 2: V1 Production |■■■■■■■■■■■■■■■■■■■■| (Mois 5-8)
Phase 3: V2 Scale |■■■■■■■■■■■■■■■■■■■■■■■■■■■■■■| (Mois 9-14)
Phase 4: V3 Innovation |■■■■■■■■■■■■■■■■■■■■■■■■■■■■■■| (Mois 15-18)

Jalons:

- M4 → MVP livré + 10 beta-testeurs
- M8 → V1 production + 100 utilisateurs payants
- M14 → V2 scale + 1000 utilisateurs + architecture distribuée
- M18 → V3 innovation + assistant IA + expansion régionale

**CHAPITRE
17****Maintenance**

La maintenance de ScrapIQ CI couvre trois dimensions complémentaires : corrective (résolution des bugs), évolutive (ajout de fonctionnalités) et préventive (optimisation, monitoring, mises à jour). Cette stratégie de maintenance garantit la disponibilité, la performance et la sécurité de la plateforme sur le long terme, avec un SLA de 99,9% pour les clients Enterprise.

17.1. 17.1 Maintenance corrective

La maintenance corrective consiste à résoudre les anomalies détectées en production. ScrapIQ CI met en œuvre un processus structuré de gestion des incidents, depuis la détection (monitoring automatique, signalement utilisateur) jusqu'à la résolution (correctif, déploiement, validation). L'objectif est de minimiser le temps de résolution (MTTR - Mean Time To Resolution) et l'impact sur les utilisateurs.

17.1.1 17.1.1 Classification des incidents

Niveau	Description	MTTR cible	Escalade
P0 — Critique	Plateforme indisponible, perte de données	< 1h	CEO + CTO + équipe on-call
P1 — Majeur	Fonctionnalité clé indisponible, API down	< 4h	Lead dev + on-call
P2 — Mineur	Bug fonctionnel, contournement possible	< 24h	Lead dev
P3 — Cosmétique	UI/UX, typo, alignment	< 72h	Dev team

17.1.2 17.1.2 Processus de résolution

Le processus de résolution d'incident suit les étapes suivantes :

- Détection : alerte automatique (Sentry, Prometheus, uptime monitoring) ou signalement utilisateur
- Triage : classification du niveau (P0-P3) et assignation à un développeur
- Investigation : analyse des logs, reproduction du problème, identification de la cause racine
- Correctif : développement du fix, tests (unitaires + intégration), code review
- Déploiement : déploiement en staging → validation → production (blue-green)
- Post-mortem : analyse de l'incident, plan d'action préventif, documentation

17.2. 17.2 Maintenance évolutive

La maintenance évolutive consiste à ajouter de nouvelles fonctionnalités, améliorer les existantes, et adapter la plateforme aux besoins changeants du marché. Elle représente environ 60% du temps de développement après le lancement.

17.2.1 17.2.1 Processus de développement évolutif

Phase	Activités	Durée moyenne
Idéation	Analyse des besoins, retours utilisateurs, étude de faisabilité	1-2 semaines
Conception	Spécifications techniques, architecture, maquettes	1-2 semaines
Développement	Implémentation, tests unitaires, code review	2-6 semaines
Test	Tests d'intégration, E2E, performance, sécurité	1-2 semaines
Déploiement	Staging → production progressive (canary)	2-3 jours
Monitoring	Suivi des métriques, retours utilisateurs	1 semaine

17.3. 17.3 Maintenance préventive

La maintenance préventive vise à anticiper les problèmes avant qu'ils n'impactent les utilisateurs. Elle inclut le monitoring continu, l'optimisation des performances, les mises à jour de sécurité, et la gestion technique de la dette.

17.3.1 17.3.1 Monitoring continu

Métrique	Outil	Seuil d'alerte	Action
Uptime	UptimeRobot + health check	< 99.9%	Escalade P0
Latence API (P95)	Prometheus + Grafana	> 500ms	Investigation
Taux d'erreur	Sentry	> 1%	Investigation immédiate
CPU usage	Grafana	> 80%	Auto-scale ou investigation
Mémoire	Grafana	> 85%	Investigation memory leak
Espace disque	Grafana	> 80%	Cleanup + expansion
Queue length	BullMQ monitoring	> 50 jobs	Scale workers
Rate limit hits	Security module	> 100/h	Investigation attaque

17.3.2 17.3.2 Mises à jour de sécurité

Les mises à jour de sécurité sont appliquées selon le calendrier suivant :

- Dépendances NPM : scan hebdomadaire (npm audit), mise à jour mensuelle
- Système d'exploitation (serveurs) : mises à jour de sécurité dans les 48h
- Base de données PostgreSQL : mise à jour de version mineure trimestrielle
- Next.js / React : mise à jour vers la dernière stable tous les 2 mois
- Playwright / Chromium : mise à jour mensuelle (suivi des changements Google Maps)
- Audit de sécurité complet : trimestriel (scan OWASP ZAP, penetration testing)

17.4. 17.4 SLA et support

ScrapIQ CI propose trois niveaux de SLA selon le plan d'abonnement :

Plan	Uptime garanti	Support	Temps de réponse	Canal
Starter	99,5%	Email	< 48h	support@scraapiq.ci
Pro	99,9%	Email + Chat	< 8h (business hours)	Chat in-app + email
Enterprise	99,9%	Email + Chat + Téléphone	< 1h (24/7 pour P0)	Téléphone + chat + email

17.4.1 17.4.1 Crédits de service

En cas de non-respect du SLA, des crédits de service sont accordés automatiquement :

- Uptime < 99,9% sur un mois → 10% du montant mensuel crédité
- Uptime < 99,5% sur un mois → 25% du montant mensuel crédité
- Uptime < 99,0% sur un mois → 50% du montant mensuel crédité
- Indisponibilité P0 > 4h → 1 mois gratuit offert

**CHAPITRE
18****Évolutions**

Les évolutions envisagées pour ScrapIQ CI s'articulent autour de quatre axes stratégiques : l'élargissement de la couverture géographique, l'enrichissement des données par IA, l'ouverture de la plateforme via une marketplace, et l'intégration d'technologies émergentes (blockchain, IA générative). Ces évolutions sont planifiées sur un horizon de 24 à 36 mois.

18.1. 18.1 Évolutions envisagées**18.1.1 18.1.1 Expansion géographique**

ScrapIQ CI vise à étendre sa couverture à l'ensemble de l'Afrique de l'Ouest dans un délai de 24 mois. Cette expansion se fera par paliers, en commençant par les pays francophones limitrophes de la Côte d'Ivoire, puis en s'étendant progressivement à toute la CEDEAO.

Pays	Villes cibles	Sources spécifiques	Timeline
Sénégal	Dakar, Thiès, Saint-Louis	Annuaire.sn, SENAUI	Mois 18-20
Mali	Bamako, Sikasso	Annuaire.ml, RCCM Mali	Mois 20-22
Burkina Faso	Ouagadougou, Bobo-Dioulasso	Annuaire.bf, RCCM BF	Mois 20-22
Guinée	Conakry, Kankan	Annuaire.gn	Mois 22-24
Ghana	Accra, Kumasi	Google Maps GH, Yello	Mois 24-26
Nigeria	Lagos, Abuja	Google Maps NG	Mois 26-30

18.1.2 18.1.2 Enrichissement IA avancé

L'enrichissement par IA sera étendu avec de nouvelles capacités :

- VLM (Vision Language Model) : analyse de captures d'écran de sites web pour extraire logos, horaires, certifications, labels qualité
- NLP avancé : analyse de sentiments des avis clients Google Maps pour scoring de réputation
- IA prédictive : prédiction de la santé financière d'une entreprise à partir de signaux publics (croissance, recrutement, investissements)
- Génération de descriptions personnalisées : création automatique de fiches d'entreprises adaptées au contexte (commercial, investisseur, partenaire)
- Détection de fraudes : identification d'entreprises avec données suspectes (fausses adresses, téléphones invalides, doublons intentionnels)
- Recommandation de prospection : suggestion d'entreprises à contacter selon le profil commercial de l'utilisateur

18.1.3 18.1.3 Marketplace de connecteurs

ScrapIQ CI ouvrira une marketplace permettant à des développeurs tiers de créer et vendre des connecteurs de sources de données personnalisées. Cette marketplace fonctionnera sur le modèle revenue-share (70/30)

et permettra d'étendre la couverture de sources sans développement interne.

Aspect	Description
Modèle	API publique + SDK TypeScript/Python pour développer des connecteurs
Revenue share	70% pour le développeur, 30% pour ScrapIQ CI
Validation	Review process (sécurité, qualité, performance) avant publication
Pricing	Gratuit, payant par usage, ou abonnement mensuel
Documentation	Spec OpenAPI complète, exemples, tutoriels
Support	Forum communautaire + support premium pour connecteurs certifiés

18.2. 18.2 Recherche et développement

18.2.1 18.2.1 Axes de R&D;

La R&D; de ScrapIQ CI se concentre sur quatre axes prioritaires :

Axe R&D;	Description	Investissement	Horizon
IA conversationnelle	Assistant IA multi-langues (FR, EN, langues locales)	15 M FCFA/an	6-12 mois
Blockchain traçabilité	Preuve d'origine des données, horodatage immuable	10 M FCFA/an	12-18 mois
Edge computing	Scraping distribué géographiquement (latence réduite)	8 M FCFA/an	12-24 mois
IA générative rapports	Génération automatique de rapports personnalisés	12 M FCFA/an	6-12 mois

18.2.2 18.2.2 Partenariats académiques

ScrapIQ CI établira des partenariats avec les universités ivoiriennes pour :

- Stage et emplois pour étudiants en informatique (Université Félix Houphouët-Boigny, INPHB)
- Recherche appliquée sur le NLP pour les langues locales (Nouchi, Dioula, Baoulé)
- Études de marché et d'impact économique (data science appliquée)
- Hackathons annuels sur le thème du scraping éthique et de la donnée d'entreprise

18.3. 18.3 Innovations futures

18.3.1 18.3.1 Technologies émergentes

Technologie	Cas d'usage ScrapIQ CI	Maturité	Timeline
WebAssembly	Scraping ultra-rapide côté client (bypass JS rendering)	Expérimental	18-24 mois
Federated Learning	Entraînement de modèles IA sans centraliser les données	Recherche	24-36 mois
Zero-knowledge proofs	Vérification de données sans révéler la source	Recherche	36+ mois
Quantum-resistant crypto	Chiffrement post-quantique pour données sensibles	Veille	36+ mois
MCP (Model Context Protocol)	Standardisation des échanges entre agents IA	Émergent	12-18 mois

18.3.2 18.3.2 Vision 2030

À l'horizon 2030, ScrapIQ CI ambitionne de devenir la plateforme de référence pour la données d'entreprises en Afrique francophone, avec :

- 10+ pays couverts (CEDEAO + Afrique centrale)
- 5+ millions d'entreprises indexées
- 100+ sources de données connectées
- 10 000+ organisations clientes
- Marketplace de 500+ connecteurs
- API publique utilisée par 10 000+ développeurs
- IA prédictive avec 90% de précision sur les recommandations de prospection
- Certification ISO 27001 (sécurité) et ISO 9001 (qualité)

**CHAPITRE
19****Annexes**

Les annexes regroupent le glossaire des termes techniques, les références réglementaires et normatives, les contacts du projet, et les documents complémentaires utiles à la compréhension du cahier des charges.

19.1. 19.1 Glossaire

Terme	Définition
API	Application Programming Interface — interface de programmation permettant à des logiciels de communiquer entre eux
BM25	Okapi BM25 — algorithme de scoring de pertinence utilisé par Elasticsearch pour classer les résultats de recherche
BullMQ	Bibliothèque Node.js pour les queues de jobs asynchrones, basée sur Redis
CRUD	Create, Read, Update, Delete — les 4 opérations de base sur une ressource REST
CSR/SSR	Client-Side Rendering / Server-Side Rendering — stratégies de rendu web
Déduplication	Processus d'identification et de fusion des doublons dans un jeu de données
Embedding	Représentation vectorielle d'un texte, utilisée pour la comparaison sémantique
Elasticsearch	Moteur de recherche distribué basé sur Lucene, avec scoring BM25
FCFA / XOF	Franco CFA — monnaie utilisée en Côte d'Ivoire (1 EUR = 655,957 FCFA)
GPS	Global Positioning System — système de positionnement par satellite
Haversine	Formule calculant la distance entre deux points GPS sur une sphère
IndexedDB	API JavaScript de stockage asynchrone côté client (base de données dans le navigateur)
Jaro-Winkler	Algorithme de similarité entre chaînes de caractères, utilisé pour la déduplication
JWT	JSON Web Token — standard pour l'authentification stateless (RFC 7519)
Leaflet	Bibliothèque JavaScript open-source pour cartographie interactive
LLM	Large Language Model — modèle d'IA générative (ex: GLM-4, GPT-4)
MRR	Monthly Recurring Revenue — revenu mensuel récurrent
NLP	Natural Language Processing — traitement du langage naturel par IA
OAuth 2.0	Protocole d'autorisation déléguée (RFC 6749)
OpenStreetMap	Projet collaboratif de cartographie libre et gratuite
pgvector	Extension PostgreSQL pour le stockage et la recherche de vecteurs
PWA	Progressive Web App — application web installable avec capacités offline
RBAC	Role-Based Access Control — contrôle d'accès basé sur les rôles

Terme	Définition
RCCM	Registre du Commerce et du Crédit Mobilier — registre officiel des entreprises en CI
Redis	Base de données en mémoire, utilisée comme cache et message broker
RGPD / AIPD	Règlement Général Protection Données (UE) / Autorité de Protection des Données (CI)
SaaS	Software as a Service — logiciel vendu en mode abonnement
Scraping	Extraction automatisée de données depuis des sites web
Service Worker	Script exécuté en arrière-plan par le navigateur (PWA)
SLA	Service Level Agreement — accord de niveau de service
TOTP	Time-based One-Time Password — code 2FA à usage unique (RFC 6238)
VLM	Vision Language Model — modèle d'IA capable d'analyser des images
WAF	Web Application Firewall — pare-feu applicatif web
WebSocket	Protocole de communication bidirectionnelle persistante
Z.ai SDK	SDK JavaScript pour les services d'IA Z.ai (LLM, VLM, TTS, ASR)

19.2. 19.2 Références et normes

Référence	Description	Pertinence
RFC 7519	JSON Web Token (JWT)	Authentification API
RFC 6749	OAuth 2.0 Authorization Framework	SSO Google/Microsoft
RFC 6238	TOTP: Time-Based One-Time Password	2FA
Loi n°2013-450	Protection des données personnelles (Côte d'Ivoire)	Conformité APIPD
RGPD (UE) 2016/679	Règlement général protection données	Référence pour standards
OWASP Top 10	Top 10 vulnérabilités web	Sécurité WAF
ISO 27001	Management de la sécurité de l'information	Certification future
OpenAPI 3.0	Specification REST API	Documentation Swagger
WCAG 2.1	Web Content Accessibility Guidelines	Accessibilité
PWA Checklist	Google PWA checklist	Progressive Web App

19.3. 19.3 Contacts

Rôle	Nom	Email	Téléphone
Product Owner	Adama Koné	adama@scraapiq.ci	+225 07 00 00 00 01
Lead Developer	Mariam Traoré	mariam@scraapiq.ci	+225 07 00 00 00 02
DevOps	Sekou Bamba	sekou@scraapiq.ci	+225 07 00 00 00 03
Support	support@scraapiq.ci	—	+225 27 22 00 00 00

19.4. 19.4 Historique des versions

Version	Date	Auteur	Changements
1.0	17/07/2026	Adama Koné	Version initiale — cahier des charges complet

Fin du document

ScrapIQ CI — Web Scraping Intelligent pour la Côte d'Ivoire

Document confidentiel — © 2026 ScrapIQ CI — Tous droits réservés

19.5. 3.16 Spécifications des modules complémentaires (suite)

19.5.1 3.16.1 Module Sécurité Entreprise — Détail des 9 couches

Le module de sécurité Entreprise implémente 9 couches de protection complémentaires qui fonctionnent en synergie pour garantir la confidentialité, l'intégrité et la disponibilité de la plateforme. Chaque couche est indépendamment configurable et monitorée en temps réel.

1. Rate Limiting — 6 configurations par endpoint. Token bucket par IP+endpoint, blocage automatique, retry-after. Configurations: default (60/min), login (5/15min), register (3/1h), api (100/min), scraping (20/h), export (30/h). Chaque config a un windowMs, maxRequests, et blockDurationMs distincts.

2. WAF — 10 règles de protection. Détection: SQL injection (UNION, OR 1=1, DROP), XSS (script, event handlers), Path traversal, SSRF, Command injection, XXE, LFI. Action: block (9 règles) ou log (1 règle). Sanitization automatique des inputs. Logs dans securityEvents.

3. DDoS — Détection de pics de trafic. Seuil: 100 requêtes/seconde par IP. Blocage: 1 heure. Tracking automatique de toutes les IPs. Blacklist dynamique. Stats: total IPs, blocked IPs, recent IPs. Liste des IPs bloquées avec timestamp.

4. Captcha — Challenge après échecs. Déclenché après 3 tentatives échouées. Types: addition, multiplication, recopiage de mot. TTL: 5 minutes. Max 3 tentatives par challenge. clearedFailedAttempts après succès. Stats: challenges actifs, IPs avec échecs, IPs requiring captcha.

5. Journalisation — Événements de sécurité structurés. SecurityEvent avec type, severity (info/warn/error/critical), source, details, metadata. 1000 événements max (rolling). Filtres par type et sévérité. Stockage en mémoire avec rotation automatique.

6. Audit — Blockchain immuable. AuditEntry avec hash chaîné SHA-256. Chaque entrée contient le hash de la précédente. verifyAuditIntegrity() vérifie la chaîne complète. Catégories: auth, security, data, api, admin, rgpd. 5000 entrées max. Immuable (pas de UPDATE/DELETE).

7. Chiffrement — AES-256-GCM. Algorithme: AES-256-GCM avec IV (16 bytes) + AuthTag. Clé: 256 bits (env var). Mots de passe: bcrypt 12 rounds. Masquage: email (ad****@domain), téléphone (+225****1234), CB (*****4242). Champs chiffrés: passwords, 2FA secrets, API keys, refresh tokens, session cookies, OAuth tokens.

8. RGPD/APIPD — Conformité loi n°2013-450. 8 droits implémentés: accès, effacement, portabilité, rectification, restriction, registre, notification 72h, pseudonymisation. GdprRequest model avec type, status (pending/processing/completed/rejected). Conforme APIPD (Autorité de Protection des Données de Côte d'Ivoire).

9. Protection API — 7 headers + CORS + CSP. Headers: X-Content-Type-Options, X-Frame-Options, X-XSS-Protection, HSTS, Referrer-Policy, Permissions-Policy, CSP. CORS: 3 origines autorisées. CSP: 9 directives. Validation: method, body size (10 Mo), WAF sur URL+body. Sanitization automatique.

19.5.2 3.16.2 Module Architecture Distribuée — Détail des 5 queues

L'architecture distribuée repose sur 5 queues BullMQ spécialisées, chacune avec sa propre configuration de concurrence, retry, backoff et priorité. Redis est utilisé comme message broker (fallback mémoire si Redis indisponible).

scraping — Workers: 3, Retry: 3, Backoff: exponential 2s, Priorité: 10, Max durée: 5 min. Jobs de scraping Google Maps, Facebook, LinkedIn, Sites web. Le retry gère les blocages temporaires (429, timeout). Le backoff exponentiel évite d'aggraver le blocage.

ai-cleaner — Workers: 2, Retry: 2, Backoff: exponential 3s, Priorité: 5, Max durée: 3 min. Nettoyage IA: déduplication (embeddings + Jaro-Winkler + GPS), enrichissement LLM, scoring qualité, détection fermetures. Priorité haute car les données nettoyées alimentent tous les autres modules.

export — Workers: 2, Retry: 2, Backoff: fixed 1s, Priorité: 10, Max durée: 2 min. Génération d'exports multi-format (xlsx, csv, pdf, json, zip). Backoff fixe car les échecs sont généralement liés à la mémoire, pas au réseau.

notifications — Workers: 5, Retry: 3, Backoff: exponential 0.5s, Priorité: 1, Max durée: 30s. Envoi multi-canal: email, SMS, WhatsApp, push, webhook, in-app. Priorité critique (1) car les notifications d'alerte doivent être livrées rapidement. Concurrency élevée (5) car les envois sont indépendants.

reports — Workers: 1, Retry: 1, Backoff: fixed 5s, Priorité: 20, Max durée: 5 min. Rapports automatiques planifiés (daily, weekly, monthly). Priorité basse (20) car ce sont des tâches de fond. Concurrency 1 car les rapports sont lourds (génération PDF + envoi).

19.5.3 3.16.3 Module Business Intelligence — Détail des 6 vues

Le module BI propose 6 vues analytiques avec 7 types de graphiques Recharts, conçues pour être directement exploitables dans Power BI Desktop via l'API REST.

Vue d'ensemble — 6 KPIs avec sparklines (entreprises totales, croissance mensuelle, score qualité, taux complétude, sources actives, couverture géo). Composed chart croissance 12 mois (area + bar). Pie chart répartition secteurs. Tableau top 10 entreprises.

Prévisions — Forecast chart avec réel (5 mois) + prévision (3 mois) et intervalle de confiance à 95%. 3 cards prévisions mensuelles. Bar chart prévisions par secteur (actuel vs +3 mois).

Secteurs — Bar chart horizontal volume par secteur (10 secteurs colorés). Bar chart horizontal croissance par secteur. Scatter chart matrice qualité × croissance (taille = nombre entreprises). Tableau détaillé avec CA estimé.

Géographie — Bar chart 8 communes Abidjan. Bar chart horizontal 8 villes CI. Composed chart communes (count + growth + quality, double axe Y). Tableau villes avec part %, croissance, qualité.

Qualité — 4 KPIs (score global, complétude, doublons, fiches enrichies). Radar 7 dimensions (actuel vs objectif). Line chart évolution 12 mois (3 métriques). Barres détaillées par dimension.

Power BI Ready — 5 tables (Companies 38862, Sectors 10, Communes 12, ScrapingJobs 4821, AuditLogs 12450). 6 mesures DAX. 4 endpoints REST. Guide connexion Power BI Desktop en 4 étapes.

19.6. 4.12 Architecture détaillée — Flux de données end-to-end

Le flux de données complet de ScrapIQ CI, depuis la requête utilisateur jusqu'à l'export final, traverse 10 étapes orchestrées par les 10 agents IA spécialisés. Voici le détail de chaque étape avec les volumes, latences et technologies impliquées.

Étape	Composant	Volume typique	Latence	Technologie
1. Requête	Assistant IA / Search	1 requête	2-5s (LLM)	z-ai GLM-4
2. Sources	Agent 1	3-5 sources	< 1s	Règles + heuristiques
3. Scraping	Agent 2 (Playwright)	50-100 entreprises	30-120s	Playwright + stealth
4. Nettoyage	Agent 3	50-100 items	1-3s	Regex + normalize
5. Dédup	Agent 4	10-30 doublons	1-5s	pgvector + Jaro-Winkler
6. Enrichissement	Agent 5 (LLM)	20-50 champs	5-30s	z-ai GLM-4
7. Validation	Agent 6	50-100 items	2-10s	Regex + HTTP checks
8. Géocodage	Agent 7	50-100 adresses	5-20s	OSM Nominatim
9. Classification	Agent 8 (LLM)	50-100 items	5-20s	Règles + z-ai
10. Export	Agent 10	50-100 lignes	2-10s	xlsx + json2csv

19.7. 4.13 Architecture — Schéma réseau détaillé

Schéma réseau détaillé (ASCII art)



19.8. 9.12 API — Schéma de données des réponses

19.8.1 9.12.1 Format de réponse standard

```
// Format succès
{
  "success": true,
  "data": T,
  "meta": {
    "page": 1,
    "limit": 20,
    "total": 38862,
    "totalPages": 1944,
    "hasNext": true,
    "hasPrev": false
  },
  "message": "Optional message"
}

// Format erreur
{
  "success": false,
  "error": "Description de l'erreur",
  "code": "OPTIONAL_ERROR_CODE"
}

// Format pagination
GET /api/v1/companies?page=2&limit=10
→ meta.totalPages = ceil(total / limit)
→ meta.hasNext = page < totalPages
→ meta.hasPrev = page > 1
```

19.8.2 9.12.2 Codes de statut HTTP

Code	Signification	Quand
200	OK	GET, PUT, DELETE réussi
201	Created	POST réussi (ressource créée)
202	Accepted	Job asynchrone lancé (scraping, export)
400	Bad Request	Paramètres invalides ou manquants
401	Unauthorized	Token JWT manquant ou invalide
403	Forbidden	Rôle insuffisant (RBAC)
404	Not Found	Ressource introuvable
409	Conflict	Ressource déjà existante (email, slug)
422	Unprocessable Entity	Validation échouée (format, longueur)
429	Too Many Requests	Rate limit dépassé (retry-after)
500	Internal Server Error	Erreur serveur non gérée
503	Service Unavailable	Mode maintenance ou overload

19.9. 10.7 Modèle de données — Schéma Prisma complet (30+ modèles)

ScrapIQ CI utilise Prisma ORM avec SQLite (dev) / PostgreSQL (prod). Le schéma contient 30+ modèles organisés en 7 domaines fonctionnels.

Domaine	Modèles	Tables
Auth & Users	User, UserSession, Account, RefreshToken, JwtBlacklist	5
Organisation	Organization, Workspace, Member	3
API & Security	ApiKey, AuditLog, RestApiLog	3
Scraping	SearchJob, JobTask, ScrapeRawResult, Company, CompanySourceRef	5
Contacts	Contact, Geolocation, Tag, CompanyTag	4
IA & Dédup	DedupCluster, DedupClusterMember, DedupDecision, CompanyEmbedding, AiEnrichment, AiModelLog	6
SaaS & Billing	License, Subscription, Invoice, QuotaUsage, Plan	5
Notifications	Notification, Webhook, WebhookDelivery, AlertRule, ScheduledReport, ReportExecution	6
Sources & Export	Source, ExportJob, ExportItem	3

Total : 30+ modèles avec index optimisés, contraintes d'intégrité, relations cascade, et Row-Level Security (RLS) pour l'isolation multi-tenant.

19.9.1 10.7.1 Index et optimisations

Table	Index	Type	Justification
companies	(tenant_id) WHERE deleted_at IS NULL	B-tree partiel	Filtrage tenant + exclusion soft-deleted
companies	gin(name gin_trgm_ops)	GIN trigramme	Recherche floue par nom
companies	(tenant_id, sector_id)	B-tree composite	Filtres secteur + tenant
contacts	(company_id, type) WHERE is_primary	Partial unique	1 contact primaire par type
company_embeddings	hnsw(embedding vector_cosine_ops)	HNSW vectoriel	Recherche ANN dédup IA
search_jobs	(status, priority) WHERE status IN ('queued','running')	Partial	Queue du scheduler
api_call_logs	(tenant_id, created_at DESC)	B-tree	Logs récents par tenant
audit_logs	(entity_type, entity_id)	B-tree	Traçabilité entité

19.10. 11.10 Sécurité — Checklist complète de conformité

La checklist suivante récapitule toutes les mesures de sécurité implémentées dans ScrapIQ CI, classées par catégorie.

Catégorie	Mesure	Statut	Détail
Auth	JWT HS256 (15min access, 30j refresh)	■ Implémenté	jose + rotation + blacklist JTI
Auth	OAuth Google + Microsoft	■ Implémenté	Passport + state CSRF + code exchange
Auth	2FA TOTP (RFC 6238)	■ Implémenté	otppath + 10 backup codes
Auth	Rate limiting login (5/15min)	■ Implémenté	Token bucket + lockout 15min
RBAC	5 rôles hiérarchiques	■ Implémenté	Owner > Admin > Manager > Agent > Viewer
RBAC	22 permissions granulaires	■ Implémenté	6 catégories, matrice rôle×permission
RBAC	Sidebar filtrée par rôle	■ Implémenté	canAccess() + 3 niveaux protection
WAF	10 règles (SQL, XSS, path, SSRF, cmd, XXE, LFI)	■ Implémenté	Regex + block/log + sanitization
DDoS	Détection 100 req/s + blocage 1h	■ Implémenté	Tracking IPs + blacklist dynamique
Captcha	Challenge après 3 échecs	■ Implémenté	Math + word, TTL 5min
Chiffrement	AES-256-GCM (données sensibles)	■ Implémenté	IV + AuthTag, bcrypt 12 rounds
Chiffrement	TLS 1.3 (transit)	■ Configuré	Caddy + Cloudflare
Audit	Blockchain immuable (SHA-256)	■ Implémenté	Hash chaîné + verifyIntegrity()
RGPD	8 droits APIPD (loi 2013-450)	■ Implémenté	Access, erasure, portability, rectification
API	7 security headers	■ Implémenté	X-Content-Type, X-Frame, CSP, HSTS, etc.
API	CORS (3 origines)	■ Implémenté	scraapiq.ci, app.scraapiq.ci, localhost
API	CSP (9 directives)	■ Implémenté	default-src, script-src, style-src, etc.
API	Validation requêtes (method, body, WAF)	■ Implémenté	10 Mo max, 5 méthodes, WAF URL+body
PWA	Service Worker (cache, offline, sync)	■ Implémenté	3 stratégies: cache-first, SWR, network-first
Session	Révocation tous devices	■ Implémenté	blacklistAllUserTokens + revoke sessions